

STAGE DE FIN D'ÉTUDES

AUTOMATISATION DE L'ANALYSE D'INCIDENTS PAR L'UTILISATION DU MACHINE LEARNING



Étudiant :
Florian LEPONT

Tuteur responsable :
M. Emmanuel NALEPA

Remerciements

Je tiens tout d'abord à remercier l'entreprise Aldebaran de m'avoir accueilli dans le cadre de mon stage de fin d'études, au sein de l'équipe «Qualification Hardware Pepper».

Je remercie tout particulièrement M. Emmanuel Nalepa de m'avoir permis de participer à ce projet captivant et formateur, m'offrant ainsi la possibilité d'étoffer mes connaissances et mes aptitudes dans de nombreux domaines. Sa disponibilité, sa pédagogie et son expérience ont été des atouts essentiels à mon enrichissement technique.

J'adresse également mes remerciements aux personnes qui m'ont proposé leur aide, ainsi qu'à tous les membres de mon équipe pour leur bonne humeur et leur sympathie.

Résumé

Mon stage ingénieur, réalisé dans le cadre de ma cinquième année de formation à l'École Nationale d'Ingénieurs de Brest (ENIB), s'est déroulé au sein du département "Qualification Hardware Pepper (QWP)" de l'entreprise Aldebaran. La société parisienne s'est fait connaître dans le monde des nouvelles technologies et de la robotique humanoïde grâce au développement de son premier produit, "Nao". A l'origine, le robot se prédestine à l'univers de la recherche et aux universités. La société cherche aujourd'hui à conquérir de nouveaux marchés en offrant des produits et des services au monde de l'entreprise et aux particuliers. Cela se traduit notamment par le développement d'un tout nouveau produit : "Pepper".

Cette extension du marché s'accompagne d'une montée en puissance de la fabrication de robots. Cela induit le développement d'une nouvelle génération d'outils de production et de post-production. Un des dispositifs mis en place est le "Filtering Test" : à la fin de la chaîne de production, les robots sont soumis à une série de tests qui visent à mettre à l'épreuve leurs différentes parties mécaniques. Lorsqu'une erreur est détectée, différentes données du robot sont enregistrées (e.g. température des fusibles, valeurs de l'accéléromètre, etc.). Afin de déterminer l'origine de l'anomalie sur le robot, chaque donnée est étudiée minutieusement et des hypothèses sont émises. Cette tâche dite d'investigation s'avère longue et laborieuse, il y a donc un désir de l'automatiser.

Le but de ma présence au sein d'Aldebaran est donc de répondre à ce besoin. En m'appuyant sur l'utilisation de méthodes d'apprentissage automatique (Machine Learning), j'ai mis au point un algorithme capable de déterminer automatiquement (après une phase d'apprentissage) les causes qui ont entraîné l'apparition d'anomalies sur Pepper. La mise au point de cet outil a été réalisé en trois temps :

1. auto-formation à l'apprentissage automatique et maîtrise des outils de développement.
2. conception et développement de l'algorithme.
3. industrialisation du produit, i.e. en simplifier l'utilisation et le robustifier.

Ce rapport de stage présente les différentes recherches effectuées, ainsi que les travaux de développement réalisés pour répondre au mieux à la problématique.

Sommaire

1	Entreprise	9
1.1	Histoire	9
1.1.1	Le premier robot, Nao	9
1.1.2	La famille s'agrandit	9
1.2	Les produits	9
1.2.1	Nao	10
1.2.2	Pepper	11
1.2.3	Roméo	12
1.2.4	Le système d'exploitation NAOqi	13
1.2.5	Plateforme de développement	13
2	Introduction	15
2.1	Présentation du produit	15
2.1.1	Les actionneurs	15
2.1.2	Les senseurs	16
2.2	Expression du besoin	16
2.2.1	DExTER et MEIGUI	16
2.2.2	Hiérarchisation des erreurs	17
2.2.3	Exemple d'analyse d'une anomalie	18
2.3	Solution proposée	19
3	Le Machine Learning	21
3.1	Généralités sur le Machine Learning	21
3.1.1	Définition et principes généraux du Machine Learning	21
3.1.2	Les exemples	23
3.1.3	La décision	24
3.1.4	Le modèle	24
3.2	Les différents algorithmes d'apprentissage supervisé	28
3.2.1	La régression linéaire uni-variable	28

3.2.2	La régression linéaire multi-variable	30
3.2.3	La régression logistique	32
3.2.4	Support Vector Machine	37
3.2.5	Périmètres d'utilisation de la régression logistique et du SVM	38
3.2.6	Autres algorithmes d'apprentissage supervisé	39
4	Automatisation du processus d'investigation	41
4.1	Architecture High Level du système proposé	41
4.1.1	Les exemples	42
4.1.2	Le modèle d'apprentissage	46
4.1.3	La décision	46
4.2	Détection d'une root cause	46
4.2.1	Différentes approches étudiées	46
4.2.2	Reconnaissance de motifs	49
4.3	Performances de la solution	52
4.3.1	Optimisation des paramètres du SVM	52
4.3.2	Matrices de confusion	53
4.3.3	Courbes d'apprentissage	55
5	Industrialisation du produit	59
5.1	API	59
5.1.1	Prétraitement des données	59
5.1.2	Module Marchine Learning	60
5.2	Outils graphiques	61
5.2.1	Pattern selector	61
5.2.2	Probability Visualization	62
5.2.3	Control panel	62
5.3	Utilisation suggérée des outils	63
5.3.1	Menu principal	64
5.3.2	Nouvelle error name	64
5.3.3	Nouvelle root cause	65
5.3.4	Investiguer un fichier log	65
5.3.5	Analyse des performances d'une root cause	66
5.3.6	Mise à jour d'une root cause	66
5.4	Dimensionnement de la solution	66
6	Conclusion	73

Table des figures

1.1	Le robot humanoïde Nao	10
1.2	Le robot humanoïde Pepper	11
1.3	Le robot humanoïde Roméo	12
2.1	Répartition des actionneurs de Pepper	16
2.2	Analyse d'une anomalie : accéléromètre	18
2.3	Analyse d'une anomalie : les genoux	18
2.4	Analyse d'une anomalie : la hanche	18
3.1	Schéma fonctionnel haut niveau du Machine Learning	22
3.2	Schéma fonctionnel haut niveau du Machine Learning, l'exemple de la prévision saisonnière	23
3.3	Comparaison d'un apprentissage supervisé et non supervisé dans le cadre de l'exemple "apprendre aux humains"	26
3.4	Comparaison d'un apprentissage supervisé et non supervisé dans le cadre de l'exemple "prévisions saisonnières"	26
3.5	Comparaison par l'exemple de la régression et de la classification	27
3.6	Évolution du prix de l'immobilier en fonction de la surface	29
3.7	Régression linéaire, optimisation de la fonction coût	30
3.8	Régression linéaire, calcul des paramètres de l'hypothèse	31
3.9	Classification via régression linéaire	33
3.10	Fonction sigmoïde	34
3.11	Exemple d'une régression logistique	35
3.12	fonctions $-\log(h_\theta(x))$ et $-\log_\theta(1 - h(x))$	37
3.13	SVM : cas simple d'une régression logistique avec une hypothèse linéaire . .	38
3.14	SVM : optimisation du calcul de l'hypothèse par l'introduction de marges .	39
3.15	Exemple d'un problème de classification linéaire	39
3.16	Exemple d'un problème de classification non linéaire	40
4.1	Création des couches root cause	42
4.2	Utilisation de la couche error name	43

4.3	Synoptique d'une couche root cause	44
4.4	Représentation de la répartition des exemples et des classes en fonction des features	45
4.5	Calcul des caractéristiques simplifiées	47
4.6	Comparaison de deux caractéristiques	47
4.7	Formes caractéristiques de BaseAccZ en temps normal et en cas de chute . .	48
4.8	Patron caractéristique de la chute du robot	49
4.9	Détection d'une chute à partir du patron de BaseAccZ	50
4.10	Évolution de la position du senseur et de l'actuateur de la hanche	51
4.11	Créer un patron du motif caractéristique de la root cause "frottement des freins de la hanche"	52
4.12	Balayage des features et motif caractéristique d'une root cause	53
4.13	Courbe de probabilité de la root cause "frottement des freins de la hanche" .	54
4.14	Représentation de la répartition des exemples et des classes en fonction des features, approche fonctionnelle	55
4.15	Variation du paramètre C	55
4.16	Variation des paramètres C et gamma	56
4.17	Courbes de validation du paramètre C	56
4.18	Courbes de validation du paramètre gamma	57
4.19	Courbes d'apprentissage	57
5.1	Interface graphique du pattern selector	62
5.2	Interface graphique du pattern selector en mode étendu	63
5.3	Interface graphique du probability visualizator	64
5.4	Interface graphique du control pattern	65
5.5	Menu principal	66
5.6	Nouvelle root cause	68
5.7	Investigation d'un fichier log	69
5.8	Analyse des performances d'une couche root cause	70
5.9	Mise à jour d'une root cause	71
5.10	Evolution de la précision de l'algorithme en fonction de la taille de la région de sélection	72

Liste des tableaux

1.1	Caractéristiques techniques de Nao	10
1.2	Caractéristiques techniques de Pepper	11
1.3	Caractéristiques techniques de Roméo	12
2.1	Les différents capteurs de Pepper	17
2.2	Exemple d'un error name et ses root cause	17
3.1	Comparaison des différents modèles d'apprentissage	25
3.2	Comparaison des différentes catégories d'apprentissage supervisé	27
3.3	Parc immobilier	28
3.4	Parc immobilier multi-variable	30
3.5	Périmètre d'utilisation de la régression logistique et le SVM	38
4.1	Matrice de confusion	54
4.2	Matrice de confusion de la root cause "frottement des freins de la hanche" .	54

Chapitre 1

Entreprise

1.1 Histoire

Aldebaran (anciennement Aldebaran Robotics) est une société française de robotique humanoïde fondée en 2005 par Bruno Maisonnier.

1.1.1 Le premier robot, Nao

Constituée au départ d'une équipe de douze collaborateurs, la toute jeune entreprise se fixe comme objectif de développer des robots humanoïdes et de les commercialiser au grand public en tant que "nouvelle espèce bienveillante à l'égard des humains". Après trois années de recherche et développement, la société dévoile en 2008 son tout premier produit : Nao. La participation du robot humanoïde à divers événements internationaux, comme par exemple la RoboCup ou encore l'Exposition Universelle de Shanghai en 2010 participe à sa popularisation auprès des laboratoires de recherche, des universités et des développeurs. Une seconde génération de robot Nao apparaît en 2011. L'entreprise dévoile durant la même période le projet Roméo dont l'objectif est de créer un véritable robot d'assistance à la personne en partenariat avec différents acteurs de la recherche.

1.1.2 La famille s'agrandit

Lors de l'année 2012 Aldebaran Robotics est rachetée par SoftBank, société spécialisée dans le commerce électronique au Japon et prend le nom d'Aldebaran (suppression du terme "Robotics"). Débute alors la conception d'un tout nouveau produit, le robot humanoïde Pepper. Dévoilé au grand public en 2014, il est dans un premier temps vendu au Japon auprès des entreprises. Les premiers clients à en bénéficier sont les magasins de téléphonie mobile du groupe SoftBank. Les ventes s'ouvrent par la suite aux particuliers Japonais. La société compte aujourd'hui plus de 400 collaborateurs et poursuit le développement de ses trois produits afin de les améliorer et de conquérir de nouveaux marchés (Europe , Chine et États-Unis).

1.2 Les produits

Aldebaran commercialise à ce jour deux produits : Nao et Pepper. Le robot Roméo est une plateforme de recherche.

1.2.1 Nao

Nao est un robot humanoïde de 58 cm de hauteur. Les publics ciblés sont essentiellement les laboratoires de recherche et le monde de l'éducation (des écoles primaires jusqu'aux universités). Il est actuellement le produit le plus connu de l'entreprise auprès du grand public.



FIGURE 1.1 – Le robot humanoïde Nao

Caractéristiques techniques Caractéristiques techniques de la dernière version de Nao (V5, Évolution) tableau 1.1.

Caractéristiques générales	
Dimensions	574 x 311 x 275 mm
Masse	5,4 kg
Degrés de liberté	25
Processeur	Intel Atom Z530 1.6 GHz RAM : 1GB Mémoire flash : 2GB Micro SDHC : 8 GB
Système d'exploitation	Middleware Aldebaran NAOqi basé sur un noyau Linux
Connectivité	Wi-Fi, Ethernet, USB
Batterie	Autonomie : 90 minutes en usage normal Energie : 48.6 Wh
Vision	Deux caméras frontales 2D, 1220p, 30ips
Audio	Sortie : 2 haut-parleurs stéréo 4 microphones directionnels moteur de reconnaissance vocale Nuance
Capteurs	2 capteurs infra-rouges, résistance sensible à la pression, centrale inertielle, 2 systèmes sonars, 3 surfaces tactiles

TABLE 1.1 – Caractéristiques techniques de la dernière version commerciale de Nao [1]

1.2.2 Pepper

Dernier né d'Aldebaran, le robot Pepper est conçu pour vivre au côté des humains. Imaginé au départ pour accompagner et informer les clients dans les magasins de téléphonie du groupe japonais SoftBank, l'entreprise cherche à présent à placer son produit chez les particuliers. Le robot reprend la structure software et hardware de Nao. Contrairement à ce dernier, Pepper se déplace non pas grâce à une paire de jambes, mais via trois roues omnidirectionnelles qui facilitent son déplacement. A noter également que celui-ci est équipé d'une tablette tactile sur son torse pour faciliter les interactions Homme-Machine.



FIGURE 1.2 – Le robot humanoïde Pepper

Caractéristiques techniques Caractéristiques techniques de la dernière version commerciale de Pepper (V1.7) tableau 1.2.

Caractéristiques générales	
Dimensions	1210 x 480 x 425 mm
Masse	28 kg
Degrés de liberté	17
Processeur	Intel Atom E3845 1.91 GHz RAM : 4 GB Mémoire flash : 8 GB MICRO SDHC : 16Go
Système d'exploitation	Middleware Aldebaran NAOqi, basé sur un noyau Linux
Connectivité	Wi-Fi, Ethernet, USB
Batterie	Énergie : 795 Wh
Vision	2 caméras 2D 1 caméra 3D
Audio	3 microphones directionnels moteur de reconnaissance vocale Nuance
Connectivité	Wi-Fi, Ethernet
Capteurs	6 lasers, 2 capteurs infra-rouges, 1 système sonar, résistance sensible à la pression, 2 centrales inertielles, 3 surfaces tactiles

TABLE 1.2 – Caractéristiques techniques de la dernière version commerciale de Pepper [2]

1.2.3 Roméo

Roméo est un nouveau type de robot d'accompagnement et d'assistance à la personne. Cette plateforme de recherche est soutenue par Aldebaran ainsi que d'autres partenaires universitaires et laboratoires de recherche (e.g. INRIA, LAAS-CNRS, ISIR, ENSTA, Telecom, etc.). Il s'agit pour l'instant d'un prototype et sert principalement de plateforme de tests pour les prochaines innovations majeures de l'entreprise (e.g. yeux mobiles, système vestibulaire, etc.).

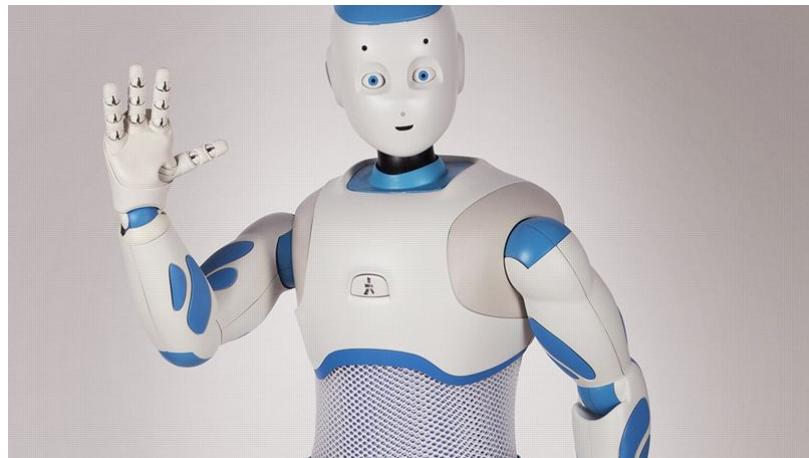


FIGURE 1.3 – Le robot humanoïde Roméo

Caractéristiques techniques Caractéristiques techniques de la dernière version commerciale de Roméo (V2) tableau 1.3.

Caractéristiques générales	
Hauteur	1467 mm
Masse	37 kg
Processeur	Intel ATOM Z530 1.6 GHz RAM : 1 GB Mémoire flash : 2 GB MICRO SDHC : 8 Go
Système d'exploitation	Middleware Aldebaran NAOqi, basé sur un noyau Linux
Connectivité	Wi-Fi, Ethernet
Batterie	Énergie : 795 Wh
Vision	4 caméras 2D 1 caméra 3D
Audio	3 microphones directionnels moteur de reconnaissance vocale Nuance
Connectivité	Wi-Fi, Ethernet
Capteurs	6 lasers, 2 capteurs infra-rouges, 1 système sonar, résistance sensible à la pression, 2 centrales inertielles, 3 surfaces tactiles

TABLE 1.3 – Caractéristiques techniques de la dernière version de Roméo
[3]

1.2.4 Le système d'exploitation NAOqi

NAOqi est le système d'exploitation commun aux 3 robots d'Aldebaran. Il se base sur la distribution de Linux Gentoo et contient plusieurs API's qui permettent de commander et de contrôler le robot [4].

NAOqi Core : Gestion de l'ensemble des fonctions de base des robots (e.g. mémoire, "autonomous Life", comportement du robot, etc.).

NAOqi Motion : Gestion des mouvements du robot.

NAOqi Audio : Gestion de la partie audio du robot.

NAOqi Vision : Gestion de la partie vidéo du robot

NAOqi People Perception : Ce module est utilisé pour détecter la présence de personnes autour du robot.

NAOqi Sensors : Gestion de l'ensemble des senseurs qui équipent le robot.

1.2.5 Plateforme de développement

Les robots sont fournis avec une plateforme de développement.

Choregraphe : Il s'agit d'un outil de programmation graphique basé sur une interface qui prend la forme de schémas blocs [5]. Il permet de façon simple d'interagir avec le robot et de concevoir des applications . Il comporte également un environnement de simulation 3D qui permet aux développeurs de tester leurs applications sans même posséder un robot. Le logiciel permet également de disposer d'un retour visuel sur ce que le robot perçoit (e.g. vidéos issues des caméras, données des moteurs, etc.)

Kit de développement (SDK) : Il permet de développer des applications pour les robots via plusieurs langages de programmation : C++, Python et Java [6].

Chapitre 2

Introduction

2.1 Présentation du produit

On présente ici de manière succincte l'architecture Hardware du robot Pepper afin de se familiariser avec les différents éléments du système avec lesquels on sera susceptible de travailler durant la mise en œuvre de ce projet.

2.1.1 Les actionneurs

Les moteurs

Le robot Pepper est constitué de 20 moteurs dont il est possible de contrôler la position et la rigidité (figure 2.1)

Tête : 2 moteurs pour les mouvements de lacet (HeadYaw) et de tangage (HeadPitch)

Bras : 4 moteurs par bras, répartis de la manière suivante :

Épaule : 2 moteurs pour les mouvements de tangage (ShoulderPitch) et de roulis du bras (ShoulderRoll).

Coude : 2 moteurs pour les mouvements de roulis (ElbowRoll) et de lacet (ElbowYaw) de l'avant-bras.

Main : 1 moteur pour le mouvement de lacet du poignet (WristYaw) et 1 pour le mouvement d'ouverture et de fermeture de la main (Hand).

Hanche : 2 moteurs pour le mouvement de roulis (HipRoll) et de tangage (HipPitch) du buste.

Genoux : 1 moteur pour le mouvement de tangage (KneePitch) du haut du corps.

Roues : 3 moteurs pour les mouvements de rotation de chacune des 3 roues omnidirectionnelles (WheelB, WheelFR et WheelFL).

Les Leds

Les Leds placées sur les épaules de Pepper, autour de ses yeux et de ses oreilles permettent d'obtenir un certain nombre d'informations sur son état. Par exemple, des Leds bleues en rotations autour des yeux indiquent que le robot écoute.

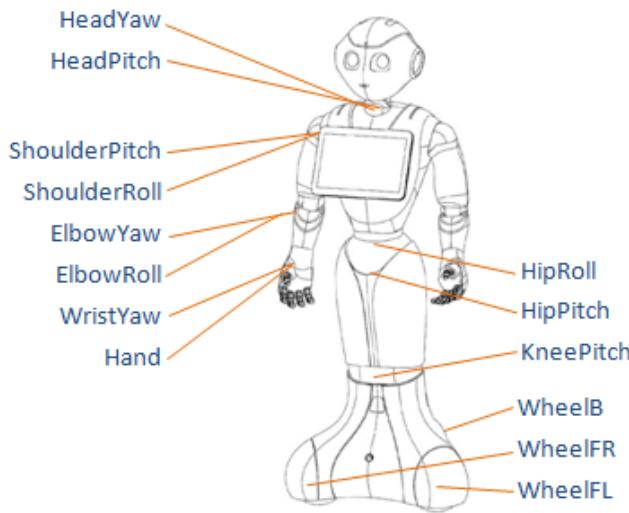


FIGURE 2.1 – Répartition des actionneurs de Pepper

2.1.2 Les senseurs

Pepper intègre également une multitude de capteurs. Certains d'entre eux sont utilisés pour s'assurer du bon comportement des parties mécaniques du robot, ou pour réaliser du contrôle-commande. D'autres senseurs sont en revanche intégrés sur le robot afin que l'utilisateur interagisse avec (tableau 2.1).

2.2 Expression du besoin

L'extension du marché visée par Aldebaran pour Pepper s'accompagne d'une montée en puissance de la production. Afin de la guider, des outils de vérification des produits en fin de ligne de production sont mis en place. Parmi eux, on retrouve le "Filtering Test" qui consiste à réaliser une série de tests durant six heures. Il vise à stresser l'ensemble des parties mécaniques du robot afin de faire ressortir d'éventuelles erreurs.

2.2.1 DExTER et MEIGUI

L'équipe de qualification hardware de Pepper a mis au point deux outils qui permettent de réaliser ces test et d'analyser les erreurs apparues.

MEIGUI : Le Filtering Test est réalisé grâce à MEIGUI. Celui-ci fait effectuer au robot un ensemble de mouvements qui permettent de stresser ses parties mécaniques. Si une anomalie survient lors du déroulement du test, les différentes données relatives à l'état des systèmes mécaniques et électroniques de Pepper sont enregistrées dans un fichier journal (e.g. température des fusibles, valeur des accéléromètres, etc.).

DExTER : Afin d'identifier les causes de l'apparition de problèmes sur le robot, un certain nombre d'hypothèses sont émises à partir de l'étude des données du fichier log. Pour cela, on s'appuie sur l'utilisation d'un autre outil, DExTER, qui permet de visualiser les données du fichier log et d'obtenir des informations sur ces dernières (date d'apparition de l'erreur, nombre d'erreurs apparues, etc.).

Senseur	position	description
Capteurs liés aux actionneurs	sur les moteurs	Chaque moteur du robot est lié à 3 senseurs, qui donnent des informations sur la valeur du courant délivré au moteur (A), la température du moteur ($^{\circ}\text{C}$) et la position du moteur.
Senseurs tactiles	1 sur chaque main, 1 sur la tête	Permet à l'utilisateur d'interagir avec le robot en le touchant.
Les boutons	1 bouton poussoir sur le buste, 3 bumpers sur la base	Les bumpers permettent au robot de détecter s'il rencontre un obstacle à proximité immédiate. Le bouton du buste permet quant à lui de modifier le mode dans lequel est le robot (autonome, veille).
Centrale inertielle	1 dans le buste, 1 dans la base	Informe sur la position et l'orientation du robot, ainsi que la vitesse et l'accélération.
Sonars	2 sonars à l'avant et l'arrière de la base	Permet de détecter la présence d'un objet situé au delà de 65 cm du robot.
Capteurs batterie	batterie	Renseigne sur le courant et la tension délivrés, le pourcentage de charge et la température.
Capteurs infrarouges	2 sur la base	Permet de détecter la présence d'un objet situé entre 0 et 50 cm du robot.
Lasers	6 lasers sur la base du robot	Permet de détecter la présence d'un objet

TABLE 2.1 – Les différents capteurs de l'architecture sensorielle de Pepper

2.2.2 Hiérarchisation des erreurs

Pour gérer au mieux les anomalies, celles-ci sont hiérarchisées en deux catégories : les *error name* et les *root causes*.

Error name Cela correspond à l'erreur visible, i.e. la conséquence liée à une anomalie hardware ou software. Par exemple, il peut s'agir de la chute du robot.

root cause Il s'agit de l'anomalie en elle-même, i.e. la cause ayant entraînée l'apparition d'une *error name*. Si l'*error name* est la chute d'un robot, la *root cause* peut par exemple être la détérioration d'un engrenage de la hanche.

En suivant la logique exprimée par ces définitions, une *error name* peut être constituée d'une ou plusieurs *root cause*.

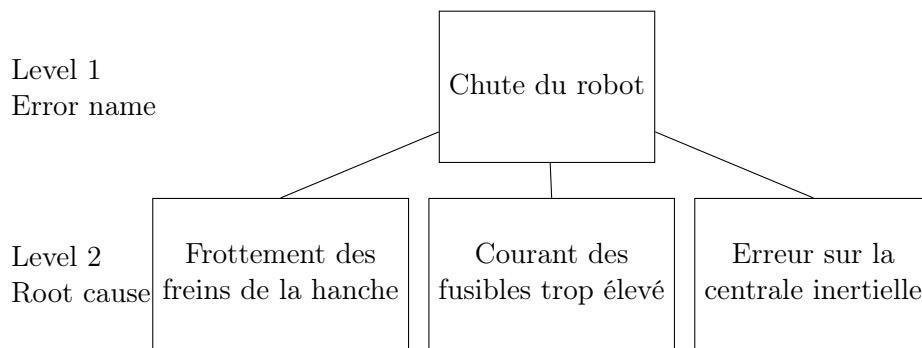


TABLE 2.2 – Exemple d'un error name et ses root cause

2.2.3 Exemple d'analyse d'une anomalie

On présente ici un exemple d'analyse d'un fichier log :

Observation

- Lors du déroulement du Filtering test, le robot tombe à $t = 16972$ secondes, soit lorsqu'il réalise une séquence de mouvements particulière appelée "Heat Behavior". Les valeurs retournées par l'accéléromètre selon l'axe Z attestent de cette chute. (cf. figure 2.2)
- On analyse les données liées aux systèmes mécaniques et électroniques du robot qui peuvent avoir une relation directe ou indirecte avec sa chute. Lorsque l'on étudie la vitesse de rotation du moteur de la hanche, on remarque qu'aux environs de $t = 16970$ secondes (c'est-à-dire 2 secondes avant la chute du robot), l'information fournie par le senseur ne suit plus la commande envoyée au moteur (figure 2.3). On remarque également que le senseur du genou suit correctement la commande du moteur (cf. figure 2.4).
- On observe aussi une augmentation anormale du courant dans le moteur de l'articulation.

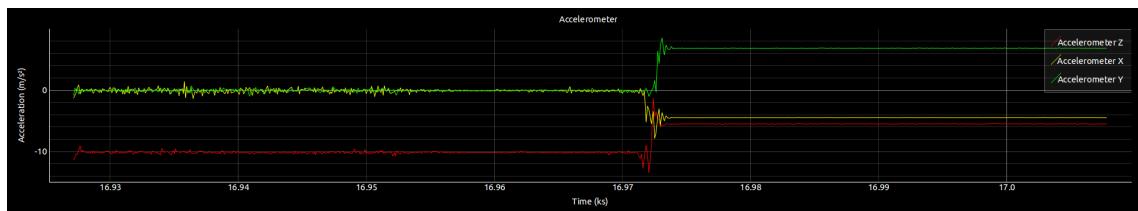


FIGURE 2.2 – Analyse d'une anomalie : accéléromètre

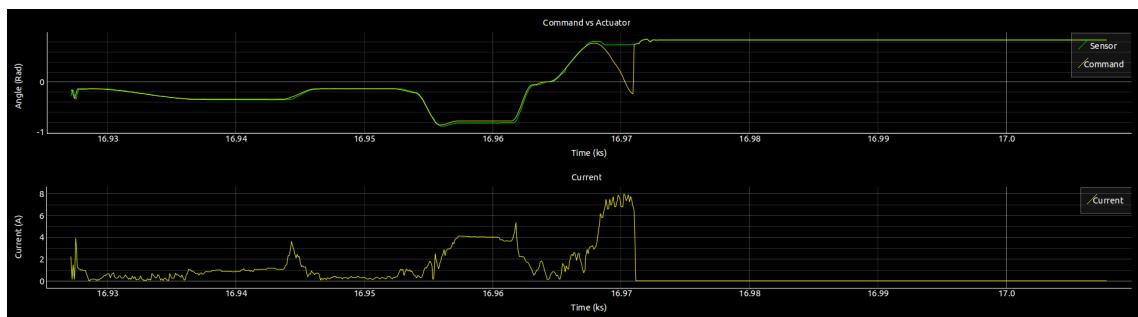


FIGURE 2.3 – Analyse d'une anomalie : les genoux

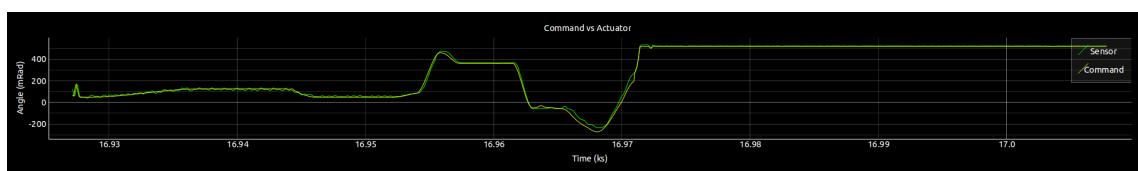


FIGURE 2.4 – Analyse d'une anomalie : la hanche

Hypothèse émise

Lors de l'exécution de l'animation "Heat Behavior", le robot est amené à réaliser des mouvements amples au niveau de sa hanche qui causent un certain stress sur cette partie

mécanique. Lorsque l'engrenage de la hanche arrive près de sa butée mécanique, celui-ci ne parvient pas à atteindre sa position zéro. Ce phénomène occasionne une augmentation du courant délivré dans le moteur de l'articulation, ce qui entraîne le passage en mode protégé du robot et a pour effet de désactiver sa rigidité. Sans cette rigidité, Pepper tombe (*error name*). Une étude plus poussée nous apprendra que la *root cause* du problème correspondait à un frottement des freins de la hanche.

2.3 Solution proposée

De part la quantité d'informations à analyser, cette tâche d'analyse peut rapidement devenir rébarbative, d'où le souhait d'automatiser ce processus d'investigation. La variabilité des types de données nous empêche de réduire le nombre d'informations à analyser à de simples caractéristiques communes (e.g. moyenne, écart type, etc.). On s'appuiera donc sur des approches algorithmiques plus poussées, en utilisant notamment des méthodes d'apprentissages automatiques (plus connues sous le terme anglais de Machine Learning). La multiplicité des modèles englobés dans cette discipline nous permettra de répondre au mieux à la problématique.

Chapitre 3

Le Machine Learning

3.1 Généralités sur le Machine Learning

Le Machine Learning (traduire par apprentissage automatique) est une ramifications de l'intelligence artificielle. Son champ d'étude est vaste et en perpétuelle évolution. Les solutions offertes par cette discipline permettent d'étudier toute sorte de données et d'automatiser une multitude de systèmes. L'apprentissage automatique rencontre un succès croissant, corrélé avec l'essor des nouvelles technologies et l'automatisation de l'analyse de volumes conséquents de données (Big Data). Les applications sont multiples, en voici quelques exemples :

- Algorithmes des moteurs de recherches (Google Deep Dream[7], Google TensorFlow [8]),
- Analyse boursière,
- Analyse de rapports d'erreurs,
- Reconnaissance vocale, biométrie, reconnaissance d'écriture,
- Robotique (vision, mouvements, prise de décision, etc.),
- Neurosciences.

3.1.1 Définition et principes généraux du Machine Learning

Le champ d'étude et d'application du Machine Learning étant immense, on propose de redéfinir cette notion en l'adaptant à la résolution de notre problématique (i.e. automatiser l'analyse d'incidents révélés lors du filtering test). On offre ici deux définitions de l'apprentissage automatique : une première dite "High Level" qui le caractérise de manière générale et une seconde qui reflète sa dimension algorithmique.

High Level : Le Machine Learning permet à un système d'évoluer grâce à un processus d'apprentissage et ainsi de remplir des tâches qu'il est difficile, voire impossible, de remplir par d'autres moyens algorithmiques plus classiques.

Mathématique Le Machine Learning fournit les outils pour prédire une/des donnée(s) de sortie Y à partir des données d'entrée X, via un processus d'apprentissage.

Au regard des deux définitions stipulées ci-dessus, on peut représenter le principe de base de l'apprentissage automatique sous la forme d'un schéma bloc (cf. figure 3.1).

Il peut être vu dans sa globalité comme un processus composé de deux étapes successives :

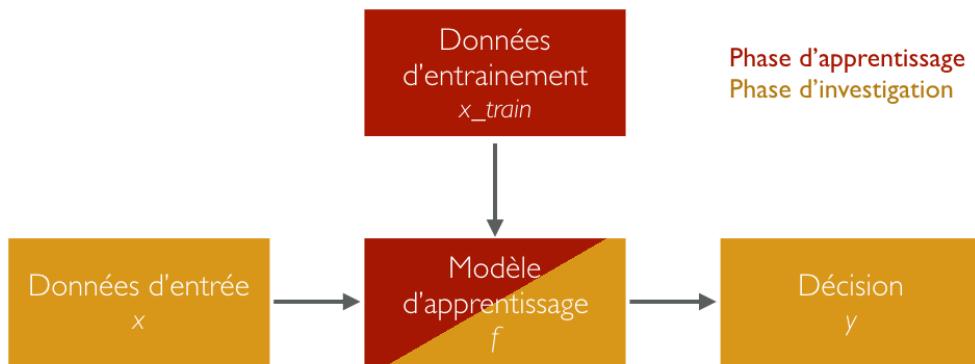


FIGURE 3.1 – Schéma fonctionnel haut niveau du Machine Learning

Apprentissage

- (a) Un ensemble de données est mis en entrée du système lors de la phase d'apprentissage (x_{train}).

- (b) A partir de ces informations, le système (f) apprend - s'entraîne- pour être en capacité de prendre une décision vis-à-vis de la tâche qui lui est demandée.

Prise de décision

- (a) On a en entrée du système une ou des donnée(s) brutes (x).

- (b) Cette donnée est traitée et analysée par le système.

- (c) En sortie, une décision (y) est prise quant à la tâche demandée grâce à l'apprentissage effectué en amont.

Un exemple concret

Afin d'exposer de manière plus concrète le processus fonctionnel haut niveau d'un algorithme d'apprentissage, on soumet l'exemple suivant :

On cherche à déterminer la période de l'année à laquelle on se trouve actuellement (i.e. printemps, été, automne ou hiver) grâce à l'analyse de l'humidité, de la température et de la pression atmosphérique d'aujourd'hui.

La première étape consiste à entraîner notre système afin que celui-ci soit en mesure de prendre une décision vis-à-vis des données qu'on lui présentera en entrée (i.e. l'humidité, la température et la pression atmosphérique d'aujourd'hui). Pour cela, on lui présente différents échantillons de températures, d'humidité et de pression prélevés à différentes périodes de l'année.

Une fois le système entraîné, on attend de celui-ci ce type de comportement : on présente en entrée du système une température de -2°C, une pression atmosphérique de 1030hPa et un taux d'humidité de 81%. La décision (sortie) espérée est : hiver.

On peut adapter le schéma fonctionnel haut niveau du Machine Learning à notre exemple (cf. figure 3.2).

Lexique

Pour caractériser et désigner plus précisément les différents éléments de notre système, on présente ci-dessous le champ lexical rattaché au Machine Learning :

Features Le type de données présenté en entrée.

La température, la pression atmosphérique et l'humidité.

Echantillons ou exemples Les données qui permettent d'entrainer le système (x_{train}).

Des échantillons de température, pression atmosphérique et humidité pris à différentes périodes de l'année.

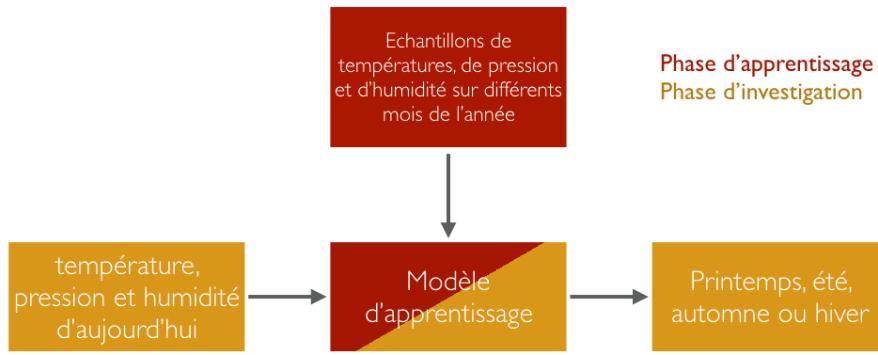


FIGURE 3.2 – Schéma fonctionnel haut niveau du Machine Learning, l'exemple de la prévision saisonnière

Modèle d'apprentissage Le cœur du système décisionnel (f).

Décision La sortie ou réponse du système (y)

Printemps, été, automne ou hiver.

3.1.2 Les exemples

Les exemples sont les données utilisées pour entraîner l'algorithme d'apprentissage. On parle également d'échantillons. Ils sont regroupés en "features" (terme anglais, traduire par caractéristiques). Pour reprendre l'exemple cité précédemment (partie 3.1.1), les données sont regroupées en 3 features : la température, l'humidité et la pression atmosphérique. Les échantillons sont donc structurés de la manière suivante :

$$\begin{matrix} & \text{temperature}(\text{°C}) & \text{humidité}(\%) & \text{pression}(\text{HPa}) \\ Exemple_1 & -10 & 85 & 1023 \\ Exemple_2 & 15 & 80 & 1020 \\ Exemple_3 & 23 & 65 & 1015 \\ \dots & \dots & \dots & \dots \\ Exemple_n & 10 & 81 & 1032 \end{matrix} \quad (3.1)$$

Différents types d'exemples

Il existe deux types d'exemples : les échantillons labellisés et non labellisés.

Dans l'exemple de la prévision saisonnière (partie 3.1.1), on a les jeux de données suivants :

Données labellisées Les échantillons labellisés correspondent à des exemples corrélés à une sortie - un label - connue.

$$\begin{matrix} & \text{temperature}(\text{°C}) & \text{humidité}(\%) & \text{pression}(\text{HPa}) \\ Exemple_1 & -10 & 85 & 1023 & hiver \\ Exemple_2 & 15 & 80 & 1020 & automne \\ Exemple_3 & 23 & 65 & 1015 & ete \\ \dots & \dots & \dots & \dots & printemps \\ Exemple_n & 10 & 81 & 1032 & \end{matrix} \quad (3.2)$$

On connaît la sortie qui correspond aux données d'entrée, i.e. qu'on sait à quelle période de l'année les échantillons ont été prélevés.

Données non labellisées Les échantillons non labellisés ne sont quant à eux pas corrélés à une sortie.

$$\begin{array}{l} \text{temperature}({}^{\circ}\text{C}) \quad \text{humidité}(\%) \quad \text{pression}(H\text{Pa}) \\ \text{Exemple}_1 \quad -10 \quad 85 \quad 1023 \quad ?? \\ \text{Exemple}_2 \quad 15 \quad 80 \quad 1020 \quad ?? \\ \text{Exemple}_3 \quad 23 \quad 65 \quad 1015 \quad ?? \\ \dots \quad \dots \quad \dots \quad \dots \quad \dots \\ \text{Exemple}_n \quad 10 \quad 81 \quad 1032 \quad ?? \end{array} \quad (3.3)$$

On ne connaît pas la sortie qui correspond aux données d'entrée, i.e. on *ne sait pas* à quelle période de l'année les échantillons ont été prélevés.

3.1.3 La décision

La décision correspond à la sortie du système, i.e. le choix réalisé par l'algorithme d'apprentissage automatique vis-à-vis de la tâche qui lui a été confiée.

Différents types de sorties

Il existe différents types de sortie : continues et discrètes.

Sorties continues peuvent prendre n'importe quelle valeur.

$$y \in R$$

Déterminer automatiquement l'évolution de la température en fonction des échantillons enregistrés durant les mois précédents correspond à une sortie continue d'un système d'apprentissage.

Sorties discrètes ne peuvent prendre que des valeurs prédéterminées.

$$y \in \{1, 2, 3, \dots, C\}$$

L'exemple de la prévision saisonnière partie 3.1.1 a une sortie discrète. En effet, la sortie ne peut prendre que des valeurs prédéterminées : printemps, été, automne et hiver.

3.1.4 Le modèle

Il existe différents variétés d'apprentissage supervisé. Le choix d'un modèle en particulier est influencé par le type d'exemples que l'on a en entrée du système et du type de décision que l'on souhaite obtenir en sortie.

Apprentissage supervisé et non supervisé

L'apprentissage supervisé nécessite d'avoir des données labellisées en entrée, i.e. on connaît le type de décision que l'on aura en sortie du système, en fonction des exemples en entrée : il y a une corrélation entre la sortie et l'entrée. C'est cette notion qui s'exprime au travers du terme *supervisé*. L'apprentissage non supervisé s'appuie quant à lui sur l'utilisation d'exemples non labellisés pour son apprentissage, i.e qu'on ne connaît pas le type de décision associé aux exemples en entrée. Dans ce cas, pour parvenir à prendre une décision, l'algorithme devra diviser les groupes de données hétérogènes en sous-groupes

homogènes d'informations, aux caractéristiques similaires. On appelle ces subdivisions des *clusters*. Afin de matérialiser les différences entre les deux méthodes et les applications possibles pour chacune d'elles, on propose deux exemples tableau 3.1.

	apprentissage supervisé	apprentissage non supervisé
exemple n°1 : apprendre aux humains	<p>Une institutrice enseigne à ses élèves à différencier un chat d'un chien : c'est la <i>décision</i> qu'on attend d'eux. Pour cela, l'éducatrice leur montre différentes photographies de chiens et de chats : ce sont les <i>exemples</i> utilisés pour l'<i>apprentissage</i>. Ces exemples peuvent être segmentés en différentes caractéristiques, comme la taille de l'animal, sa couleur, la longueur du poil, etc : il s'agit des <i>features</i>. Lorsque l'institutrice leur présente les différentes images, elle stipule clairement s'il s'agit d'un chien ou d'un chat : il y a donc une corrélation entre l'entrée et la sortie de l'apprentissage : les exemples sont <i>labellisées</i> (cf. figure 3.3,a).</p>	<p>Une institutrice donne à ses élèves le même exercice que dans le cadre de l'apprentissage supervisé, à la différence que lorsqu'elle présente les différentes images, elle <i>ne stipule pas</i> la race de l'animal : il n'y a donc aucune corrélation entre l'entrée et la sortie de l'apprentissage. Pour réussir cet exercice, les enfants devront donc regrouper les animaux en s'appuyant sur des similitudes physiques, i.e. leurs features (e.g. taille de l'animal, sa couleur, longueur du poil, etc.). Les élèves ne connaîtront certes pas le nom des deux animaux, mais ils auront su les différencier (figure 3.3, b).</p>
exemple n°2 : prévisions saisonnières 3.1.1	<p>On reprend l'exemple dans lequel on souhaite déterminer la période de l'année à laquelle on se trouve actuellement, en fonction des features humidité, température et pression atmosphérique. On prélève des échantillons à différentes périodes de l'année en notant à quelle saison ces données ont été prélevées : ce sont des <i>exemples labellisés</i>, i.e. il y a une corrélation entre les données et la sortie du système. Il s'agit donc d'un apprentissage supervisé (figure 3.4, a).</p>	<p>Cette fois-ci on ne note pas la saison à laquelle les échantillons ont été prélevés. Pour résoudre le problème, l'algorithme doit donc associer les données les plus similaires entre elles et créer des groupes homogènes d'informations qui correspondront aux 4 décisions possibles (figure 3.4, b) : ces sont des <i>clusters</i></p>

TABLE 3.1 – Comparaison de l'apprentissage supervisé et non supervisé par des exemples

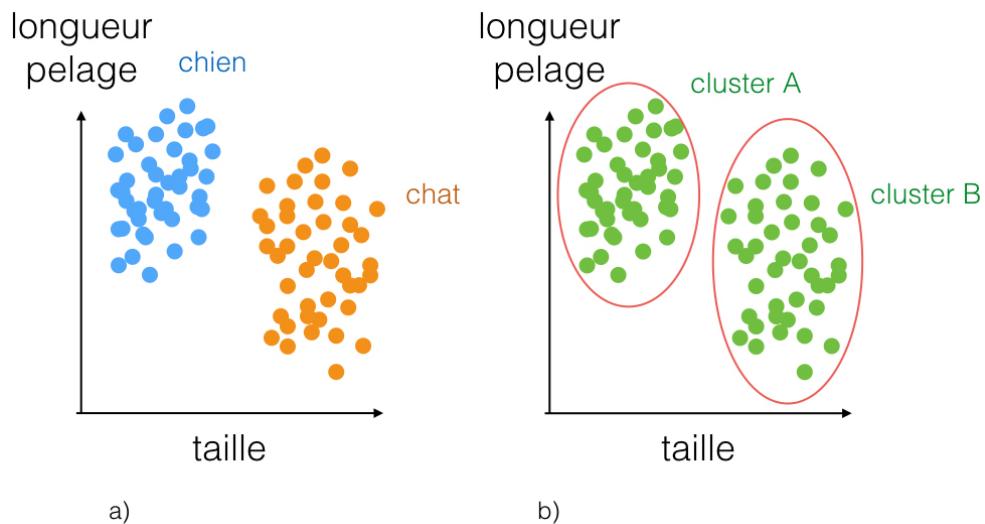


FIGURE 3.3 – Comparaison d'un apprentissage supervisé et non supervisé dans le cadre de l'exemple "apprendre aux humains". On observe sur la figure a) les différents exemples d'entraînement exprimés dans un repère composé des deux features "taille" et "longueur de pelage". On remarque qu'il y a la formation de deux groupes de données homogènes : les animaux de taille globalement élevée avec un pelage court et les animaux de taille moindre avec un poil globalement plus long. Les données étant labellisées, on sait que le premier groupe correspond à des chiens et le deuxième à des chats. Dans le cas de la figure b), les exemples n'étant pas labellisés, l'algorithme ne peut pas regrouper les données en fonction de leurs valeurs de sortie. Il réunit donc les ensembles homogènes de données en clusters.

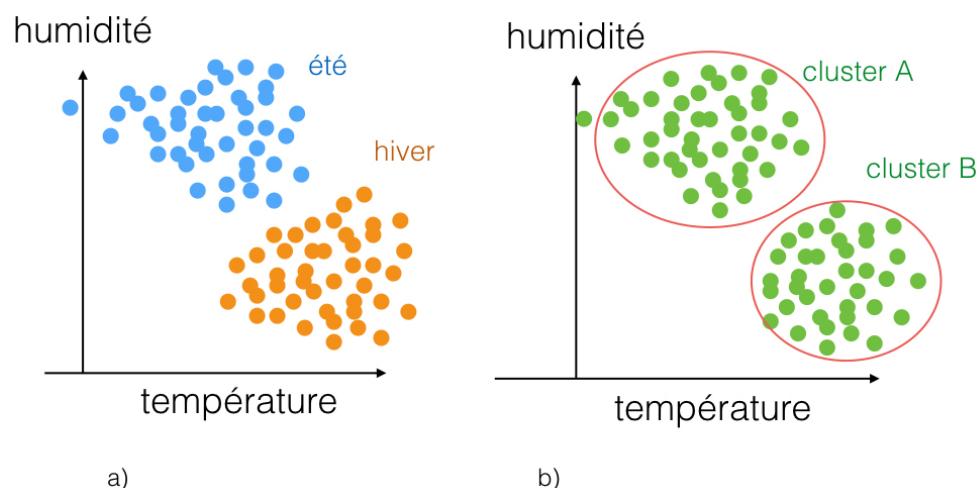


FIGURE 3.4 – Comparaison d'un apprentissage supervisé et non supervisé dans le cadre de l'exemple "prévisions saisonnières". On observe sur la figure a) les différents exemples d'entraînement exprimés dans un repère composé des deux dimensions (features) "humidité" et "température". On remarque qu'il y a la formation de deux groupes de données homogènes : un où les échantillons sont prélevés lors de saisons globalement chaudes et sèches, l'autre où les échantillons sont enregistrés lors de périodes globalement froides et humides. Les données étant labellisées, on sait que le premier groupe correspond à l'été et l'autre groupe à l'hiver. Dans le cas de la figure b), les exemples n'étant pas labellisés, l'algorithme ne peut pas regrouper les données en fonction de leurs valeurs de sortie. Il réunit donc les ensembles homogènes de données en clusters.

Apprentissage supervisé : régression et classification

La régression est un type d'apprentissage avec lequel on souhaite obtenir une sortie continue. Dit de manière différente, la régression implique le fait que l'on souhaite *estimer* ou *prédirer* une réponse. La classification est quant à elle un type d'apprentissage avec lequel on souhaite obtenir une sortie discrète. Elle peut être vue comme un cas particulier de la régression, où les valeurs à prédire sont discrètes. Formulé autrement, la classification implique le fait que l'on souhaite *classer* un exemple parmi différentes catégories. Afin de mettre en avant les nuances qui existent entre les deux méthodes et les applications possibles pour chacune d'elle, on propose l'exemple tableau 3.2).

régression	classification
On souhaite connaître le temps (température et humidité) qu'il fera pendant les jours suivants. Pour cela, on s'appuie sur les différents échantillons de température et d'humidité enregistrés lors des mois et des années précédentes (exemples labellisés). Le fait de déterminer la température des jours suivants relève de la <i>prédiction</i> (figure 3.5, b).	L'exemple de la prévision saisonnière 3.1.1 est un problème de <i>classification</i> : on cherche à classer notre donnée d'entrée parmi plusieurs groupes de données homogènes : printemps, été automne ou hiver (figure 3.5, a).

TABLE 3.2 – Comparaison entre l'apprentissage supervisé de type régression et supervisé de type classification

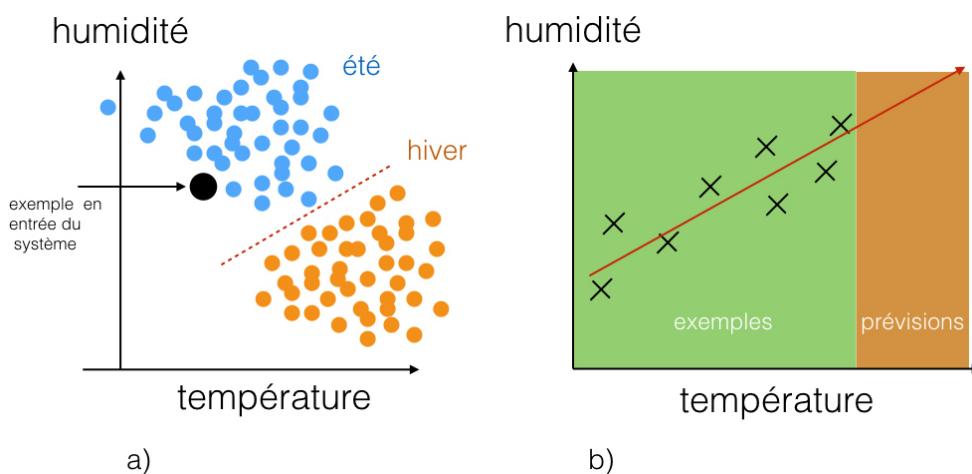


FIGURE 3.5 – Comparaison par l'exemple de la régression et la classification. Sur la figure a), on observe deux jeux de données homogènes (été et hiver) qui s'expriment dans un repère en deux dimensions (features humidité et température). Le but est ici de classer l'exemple en entrée du système parmi ces deux classes. Il s'agit donc d'un problème de classification. Dans la figure b), on observe une succession d'exemples exprimés dans un repère en deux dimensions (features température et humidité). On remarque une évolution globalement linéaire de ces exemples, nous permettant ainsi de prédire la température et l'humidité sur les prochains mois : il s'agit d'un problème de régression.

3.2 Les différents algorithmes d'apprentissage supervisé

Il existe différents algorithmes d'apprentissage supervisé utilisés pour résoudre des problèmes de régression et de classification.

3.2.1 La régression linéaire uni-variable

La régression linéaire cherche à expliquer une variable de sortie y par une fonction affine de x . Cette fonction linéaire affine est appelée *hypothèse* (notée $h(x)$). Dit de manière différente : on a un jeu de données x auquel correspond un jeu de données y , on cherche à déterminer les valeurs θ_1 et θ_2 qui permettent de "mapper" les données, tel que :

$$h_{\theta}(x) = \theta_0 + \theta_1 x \quad (3.4)$$

Exemple de régression linéaire uni-variable

On souhaite déterminer le prix d'un logement en fonction de sa surface au sol en se basant sur les exemples de prix du parc immobilier. La surface au sol est donc l'entrée x de notre système et le prix la sortie y . A partir des exemples du tableau 3.3, on obtient la représentation graphique en figure 3.6. Grâce à l'expression de l'hypothèse, on est capable de déterminer le prix d'un loyer en fonction de la surface au sol.

taille (m^2)	prix (k€)
210	460
141	232
153	314
85	178
50	100
101	212
12	75
177	432
60	150
211	510
131	270
163	334

TABLE 3.3 – Exemples de prix des logements en fonction de leur taille

Cet exemple est dit uni-variable car un seul jeu de données x (superficie) correspond à un jeu de données y (prix).

La fonction coût

La fonction coût (en anglais cost function) compare la moyenne des différences entre les résultats de l'hypothèse $h(x)$ et les sorties actuelles y . Cela signifie qu'elle cherche à minimiser les valeurs calculées via l'hypothèse et les valeurs réelles (cf. figure 3.7). Soit :

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2 \quad (3.5)$$

avec :

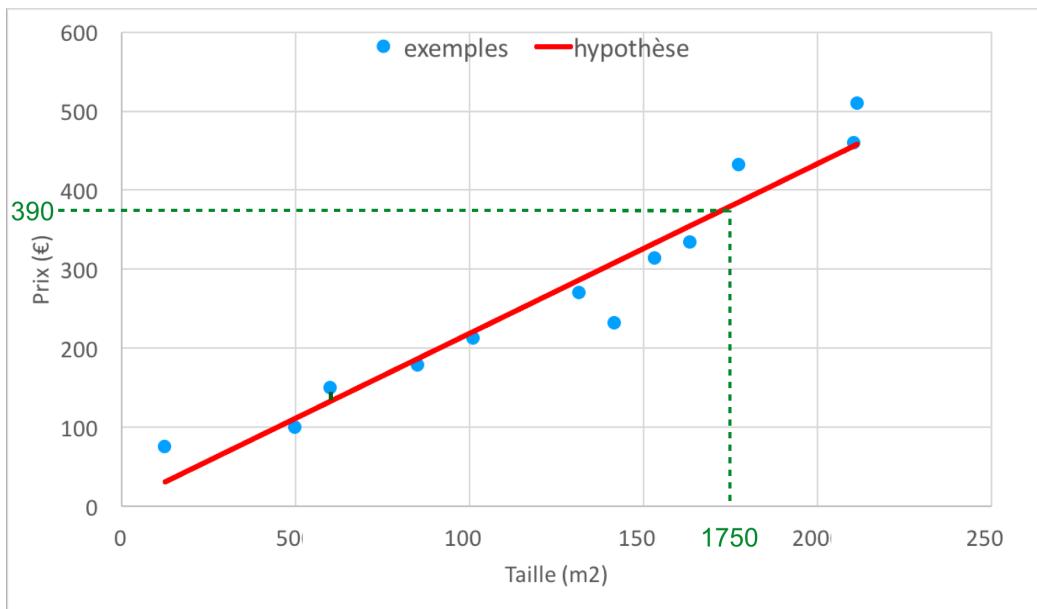


FIGURE 3.6 – Évolution du prix de l’immobilier en fonction de la surface. L’ensemble des données semblent globalement évoluer de manière linéaire. Cette linéarité est représentée par l’hypothèse $h(x)$. Grâce à celle-ci, on peut déterminer le prix d’un logement en fonction de sa superficie, et inversement. Par exemple, un appartement d’une surface de 175 m^2 coutera aux alentours de 390k€.

- $J(\theta_0, \theta_1)$ la fonction coût
- θ_0 et θ_1 les paramètres de l’hypothèse $h(x)$
- m le nombre d’exemples disponibles pour l’entraînement
- $h_\theta(x)$ l’hypothèse $h_\theta(x) = \theta_0 + \theta_1 x$
- x^i exemple i
- y^i sortie i

Algorithme du gradient

On cherche à minimiser la valeur de la fonction coût $J(\theta_0, \theta_1)$ en jouant sur les paramètres θ_0 et θ_1 de l’hypothèse. Pour cela, on calcule la fonction coût pour différentes valeurs de θ_0 et θ_1 et on cherche la valeur minimale de $J(\theta_0, \theta_1)$. Dans l’idée, cela revient à choisir une valeur de θ et de "faire un pas" vers la direction la plus basse, il s’agit d’un calcul itératif. La forme de la courbe J en fonction de θ_0 et θ_1 étant convexe (cf. figure 3.8), cela revient à trouver le minimum global de la courbe en appliquant l’algorithme du gradient (en anglais, gradient descent) :

$$\begin{aligned}
 & \text{repeat : } \{ \\
 & \quad \theta_0 = \theta_0 - \alpha \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0} \\
 & \quad \theta_1 = \theta_1 - \alpha \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1} \\
 & \}
 \end{aligned} \tag{3.6}$$

avec α la taille du "pas" que l’on fait vers la direction la plus basse. Si la valeur de α est trop petite, le nombre d’itération sera plus important, augmentant ainsi le temps de calcul. Si la valeur de α est trop grande, on risque de ne pas pouvoir atteindre le minimum et de diverger.

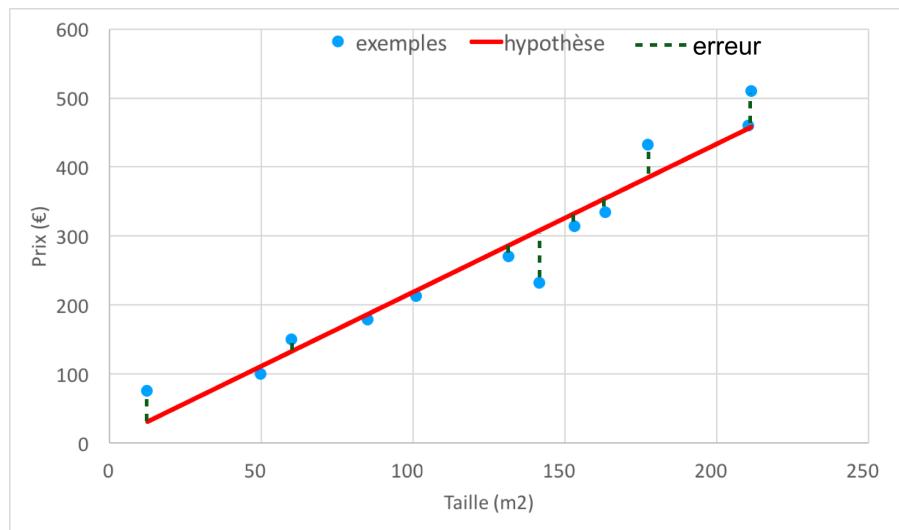


FIGURE 3.7 – Régression linéaire, optimisation de la fonction coût. Le calcul de la fonction coût revient à minimiser la distance entre un exemple et l'hypothèse, et ce pour chaque exemple.

3.2.2 La régression linéaire multi-variable

On peut réaliser de la régression linéaire avec plusieurs features en entrée.

Exemple de régression linéaire multi-variable

Afin de présenter ce qu'est la régression linéaire multi-variable, on ajuste l'exemple partie 3.2.1 pour qu'il corresponde à un problème multi-variable.

On souhaite cette fois-ci déterminer le prix d'un logement en fonction de sa surface au sol, du nombre de pièces et du nombre d'étages, en se basant sur les exemples de prix du parc immobilier. On a donc plusieurs entrées (surface, nombre de pièces, nombre d'étages). Soit le tableau 3.4, les exemples x utilisés pour l'entraînement.

surface	nombre de pièces	nombre d'étages	prix
210	10	1	460
141	4	0	232
153	5	2	314
85	6	1	178
50	3	1	100
101	8	1	212
12	3	0	75
177	12	0	432
60	5	0	150
211	10	2	510
131	5	1	270
163	7	0	334

TABLE 3.4 – Exemples du prix des logements en fonction de leur surface, du nombre d'étages et du nombre de pièces.

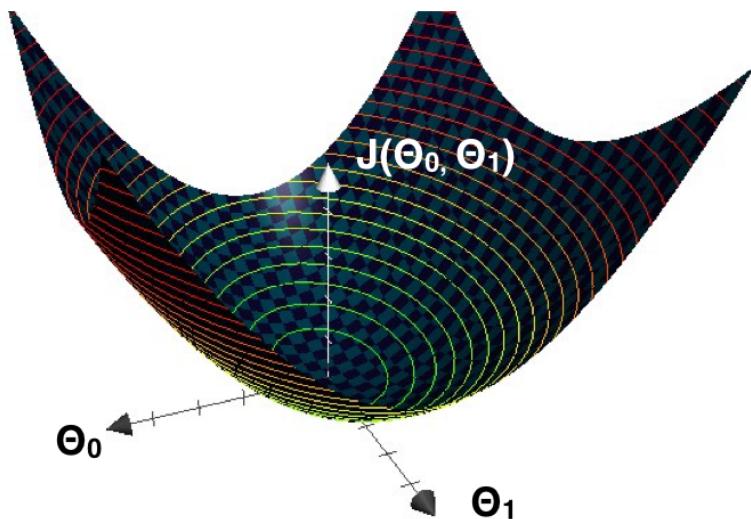


FIGURE 3.8 – Régression linéaire, calcul des paramètres de l'hypothèse. Ce graphique représente la variation des paramètres θ_0 et θ_1 de l'hypothèse en fonction de la valeur de la fonction coût. On cherche les valeurs θ_0 et θ_1 minimisant $J(\theta_0, \theta_1)$. La courbe ayant la forme d'une "cuvette", les valeurs optimales de θ_0 et θ_1 correspondent à celles au fond de la "cuvette".

La fonction hypothèse s'exprime alors sous cette forme :

$$h_{\theta}(x) = \theta_0 + \theta_1 X_1 + \theta_2 X_2 + \theta_3 X_3 \quad (3.7)$$

Où X_1 , X_2 et X_3 correspondent respectivement aux features surface, nombre d'étages et nombre de pièces.

Généralisation de la fonction coût

On peut la généraliser sous cette forme :

$$h_{\theta}(x) = \theta_0 + \theta_1 X_1 + \theta_2 X_2 + \theta_3 X_3 + \dots + \theta_n X_n \quad (3.8)$$

Généralisation de la fonction coût

On peut généraliser la fonction coût et l'utiliser pour l'appliquer à un problème de régression linéaire multi-variable, tel que :

$$J(\theta_1, \theta_2, \theta_3, \dots, \theta_n) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2 \quad (3.9)$$

Généralisation de l'algorithme du gradient

On peut généraliser l'algorithme du gradient utilisé lors de la régression linéaire univariable pour l'appliquer à un problème de régression linéaire multi-variable :

$$\text{Repeat } \{ \theta_j = \theta_j - \alpha \frac{\partial J(\theta_0, \theta_1, \theta_2, \theta_3, \dots, \theta_n)}{\partial \theta_j} \} \quad (3.10)$$

On met à jour simultanément l'ensemble des valeurs de θ lors de chaque itération.

$$\text{Repeat } \{ \theta_j = \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_\theta(x^i) - y^i) x_j^i \} \quad (3.11)$$

avec x_j^i l'entrée j de l'entraînement i .

Vectorisation des calculs

On peut exprimer les exemples en entrée du système sous forme vectorielle :

$$\begin{bmatrix} X_0 \\ X_1 \\ X_2 \\ \dots \\ X_n \end{bmatrix} = X \quad (3.12)$$

De même, on réécrit les paramètres θ de l'hypothèse sous forme vectorielle :

$$\begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \dots \\ \theta_n \end{bmatrix} = \theta \quad (3.13)$$

On peut alors réécrire l'hypothèse (équation (3.8)) :

$$h_\theta(x) = \theta^T X \quad (3.14)$$

L'algorithme du gradient (équation (3.11)) s'exprime donc sous sa nouvelle forme vectorielle :

$$\theta = \theta - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^i) - y^i) X^i \quad (3.15)$$

3.2.3 La régression logistique

La régression logistique permet de résoudre des problèmes de classification. Elle découle de la régression linéaire et s'appuie sur les mêmes concepts. On cherche à séparer des groupes de données homogènes dans un ensemble hétérogène.

Régression linéaire et classification

On reprend l'exemple de la prévision saisonnière en partie 3.1.1 et on utilise de la régression linéaire afin de classer automatiquement l'échantillon qu'on lui présente en entrée dans une des classes printemps ou hiver, en fonction de la température (cf. figure 3.9).

Pour cela, on met en place un seuil de classification :

- Si $h_\theta(x) > 0,5$ alors $y = 1$
- Si $h_\theta(x) < 0,5$ alors $y = 0$

Où $y = 0$ correspond à la période hiver et $y = 1$ l'été.

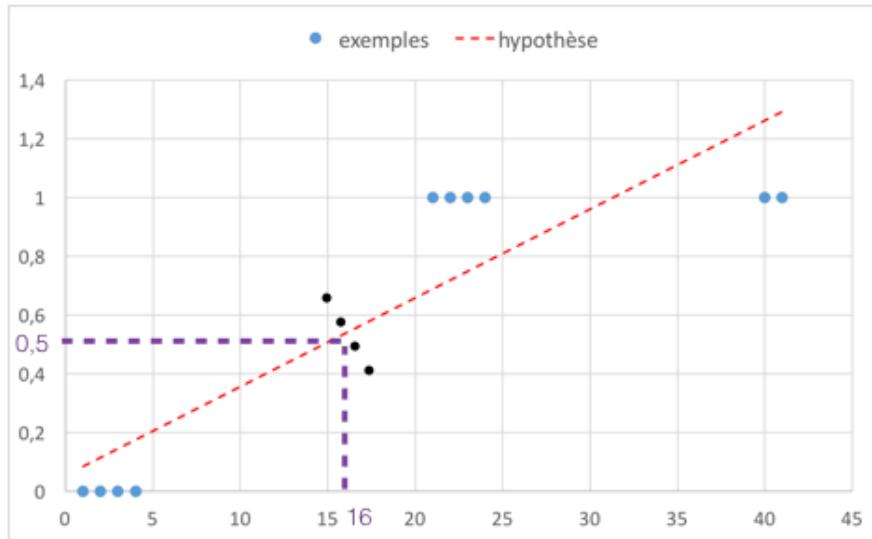
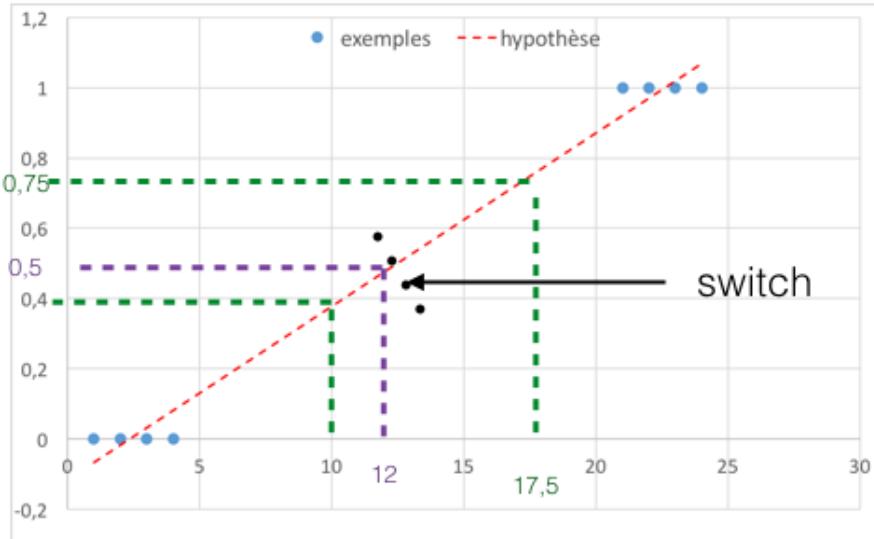


FIGURE 3.9 – Classification via régression linéaire. On observe sur la figure a) que lorsque la température est inférieure à 12,5°C, le système considère que la valeur de sortie est 0 (hiver). Lorsque la température est au dessus, la valeur de sortie devient 1 (été). Ce cas particulier fonctionne car les exemples sont répartis de manière uniforme. Or, dans le cas de la figure b), on remarque qu'une répartition non uniforme des données entraîne un dysfonctionnement du classement. En effet, le seuil de différentiation entre les deux classes se situe aux alentours de 15°C, ce qui n'est pas représentatif des exemples.

Cette méthode fonctionne dans le cas présent car les exemples sont régulièrement espacés entre eux. Dans le cas contraire, le seuil serait alors mal positionné et la classification

serait erronée. La régression linéaire n'est donc pas adaptée pour la résolution de problèmes de classification.

Régression logistique et fonction sigmoïde

Pour réaliser de la classification en utilisant de la régression, on peut modifier la forme linéaire de l'hypothèse en une sigmoïde (figure 3.10). On appelle également cette courbe fonction logistique ou fonction de répartition.

Avec $g(x) = \frac{1}{1+e^{-z}}$ la fonction sigmoïde, on a l'hypothèse $h_\theta(x)$ suivante :

$$h_\theta(x) = g(\theta^T x) \quad (3.16)$$

soit :

$$h_\theta(x) = \frac{1}{1 + e^{\theta^T x}} \quad (3.17)$$

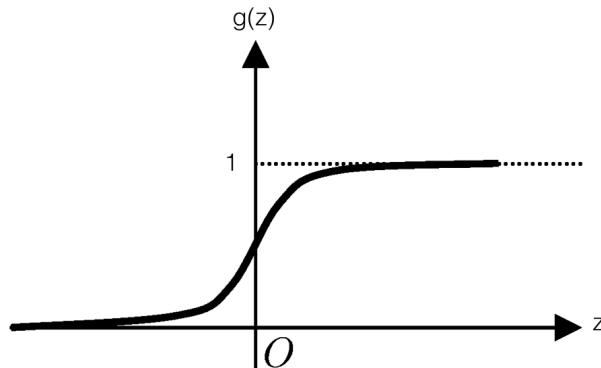


FIGURE 3.10 – Fonction sigmoïde, également appelée fonction logistique.

D'un point de vue probabiliste, cela signifie que l'hypothèse représente la probabilité estimée que la sortie y soit égale à 1. Par exemple, si $h_\theta(x) = 0,7$, veut dire que l'on a 70% de chance que la variable de sortie soit égale à 1.

Ligne de décision

On a la propriété de la fonction sigmoïde suivante :

$$g(z) \geq 0,5 \text{ lorsque } z \geq 0 \quad (3.18)$$

On a donc pour l'hypothèse la propriété suivante :

$$h(x) = g(\theta^T x) \geq 0,5 \text{ lorsque } \theta^T x \geq 0 \quad (3.19)$$

On peut alors émettre les deux affirmations suivantes :

$$\begin{aligned} y &= 1 \text{ si } h_\theta(x) \geq 0,5, \text{ soit } \theta^T x \geq 0 \\ y &= 0 \text{ si } h_\theta(x) \leq 0,5, \text{ soit } \theta^T x \leq 0 \end{aligned} \quad (3.20)$$

application : Soit $h_\theta(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$ avec $\theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$, on a la condition suivante :

$$y = 1 \text{ si } -3 + x_1 + x_2 \geq 0, \text{ soit } x_1 + x_2 \geq 3 \quad (3.21)$$

Cette expression correspond à la ligne (ou frontière) de décision de la régression linéaire (figure 3.11).

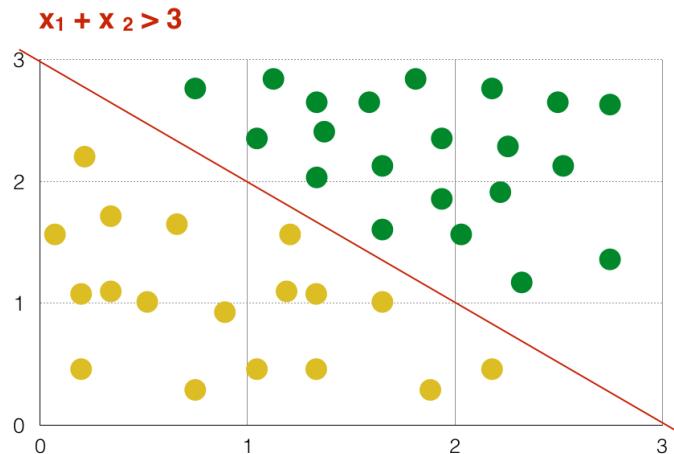


FIGURE 3.11 – Exemple d'une régression logistique. Les données en jaune sont séparées des données vertes par la frontière de décision (ligne rouge sur le graphe).

Ligne de décision non linéaire

Il est possible d'utiliser des hypothèses plus complexes qui permettent d'effectuer de la classification non linéaire.

On a par exemple $h_\theta(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$ avec $\theta = \begin{bmatrix} -1 \\ 0 \\ 0 \\ 1 \\ 1 \end{bmatrix}$.

Cela revient à dire :

$$\begin{aligned} y = 1 \text{ si } -1 + x_1^2 + x_2^2 \geq 0 \\ \text{soit } x_1^2 + x_2^2 \geq 1 \end{aligned} \quad (3.22)$$

Cette frontière de décision correspond à l'équation d'un cercle. Plus le nombre de polynômes de l'hypothèse est important, plus on peut créer des lignes de décisions complexes.

Fonction coût

Dans le cadre d'une régression linéaire, la forme de l'hypothèse est linéaire. Pour la régression logistique, elle ne l'est plus (forme sigmoïde). La fonction coût n'est donc ici pas convexe (cf. figure 3.8) et on ne peut pas déterminer le minimum global (et donc la valeur optimale des paramètres de l'hypothèse), celle-ci pouvant posséder plusieurs minimums locaux. Pour palier à ce problème, on s'appuie sur une reformulation de la fonction coût.

Soit la fonction coût utilisée pour la régression linéaire :

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} (h_\theta(x^i) - y^i)^2 \quad (3.23)$$

On pose $Cost(h_\theta, y) = \frac{1}{2}(h_\theta(x^i) - y^i)^2$ le coût. On obtient :

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m Cost(h_\theta, y) \quad (3.24)$$

On reformule le coût dans le cadre de la régression logistique :

$$cost(h_\theta(x), y) = \begin{cases} -\log(h_\theta(x)) & \text{si } y = 1 \\ -\log(1 - h_\theta(x)) & \text{si } y = 0 \end{cases} \quad (3.25)$$

On peut réécrire cette formule en un seul bloc :

$$cost(h_\theta(x), y) = -y \log(h_\theta(x)) - (1 - y) \log(1 - h_\theta(x)) \quad (3.26)$$

La fonction coût devient alors :

$$J(\theta) = \frac{1}{m} \left[\sum_{i=1}^m y^i \log(h_\theta(x^i)) + (1 - y^i) \log(1 - h_\theta(x^i)) \right] \quad (3.27)$$

Intuitivement :

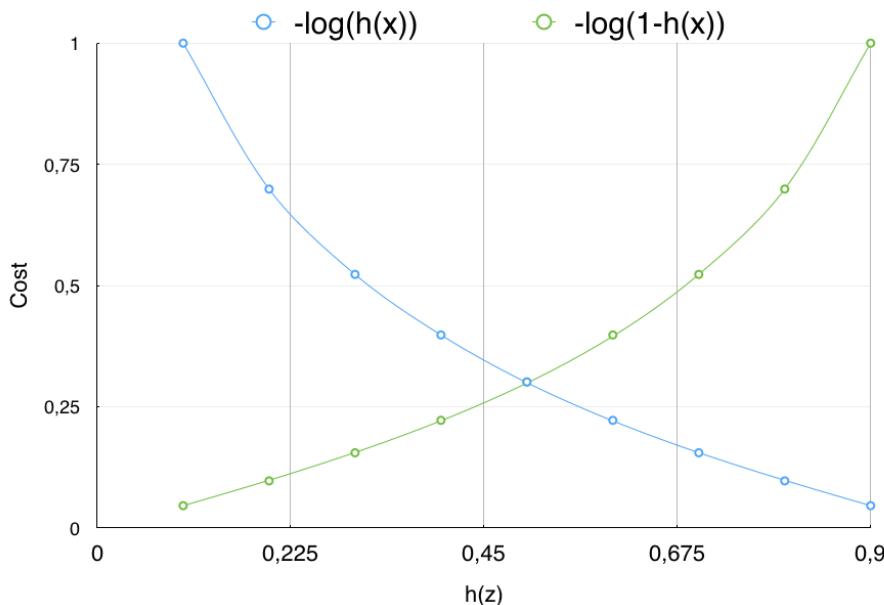
- lorsque l'on observe la forme de la fonction $-\log(h(\theta))$ (cf. figure 3.12), vraie pour $y = 1$, on remarque que lorsque $h(x)$ tend vers 1, le coût tend vers 0. Lorsque $h_\theta(x)$ tend vers 0, le coût tend vers l'infini. Autrement dit, plus la valeur de l'hypothèse s'approche de la valeur de sortie réelle ($y=1$), plus le coût est faible. Inversement, plus il s'en éloigne, plus il est élevé.
- lorsque l'on observe la forme de la fonction $-\log(1 - h(\theta))$ (cf. figure 3.12), vraie pour $y = 0$, on remarque que lorsque $h(x)$ tend vers 0, le coût s'approche de 0. Lorsque $h_\theta(x)$ tend vers 1, le coût tend vers l'infini. Autrement dit, plus la valeur de l'hypothèse s'approche de la valeur de sortie réelle ($y=0$), plus le coût est faible et inversement, plus il s'en éloigne, plus il est élevé.

C'est le comportement que l'on attend de la fonction coût, i.e. optimiser l'hypothèse de manière à ce que celle-ci s'approche de la valeur de sortie réelle.

Algorithme du gradient

La formule de l'algorithme du gradient reste identique à celle utilisée pour la régression linéaire, seule la valeur de $h_\theta(x)$ change, selon la démarche soumise en partie 3.2.3.

$$\begin{aligned} & \text{Repeat } \{ \\ & \quad \theta_j = \theta_j - \alpha \frac{1}{m} \sum_m^{i=1} (h_\theta(x^i) - y^i) x_j^i \\ & \} \end{aligned} \quad (3.28)$$

FIGURE 3.12 – fonctions $-\log_\theta(h(x))$ et $-\log_\theta(1 - h(x))$

Classification multiclasse

Les exemples de classification proposés jusqu'ici ne comportaient que deux classes. Or il est possible de résoudre des problèmes dont la décision doit être prise parmi plus de deux classes. Soit l'exemple de la prévision saisonnière (partie 3.1.1), on a en sortie une décision à prendre parmi les 4 classes : printemps, été, automne et hiver. Pour résoudre ce problème, on compare une classe par rapport à l'ensemble des autres classes (considéré alors comme un seul et même ensemble homogène). On répète ensuite le même procédé pour les autres classes. L'exemple analysé appartient à la classe ayant eu la probabilité la plus élevée en sortie. Cette méthode s'appelle "One-vs-All".

3.2.4 Support Vector Machine

Le Support Vector Machine (traduire en français par "machine à vecteurs de support") permet de résoudre des problèmes de classification. Conceptuellement, le SVM reprend les théories appliquées à la régression logistique auxquels on ajoute deux notions supplémentaires : la marge maximale et les fonctions noyaux.

Marge maximale

Afin d'expliquer ce qu'est la notion de marge maximale, on s'appuie sur un exemple dans lequel les données sont séparables par une ligne de décision linéaire. Dans le cas de la figure 3.13, on a un problème de classification composé de deux classes. Le but est donc de déterminer une valeur de l'hypothèse (représentée par la frontière de décision) permettant de séparer ces deux régions. On remarque qu'elle peut prendre une infinité de valeurs, i.e. il existe une infinité de combinaisons de valeurs des paramètres θ de l'hypothèse qui résolvent la classification. On cherche donc à déterminer l'hypothèse qui permet de répondre de manière optimale à ce problème. Pour cela, on introduit la notion de marge. Comme on peut l'observer sur la figure 3.14, la ligne de décision est bordée de deux marges qui prennent appui sur les valeurs situées à l'extrémité de chacune des deux classes. Afin de déterminer la meilleure position pour la ligne de décision (et donc le paramétrage optimal de l'hypothèse), on maximise la distance entre ces deux marges.

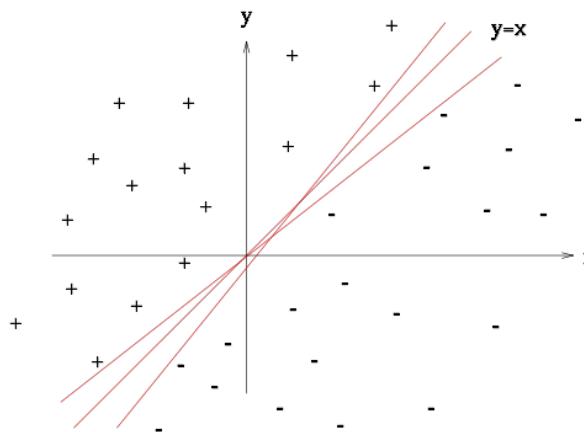


FIGURE 3.13 – SVM : cas simple d'une régression logistique avec une hypothèse linéaire. On observe sur la figure ci-contre qu'il existe une infinité de positions pour la frontière de décision qui délimite les deux classes. Cependant la performance de chacune d'elle peut être différente.

Les fonctions noyaux

Les fonctions noyaux (également appelées Kernel) permettent de résoudre des problèmes de classifications non linéaires grâce à des méthodes de classifications linéaires. Pour cela, on transforme l'espace de représentation des données d'entrée en un espace de plus grande dimension dans lequel il est possible de les délimiter par une frontière de décision linéaire (figure 3.15 et 3.16) .

Avantages du SVM

L'entraînement d'un algorithme de type SVM peut être effectué avec peu d'exemples. En effet, la marge maximale s'appuie sur les données en périphéries des ensembles homogènes.

3.2.5 Périmètres d'utilisation de la régression logistique et du SVM

La régression logistique et le SVM sont tous deux des algorithmes de classification. Le choix d'un modèle dépend du nombre d'exemples que l'on a pour l'entraînement et du nombre de features. On présente dans le tableau 3.5 les différents périmètres d'utilisation.

Périmètres d'utilisation	Modèle d'apprentissage à favoriser
le nombre de features est plus important que le nombre d'exemples (environ 1000 features pour 10 à 100 exemples)	Régression logistique ou SVM sans kernel
le nombre de features est faible (1 à 1000 features pour 10 à 10 000 exemples)	SVM avec un kernel
si le nombre de features est faible et le nombre d'exemples élevé (1 à 10 000 features pour 50 000 à 1 million d'exemples)	Régression logistique ou svm sans kernel avec création de features.

TABLE 3.5 – Périmètre d'utilisation de la régression logistique et le SVM

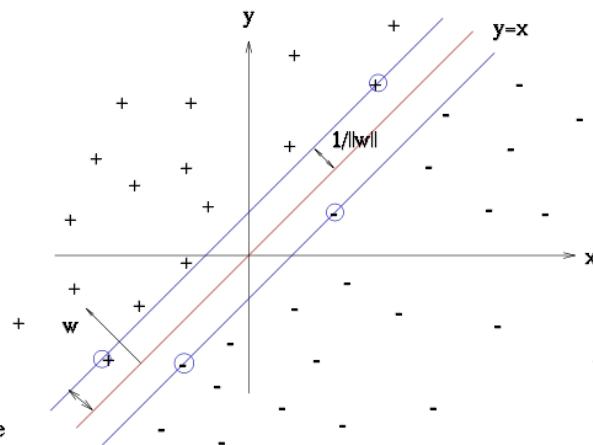


FIGURE 3.14 – SVM : optimisation du calcul de l'hypothèse par l'introduction de la notion de marges. Afin de déterminer la position optimale pour la frontière de décision, on introduit deux marges entre les échantillons à l'extrémité des classes et la ligne de décision. On cherche à maximiser la distance entre ces deux marges afin d'obtenir la frontière de décision qui optimise la classification.

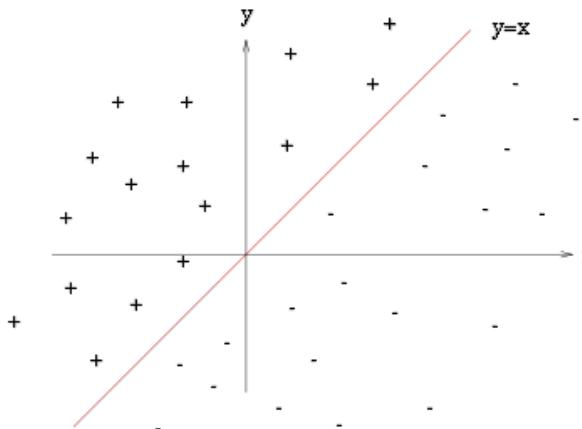


FIGURE 3.15 – Exemple d'un problème de classification linéaire. On observe qu'ici les deux classes (+ et -) sont séparables par une frontière de décision linéaire.

3.2.6 Autres algorithmes d'apprentissage supervisé

Les méthodes proposées jusqu'ici ne représentent qu'un échantillon du parc algorithmique qui compose l'apprentissage automatique supervisé. On peut notamment évoquer les réseaux neuronaux qui sont des algorithmes puissants et sont principalement utilisés pour le traitement et l'analyse d'images (mais requièrent un nombre d'exemples élevé). On peut également évoquer les arbres de décision (e.g. Markov).

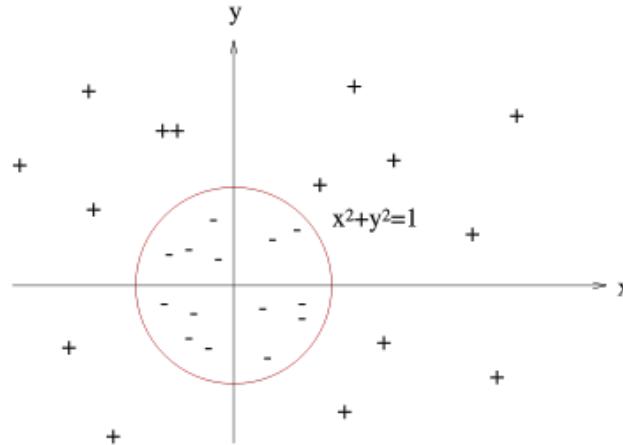


FIGURE 3.16 – Exemple d'un problème de classification non linéaire. On observe que les deux classes (+ et -) ne sont pas linéairement séparables. Pour résoudre ce problème, on utilise des kernels afin de modifier l'espace de représentation et trouver un espace où il est possible de résoudre le problème par une frontière linéaire.

Chapitre

4

Automatisation du processus d'investigation

Lorsqu'une *error name* est révélée durant le Filtering test, de nombreuses données sont enregistrées dans un fichier journal (que l'on retrouve plus souvent sous le terme anglais de fichier "log"). Une analyse poussée de ces informations permet de déterminer la *root cause* liée à l'*error name* (partie 2.2.2). Afin d'automatiser ce processus d'analyse, on s'appuie sur l'utilisation d'algorithmes d'apprentissage automatique.

4.1 Architecture High Level du système proposé

L'architecture haut niveau de la solution que l'on propose est composée de deux couches : une couche *root cause* et une couche *error name*.

Couche root cause La couche *root cause* permet de détecter la présence d'une *root cause* dans le fichier log que l'on analyse. Elle contient un algorithme d'apprentissage automatique entraîné à effectuer cette tâche.

Couche error name La couche *error name* est constituée d'un ensemble de couches *root cause* de telle manière que lorsqu'un fichier log est mis en entrée du système, l'ensemble des couches *root cause* sont activées. Ainsi, le système recherche la présence de chaque *root cause* connue dans l'exemple étudié. On dit que les *root causes* sont liées à l'*error name*. On obtient en sortie de la couche *error name* le nom de la *root cause* ayant la plus forte probabilité d'avoir été reconnue.

Exemple de mise en place d'une couche error name et de ses couches root cause

Afin d'exposer de manière concrète le fonctionnement de l'architecture haut niveau de la solution proposée, on soumet un exemple de mise en place d'une architecture de détection et son utilisation.

Mise en place du système de détection d'une root cause On souhaite dans un premier temps mettre en place l'architecture qui permet de détecter la cause (*root cause*) ayant entraîné la chute du robot lors du Filtering test (*error name*). Cette étape consiste à créer les couches *root cause*, i.e. entraîner différents algorithmes d'apprentissage automatique à reconnaître la *root cause* pour laquelle ils ont été créés (figure 4.1). Afin de les entraîner, on utilise les grandeurs liées à chaque *root cause*, contenues dans le fichier log.

Par exemple, dans le cas de la *root cause* "frottement des freins de la hanche", on utilisera les données "valeurs du senseur de la hanche" et "valeurs de l'actuateur de la hanche". Ces deux grandeurs correspondent aux features de notre système d'apprentissage (cf. partie 3.1.1). L'ensemble de ces couches *root cause* sont liées à une couche *error name*, ici la chute d'un robot.

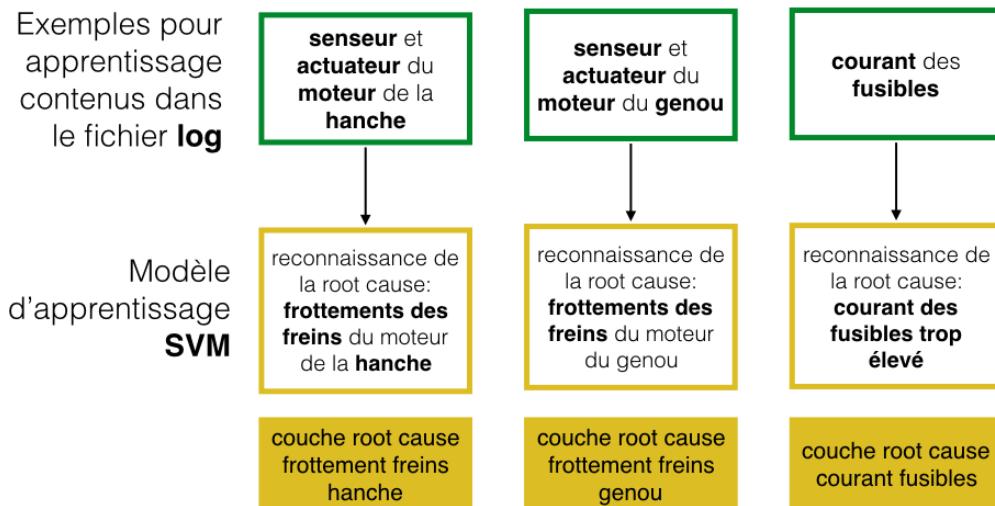


FIGURE 4.1 – Synoptique haut niveau de la création des couches *root cause*. Les couches *root cause* correspondent à des algorithmes d'apprentissage automatique que l'on entraîne à détecter la *root cause* à laquelle ils sont associés. Par exemple, créer la couche *root cause* "frottement du frein de la hanche" revient à entraîner un algorithme d'apprentissage de type SVM à partir des valeurs senseurs et actuateurs de la hanche des fichiers logs.

Utilisation du système de détection d'une root cause Une fois nos différentes couches *root cause* créées, on souhaite utiliser notre système pour détecter la cause ayant entraîné la chute d'un robot (cf. figure 4.2). Pour cela, on place à l'entrée de notre couche *error name* le fichier log que l'on souhaite analyser. Chaque couche *root cause* extrait de ce fichier les features qui lui sont liées (e.g. la *root cause* "frottement des freins de la hanche" est liée aux features senseurs et actuateurs de la hanche). L'algorithme SVM de chaque couche *root cause* va alors émettre une décision quant à la présence ou non de leur *root cause* dans le fichier log. Cette décision correspond à la probabilité que la *root cause* ait été détectée (en %). La couche *root cause* ayant la probabilité la plus élevée en sortie est considérée comme la *root cause* ayant entraîné l'*error name*. Il s'agit dans notre exemple de la chute du robot.

Chaque couche *root cause* peut être considérée comme un système d'apprentissage à part entière. Le schéma fonctionnel d'une *root cause* (cf. figure 4.3) reprend la même structure que celui du Machine Learning (cf. figure 3.1). En effet, chaque *root cause* est constituée d'une instance de l'algorithme SVM. Dans la suite de notre étude de l'architecture haut niveau, on s'intéressera plus particulièrement au fonctionnement de la couche *root cause*, celle-ci contenant l'ensemble du traitement et de l'analyse des données.

4.1.1 Les exemples

Les exemples sont les éléments qui permettent d'entraîner l'algorithme d'apprentissage automatique (cf. partie 3.1.2). Dans le cadre de la résolution de notre problématique, ils correspondent aux données générées et enregistrées dans le fichier log lorsqu'une erreur (*error name*) est détectée durant le Filtering Test.

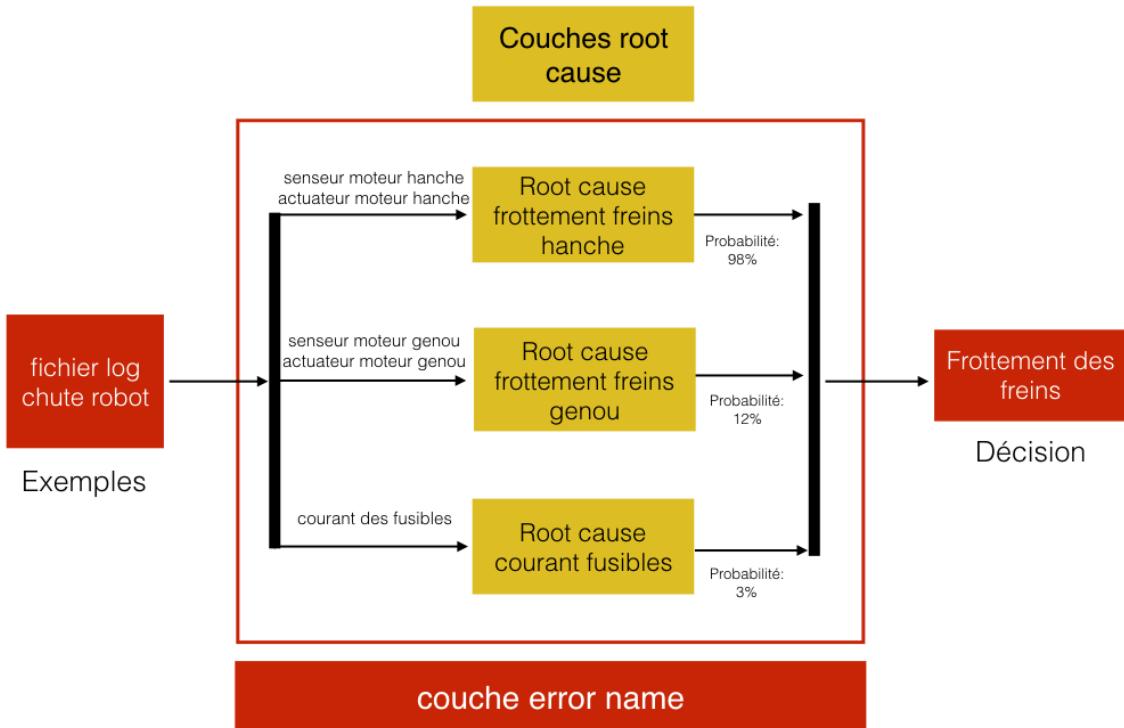


FIGURE 4.2 – Synoptique haut niveau de l'utilisation de la couche *error name*. La couche *error name* contient plusieurs couches *root cause* (on dit qu'elles sont liées). On met en entrée du système le fichier log que l'on souhaite analyser. Chaque couche *root cause* va alors chercher à détecter la présence de sa *root cause*. On obtient en sortie de la couche *error name* la *root cause* ayant eu la plus forte probabilité d'avoir été reconnue.

Structure du fichier log

Le fichier log renferme un ensemble de données enregistrées lors de la détection d'une erreur durant le Filtering Test. Elles correspondent aux "rythmes vitaux" du robot. Le fichier contient par exemple l'évolution temporelle des différents actuateurs et senseurs de Pepper, la température de différentes pièces mécaniques, etc. Dans le cadre de l'entraînement de l'algorithme du Machine Learning (SVM), chacune de ces constantes correspond à une feature (cf. partie 3.1.1). Soit le tableau 4.1, un extrait du contenu d'un fichier log :

<i>features</i>	X_1	X_2	X_3	X_4	X_5	X_6	
t_0	-0,404	0,64	-0,023	-0,04	-0,008	-0,007	
t_1	-0,404	0,64	-0,029	-0,038	-0,006	-0,006	
t_3	-0,404	0,576	-0,029	-0,033	-0,008	-0,012	
t_4	-0,402	0,544	-0,029	-0,027	-0,012	-0,022	
t_5	-0,401	0,448	-0,029	-0,027	-0,015	-0,029	
t_6	-0,401	0,448	-0,023	-0,029	-0,017	-0,031	(4.1)
t_7	-0,408	0,096	-0,021	-0,031	-0,015	-0,032	
t_8	-0,444	0,096	-0,021	-0,032	-0,015	0,035	
t_9	-0,486	0,096	-0,021	-0,033	-0,017	-0,039	
t_{10}	-0,523	0,128	-0,021	-0,033	-0,018	-0,043	
t_n	

Avec :

— X_1 = HeadPitchPositionActuatorValue

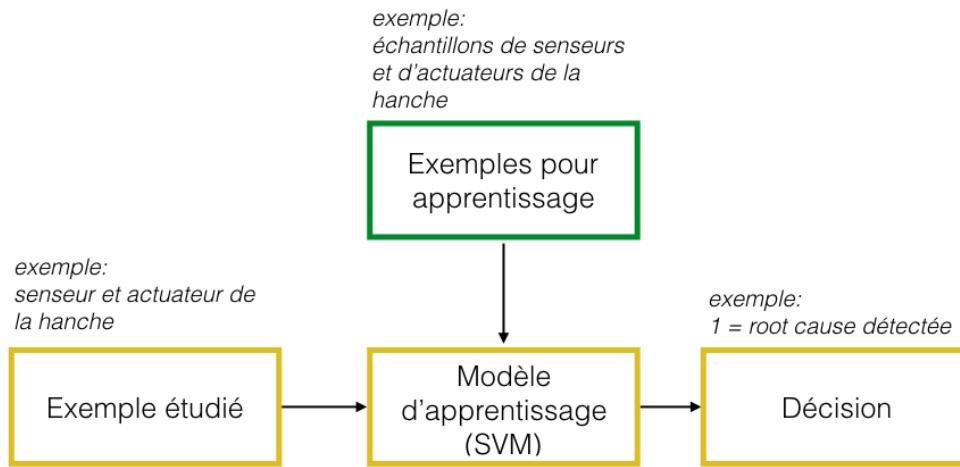


FIGURE 4.3 – Synoptique d'une couche *root cause*. Il correspond à celui du Machine Learning car chaque couche *root cause* est en réalité un algorithme d'apprentissage supervisé SVM que l'on entraîne à détecter une *root cause* particulière.

- $X_2 = \text{HeadPitchElectricCurrentSensorValue}$
- $X_3 = \text{HipPitchPositionSensorValue}$
- $X_4 = \text{HipPitchPositionActuatorValue}$
- $X_5 = \text{KneePitchPositionSensorValue}$
- $X_6 = \text{KneePitchPositionActuatorValue}$

Le fichier log, représenté dans le tableau 4.1, correspond à un exemple de la base de données qui sert à entraîner chacun de nos algorithmes.

A chaque colonne du tableau correspond une feature. Chacune des lignes est la valeur des features à un instant t (une ligne ne correspond pas à un exemple!).

Structure de la base de données d'exemples

La base de données est composée de plusieurs exemples qui correspondent à des fichiers logs. Par exemple, dans le cadre de la construction de couche *error name* de la chute d'un robot, la base de données sera constituée de fichiers logs générés par plusieurs cas de chutes de différents robots. On peut représenter la structure de la base de données par le tableau 4.2

<i>features</i>	X_1	X_2	X_3	X_4	X_5	X_6
<i>exemple0</i>	$\log_0[X_1]$	$\log_0[X_2]$	$\log_0[X_3]$	$\log_0[X_4]$	$\log_0[X_5]$	$\log_0[X_6]$
<i>exemple1</i>	$\log_1[X_1]$	$\log_1[X_2]$	$\log_1[X_3]$	$\log_1[X_4]$	$\log_1[X_5]$	$\log_1[X_6]$
<i>exemple2</i>	$\log_2[X_1]$	$\log_2[X_2]$	$\log_2[X_3]$	$\log_2[X_4]$	$\log_2[X_5]$	$\log_2[X_6]$
<i>exemple3</i>	$\log_3[X_1]$	$\log_3[X_2]$	$\log_3[X_3]$	$\log_3[X_4]$	$\log_3[X_5]$	$\log_3[X_6]$
<i>exemple4</i>	$\log_4[X_1]$	$\log_4[X_2]$	$\log_4[X_3]$	$\log_4[X_4]$	$\log_4[X_5]$	$\log_4[X_6]$
<i>exemple4</i>	$\log_n[X_1]$	$\log_n[X_2]$	$\log_n[X_3]$	$\log_n[X_4]$	$\log_n[X_5]$	$\log_n[X_6]$

(4.2)

Tout comme la structure d'un fichier log (4.1.1), chaque colonne correspond à une feature. Chaque ligne de ce tableau représente un exemple et correspond à un fichier log. Cela signifie que chaque ligne du tableau correspond au contenu d'un fichier log, présenté dans le tableau 4.1.

Construction d'une couche root cause à partir de la base de données d'exemples

Lorsque l'on veut construire une nouvelle couche *root cause*, i.e. entraîner un nouvel algorithme d'apprentissage à détecter la présence d'une *root cause* particulière dans un fichier log, on sélectionne uniquement les features de la base de données d'exemples liées à celle-ci. Par exemple, si on veut créer une nouvelle couche root cause "frottement des freins de la hanche" (lié à l'error name chute du robot), on n'utilisera que les features HipPitchPositionSensorValue et HipPitchPositionActuatorValue de notre base de données.

Représentation des exemples et des classes

Pour construire chaque couche *root cause*, on doit entraîner l'algorithme de l'apprentissage automatique SVM. Pour cela, on a besoin d'exemples labellisés positifs (dans notre cas, le terme positif signifie que l'exemple est le motif caractéristique de la *root cause*) et des exemples labellisés négatifs (des exemples qui ne correspondent pas au motif caractéristique de la *root cause*). Ces deux groupes de données forment alors des classes.

Dans le cadre de la *root cause* "frottement des freins de la hanche", on peut visualiser l'ensemble des exemples et des classes dans un repère construit à partir des features "position du senseur de la hanche" (clé HipPitchPositionSensorValue) et "position de l'actuateur de la hanche" (clé HipPitchPositionActuatorValue) en figure 4.4. Lors de la phase d'investigation, l'algorithme émet alors un choix entre ces deux classes : positive, i.e. présence de la *root cause* dans le fichier log, négative, i.e. absence de la *root cause* dans le fichier log.

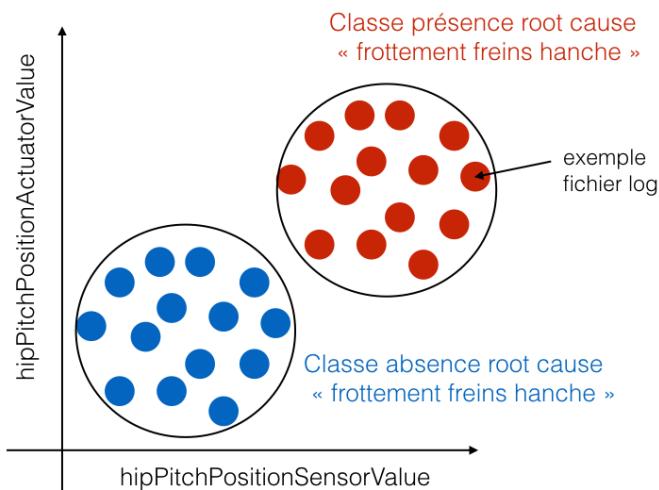


FIGURE 4.4 – Représentation de la répartition des exemples et des classes en fonction des features. On observe que lorsque l'on visualise les exemples contenus dans nos fichiers logs en fonction des deux features HipPitchPositionSensorValue et HipPitchPositionActuatorValue, ces derniers se regroupent en deux zones homogènes qui forment nos classes. Une classe correspond aux exemples de *root cause* "frottement des freins de la hanche", l'autre classe aux exemples qui ne correspondent pas à des exemples de "frottement des freins de la hanche".

Cette représentation n'est pas fonctionnelle mais conceptuelle, i.e. qu'il ne s'agit pas d'une visualisation résultant d'un système fonctionnel mais d'une idée haut niveau que l'on a de la sortie de notre système.

Parallèle avec l'exemple de la prévision saisonnière

Si on compare les échantillons utilisés dans l'exemple "prévision saisonnière" (cf. tableau 3.1) et ceux de notre solution (cf. tableau 4.2), on observe que dans les deux cas les données sont structurées en exemples et features. Cependant, dans la solution que l'on propose, les données de chaque exemple évoluent temporellement (e.g. la "HipPitchPositionSensorValue" de l'exemple 1 correspond à la colonne "HipPitchPositionSensorValue" du fichier *log₁*, qui a une évolution temporelle), alors que celles de la prévision saisonnière sont discrètes (e.g la température de l'exemple 1 est de -10°C, elle est discrète). Or, on ne peut pas réaliser de l'apprentissage supervisé avec des données temporelles. Sous leurs formes actuelles, nos exemples ne peuvent donc pas servir à entraîner les algorithmes SVM de nos couches *root cause*.

4.1.2 Le modèle d'apprentissage

Le modèle d'apprentissage utilisé est le Support Vector Machine (SVM) (cf. partie 3.2.4).

4.1.3 La décision

Chaque couche *root cause* délivre en sortie la probabilité que la *root cause* à laquelle elle est rattachée soit présente dans le fichier log analysé (via le SVM).

4.2 Détection d'une root cause

On souhaite réaliser de la reconnaissance de motifs grâce à l'utilisation du SVM, pour détecter la présence d'une *root cause* dans un fichier log. L'utilisation de cette méthode répond notamment au problème causé par l'évolution temporelle des exemples utilisés pour l'entraînement de l'algorithme (cf. partie 4.1.1). On présente dans cette partie les différentes solutions envisagées et les raisons ayant amené à utiliser la reconnaissance de motifs.

4.2.1 Différentes approches étudiées

L'évolution temporelle des exemples utilisés pour l'entraînement de l'algorithme implique de prétraiter les données (cf. partie 4.1.1). Pour cela, différentes approches sont envisagées.

Création de nouvelles features

On propose de créer de nouvelles features constantes. Elles sont des caractéristiques des features actuelles. Dans le cadre de cette étude, on les identifiera sous l'appellation de *caractéristiques simplifiées*. Elles correspondent par exemple au calcul de la moyenne d'une feature, la valeur crête-à-crête, la valeur maximum, etc. On se sert ensuite de ces *caractéristiques simplifiées* pour réaliser l'entraînement de l'algorithme d'apprentissage automatique (cf. exemple figure 4.5).

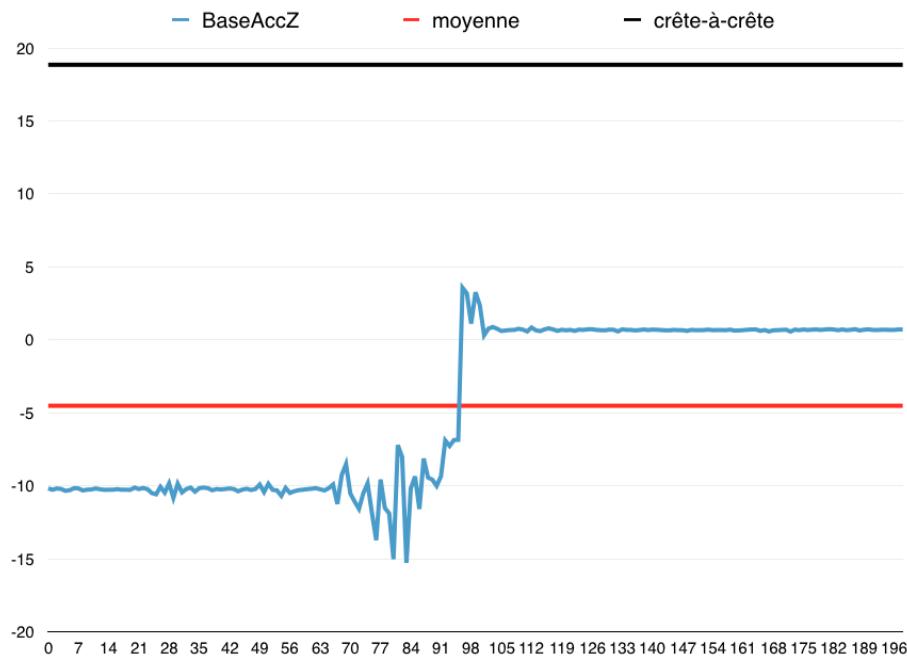


FIGURE 4.5 – Calcul des *caractéristiques simplifiées*. La figure représente l'évolution de la feature "accélération du robot selon l'axe z ", caractéristique de la chute d'un robot. La ligne rouge représente sa valeur moyenne. La ligne noire correspond à sa valeur crête-à-crête. On a ainsi réduit notre feature à deux valeurs constantes. On peut entraîner l'algorithme d'apprentissage automatique à partir de ces *caractéristiques simplifiées*.

Le problème de cette approche est qu'elle réduit le nombre d'informations que contient une donnée à seulement quelques features (e.g. moyenne, valeur crête-à-crête). Comme le démontre la figure 4.6, cette diminution des informations peut entraîner des risques de confusion entre différentes features, i.e. deux features différentes peuvent avoir les mêmes caractéristiques. Or, si on souhaite utiliser cette approche dans l'architecture que l'on propose (cf. partie 4.1), le risque est que deux couches *root cause* soient liées à des features dont les caractéristiques sont similaires. Dans ce cas, le système est incapable de déterminer quelle *root cause* est responsable de l'apparition d'une *error name*.

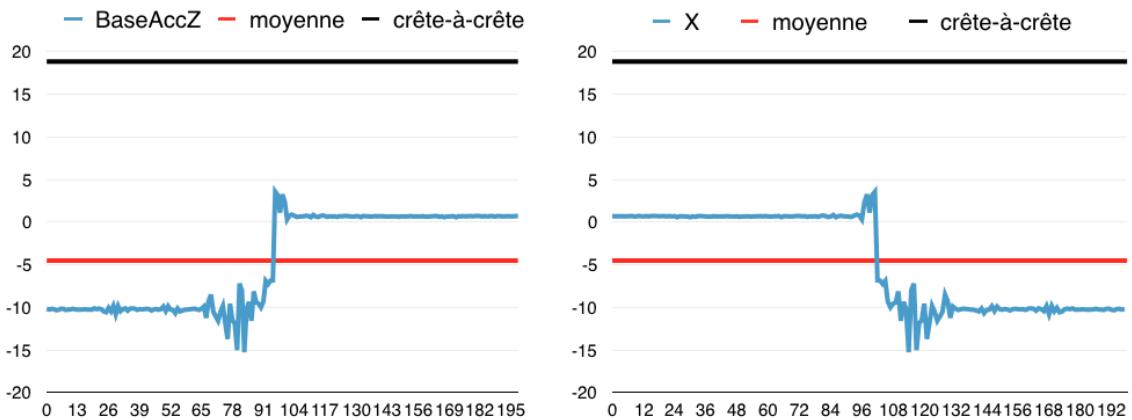


FIGURE 4.6 – Comparaison de deux caractéristiques. On retrouve sur la figure a) la valeur de l'accélération selon l'axe z et ses caractéristiques simplifiées. Sur la figure b), on observe une autre feature et ses caractéristiques simplifiées. On remarque que, bien qu'il s'agisse de features différentes entre les figures a) et b), ces dernières possèdent les mêmes *caractéristiques simplifiées*.

Considérer chaque unité de temps comme une feature

On propose de considérer chaque unité de temps comme une feature. Le nombre d'entrées du système d'apprentissage automatique est donc égal au nombre d'échantillons contenus dans un exemple.

De manière intuitive, entraîner le modèle revient à créer un patron représentatif de la feature lorsque celle-ci est liée à la présence d'une *root cause*. Une fois cette forme apprise, on la compare avec la feature que l'on souhaite analyser afin de savoir si la *root cause* est présente ou non dans la feature.

Exemple On souhaite créer une nouvelle couche *root cause* (i.e. entraîner un algorithme d'apprentissage) capable de reconnaître lorsqu'un robot chute. Dans le cadre de notre problématique ce système n'a pas de réelle utilité, on le propose ici car le problème est simple à comprendre.

Pour savoir si le robot chute ou non, on analyse l'évolution de la valeur de l'accélération selon l'axe *z*, fourni par l'accéléromètre de la base de Pepper (clé BaseAccZ).

D'après la figure 4.7, on remarque que l'évolution de BaseAccZ enregistrée lors de la chute d'un robot, diffère de l'évolution de BaseAccZ lorsque le robot ne chute pas. On va entraîner l'algorithme à reconnaître la forme caractéristique de l'évolution de l'accélération en *z* lorsque le robot chute. Pour cela, on admet que chaque échantillon (chaque instant *t*) qui constitue la BaseAccZ devient une entrée (feature) pour l'entraînement de l'algorithme d'apprentissage (cf. figure 4.8).

On compare ensuite ce patron à la courbe de l'accélération en *z* contenue dans le fichier log que l'on souhaite étudier. Si elle est globalement similaire au patron, on en déduit que le robot a chuté. Dans le cas contraire, on en déduit que le robot n'a pas chuté (cf. figure 4.9).

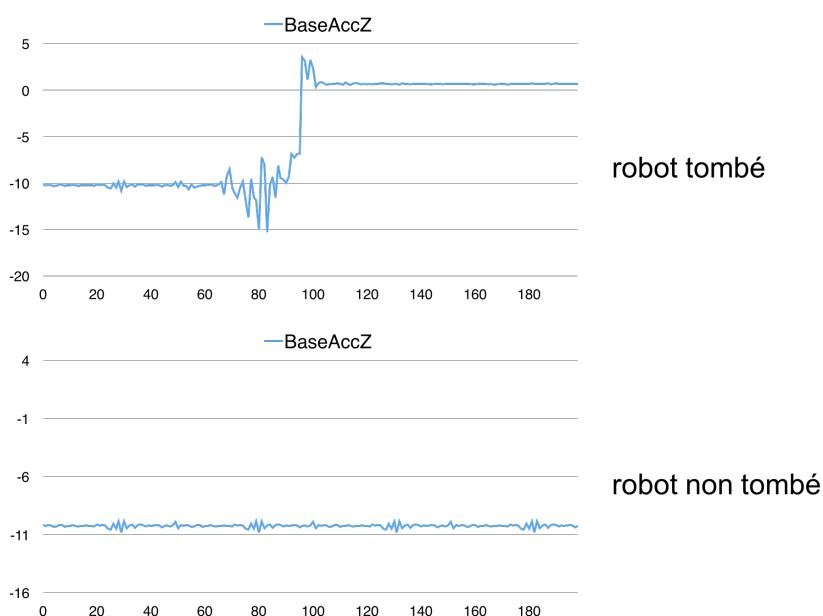


FIGURE 4.7 – Formes caractéristiques de BaseAccZ en temps normal et en cas de chute. On observe sur le graphe inférieur l'évolution de BaseAccZ lors d'un fonctionnement normal du robot. Sur le graphique supérieur, on observe l'évolution de BaseAccZ lorsque le robot chute. On remarque que celle-ci à la forme d'un échelon, centré sur l'instant où le robot tombe.

Au vu des tests réalisés, cette méthode ne semble pas viable. En effet, comme on peut

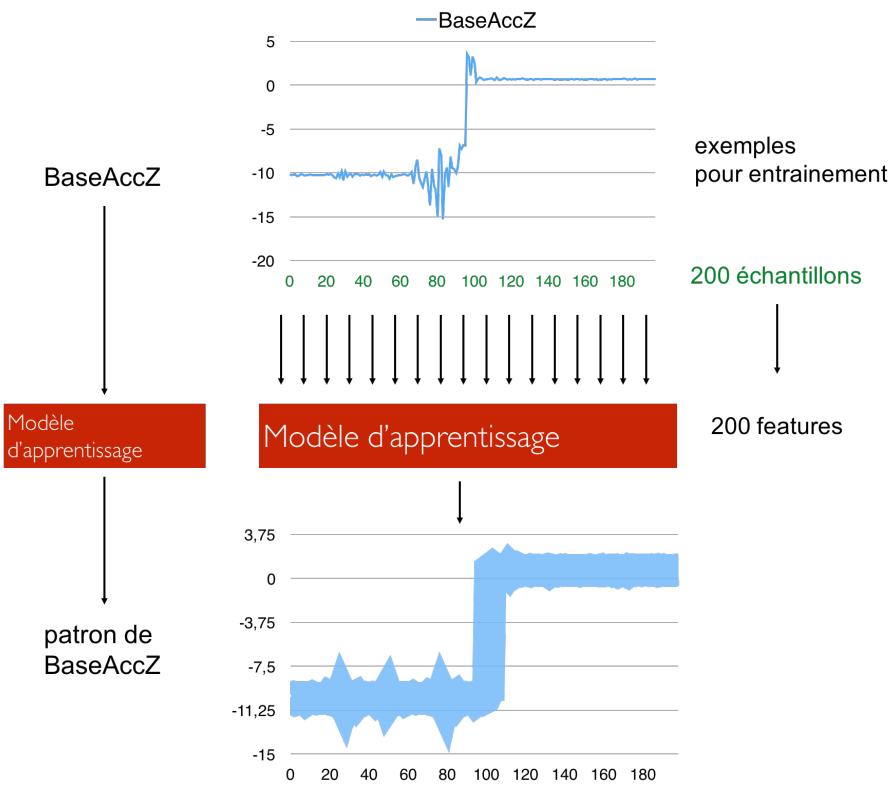


FIGURE 4.8 – Patron caractéristique de la chute du robot. Chaque échantillon, qui forme un exemple, est considéré comme une entrée du système d'apprentissage, i.e. une feature. Entraîner l'algorithme à reconnaître la forme de BaseAccZ, dans le cas de robots tombés, revient à créer un patron de BaseAccZ qui caractérise la chute. L'entraînement s'effectue à partir de différents exemples de la feature BaseAccZ lorsque le robot tombe.

l'observer sur le graphique inférieur de la figure 4.9, même si la feature BaseAccZ n'est pas totalement inclue dans le patron, elle l'est *partiellement*, et ce, sur pratiquement la moitié de son évolution. C'est pour cette raison que l'algorithme considère parfois un exemple comme caractéristique d'une chute alors qu'il ne l'est pas en réalité. Pour répondre à ce problème on propose, plutôt que de créer un patron de la totalité de la courbe, de seulement entraîner un algorithme à reconnaître une certaine portion caractéristique de la courbe. Dans le cas de la détection d'une chute du robot, il s'agit du saut de valeur qui apparaît sur la valeur de l'accélération en z du robot (BaseAccZ). On réalise ce qu'on appelle de la reconnaissance de motifs.

4.2.2 Reconnaissance de motifs

Principe général

D'une certaine manière, la reconnaissance de motif s'appuie sur une stratégie d'investigation proche de celle de l'Homme. On se place par exemple dans le cas où l'on souhaite déterminer la cause ayant entraîné la chute d'un robot. La cause correspond à la *root cause* et la chute du robot à *l'error name*. En tant qu'humain, on visualise et analyse les différentes courbes contenues dans le fichier log, généré lors de la détection de la chute. On observe l'évolution de la position du senseur (clé HipPitchPositionSensorValue) et de l'actuateur (clé HipPitchPositionActuatorValue) de la hanche (cf. figure 4.10). On remarque qu'à $t \approx 440s$, le senseur se met à ne plus suivre la valeur de l'actuateur. L'étude réalisée partie 2.2.3 nous apprend que cette particularité est la caractéristique d'un frottement

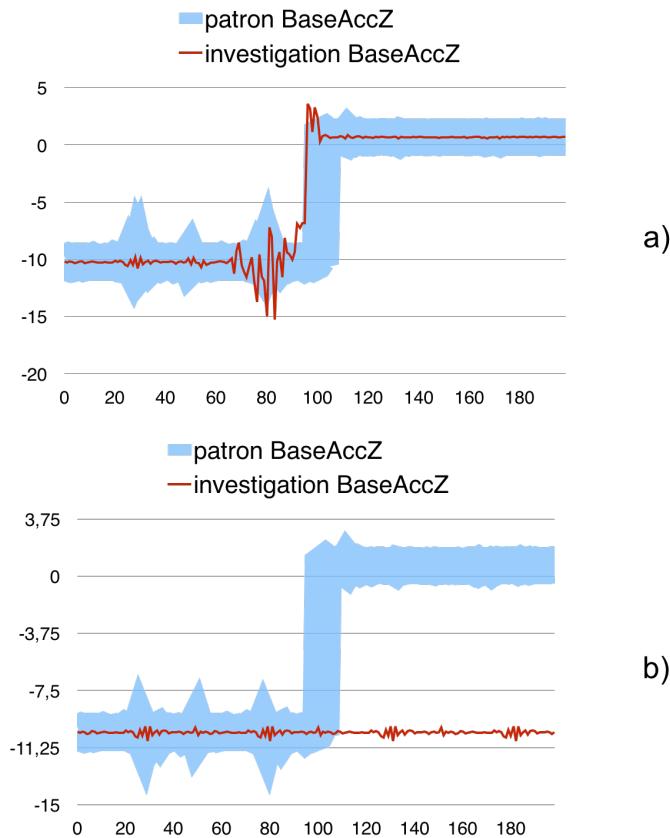


FIGURE 4.9 – Détection d'une chute à partir du patron de BaseAccZ. Afin de savoir si l'exemple que l'on étudie est lié à une chute de robot ou non, on compare la valeur BaseAccZ du fichier log au patron caractéristique d'une chute de BaseAccZ. Sur le graphique supérieur, on observe que BaseAccZ est globalement contenu dans le patron, il s'agit donc d'un fichier log généré lors de la chute d'un robot. On observe en revanche sur le graphique inférieur que BaseAccZ n'est que **partiellement** incluse dans le patron. Il ne s'agit donc pas d'un exemple caractéristique d'une chute.

des freins de la hanche. Ainsi, si on étudie ultérieurement un autre fichier log généré lors de la chute d'un robot et qu'on découvre de nouveau ce motif, on en déduit aisément que le robot est également tombé à cause du frottement des freins de sa hanche. Plus on va observer de nouveaux cas, plus l'image que l'on aura du motif caractéristique de cette *root cause* va se préciser.

Dans le cadre du développement de notre algorithme, le principe est le même : on commence tout d'abord à apprendre la forme caractéristique de la *root cause* et une fois que l'on souhaite investiguer un nouveau fichier log, on compare ce motif caractéristique aux données du fichier.

Apprentissage La phase d'apprentissage s'appuie sur les principes évoqués en partie 4.2.1. On considère que chaque échantillon (ou unité de temps) qui compose un exemple devient l'entrée de notre système d'apprentissage à la différence qu'on ne considère qu'une seule partie de la courbe de nos exemples, le motif caractéristique. Par exemple, si on souhaite créer une nouvelle root cause "frottement des freins de la hanche", on sélectionnera sur chaque exemple le motif caractéristique de celle-ci (cf. figure 4.11). Le système d'apprentissage va donc uniquement apprendre le patron du motif caractéristique et non de la courbe dans sa globalité. Les exemples devant être de la même taille, on veille à sélectionner le même nombre d'échantillons pour chacun des motifs. On présente également au système des exemples ne contenant pas le motif, afin que l'algorithme bénéficie des deux types de

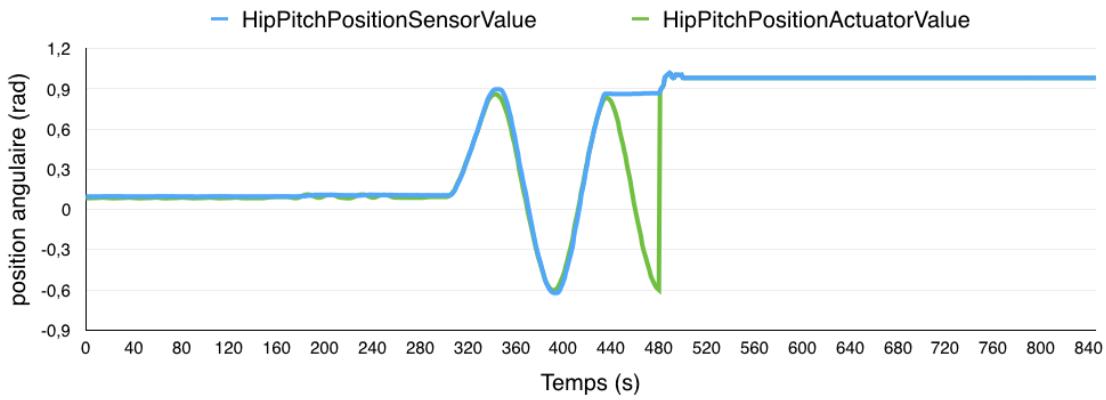


FIGURE 4.10 – Évolution de la position du senseur et de l'actuateur de la hanche.

labels pour son entraînement (root cause présente = 1, root cause non présente = 0).

Investigation Lorsque l'on souhaite investiguer un fichier pour déterminer la *root cause* qui a entraîné l'apparition de l'*error name* lors du Filering Test, on commence par extraire la valeur des features du fichier log qui sont liées à la *root cause*. Ensuite, on recherche le motif caractéristique. Pour ce faire, on découpe les courbes des features en plusieurs petits tronçons de la même taille que le motif caractéristique et on les compare avec celui-ci. S'ils sont globalement similaires au patron, on en déduit que la *root cause* a été détectée. Dans le cas contraire, on en déduit qu'elle n'a pas été détectée. En réalité, l'algorithme d'apprentissage automatique (SVM) nous retourne en sortie la probabilité avec laquelle le motif caractéristique semble avoir été détecté dans chacun des tronçons. On propose un exemple d'investigation en figure 4.12).

L'ensemble des probabilités en sortie des différents tronçons étudiés forment une courbe de probabilité. Si cette courbe dépasse un certain seuil, on considère la *root cause* comme ayant été détectée. On propose la courbe de probabilité de la *root cause* "frottement des freins de la hanche" en figure 4.14.

Représentation des données

On souhaite représenter de manière intuitive la répartition des exemples et des classes en fonction des features. Contrairement à la visualisation conceptuelle des données proposée en partie 4.1.1, on propose ici une représentation plus fonctionnelle (proche du fonctionnement de notre système).

Chaque échantillon qui compose le motif caractéristique d'une *root cause* devient lui-même une feature (i.e. une entrée) du système d'apprentissage de l'algorithme SVM (cf. figure 4.8). Par exemple, on se place de nouveau dans le cas de la *root cause* "frottement des freins de la hanche". Si on s'intéresse aux features "HipPitchPositionSensorValue" et "HipPitchPositionSensorValue" et que l'on considère que le motif caractéristique a une taille de 125 échantillons, on aura donc 250 features en entrée de l'apprentissage (125×2 features). Cela signifie que si l'on souhaite représenter visuellement la répartition des exemples et des classes en fonction des features, on aurait un repère composé de 250 dimensions. On choisit au hasard deux des 250 dimensions et on les représente sur le repère figure 4.14 .

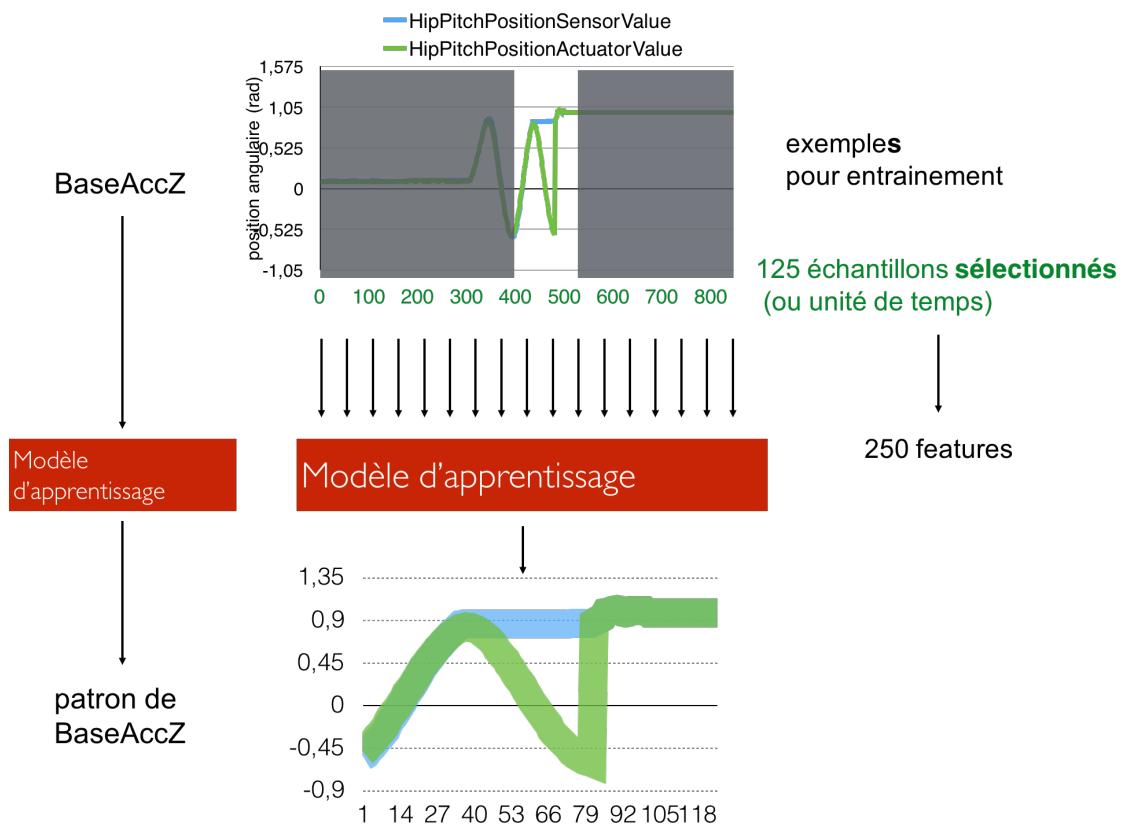


FIGURE 4.11 – Créer un patron du motif caractéristique de la root cause "frottement des freins de la hanche". Chaque échantillon qui compose un motif est considéré comme une entrée du système d'apprentissage. Entraîner l'algorithme à reconnaître le motif caractéristique formé par les courbes du `HipPitchPositionSensorValue` et `HipPitchPositionActuatorValue` revient à créer un patron caractéristique des deux features liées au frottement des freins de la hanche dans le cadre de la chute du robot. L'entraînement s'effectue à partir de différents exemples de motifs des deux features.

4.3 Performances de la solution

Une fois l'architecture du système définie, on souhaite mesurer les performances de l'algorithme.

4.3.1 Optimisation des paramètres du SVM

La prise de décision de l'algorithme du SVM peut être contrôlée via deux paramètres : C et gamma.

C Le paramètre C permet de modifier la valeur de la marge du SVM. Une valeur élevée du paramètre optimise la classification de chaque exemple en entrée, i.e. à trouver une ligne de décision permettant de classer au mieux chaque exemple. Cette optimisation de la classification se fait au dépend de la taille de la marge, qui sera réduite. Une valeur plus élevée de C permet au contraire d'optimiser la taille de la marge (i.e. la maximiser autant que possible), au préjudice de la classification des exemples (cf. 4.15).

gamma Intuitivement, le paramètre gamma définit dans quelle mesure l'influence d'un exemple affecte la ligne de décision et la marge. Il peut être considéré comme l'inverse du rayon d'influence des échantillons sélectionnés par le modèle, en tant que vecteurs de support (cf. 4.16).

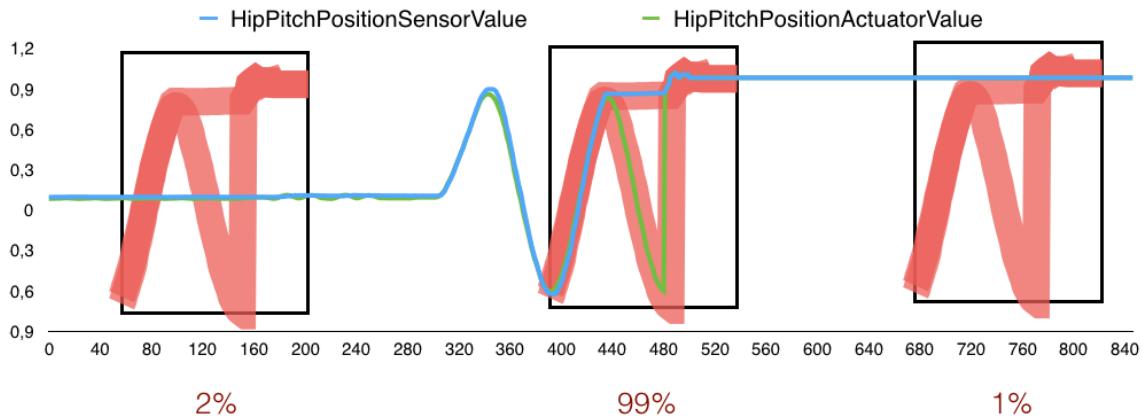


FIGURE 4.12 – Balayage des features pour trouver le motif caractéristique d'une *root cause*. On observe que le premier et le dernier tronçon de la courbe des features HipPitchPositionSensorValue et HipPitchPositionActuatorValue ne correspondent pas au motif caractéristique de la *root cause* "frottement des freins de la hanche". La probabilité en sortie du système est donc faible. Le deuxième tronçon correspond globalement au motif caractéristique de la courbe, la probabilité en sortie du système est donc élevée.

Afin de déterminer la meilleure combinaison de valeurs des deux paramètres, on calcule les *courbes de validation*. Cela consiste à faire varier chacun des deux paramètres sur une plage de données et à calculer la précision de l'algorithme pour chaque valeur. On conserve ensuite la valeur optimale.

Exemple On soumet en figure 4.17 et 4.18 les courbes de validation de la couche *root cause* "frottement des freins de la hanche". On remarque que la valeur $C = 10$ optimise le mieux la précision de l'algorithme d'apprentissage. On remarque également que la valeur $\gamma \approx 0.2$ optimise le mieux la précision de l'algorithme d'apprentissage.

4.3.2 Matrices de confusion

Au début du processus, on sépare la base de données d'exemples en deux groupes : le *training set* et *test set*. Le premier jeu sert à entraîner l'algorithme SVM et l'autre permet d'en tester les performances. On rappelle que chaque exemple est labellisé, i.e. que l'on connaît la sortie à laquelle il est corrélé (dans le cas de notre problématique, les labels étant *root cause* présente ou non présente).

Pour tester l'algorithme :

1. On commence par entraîner l'algorithme à partir des exemples du *training set*.
2. Une fois l'algorithme entraîné, on analyse chacun des exemples du *test set*.
3. On compare ensuite la sortie prédite par l'algorithme et la sortie réelle (i.e. le label associé à chaque exemple).

Ainsi, on est capable de calculer le nombre de fois que l'algorithme a correctement prédit la sortie et lorsqu'il ne l'a pas fait. Ces résultats peuvent être exprimés sous la forme d'une *matrice de confusion*. Chaque colonne de la matrice représente le nombre d'occurrences d'une classe réelle (le label), tandis que chaque ligne représente le nombre d'occurrences de la classe prédite. Un des intérêts de la matrice de confusion est qu'elle montre rapidement si le système parvient à classifier correctement.

Avec :

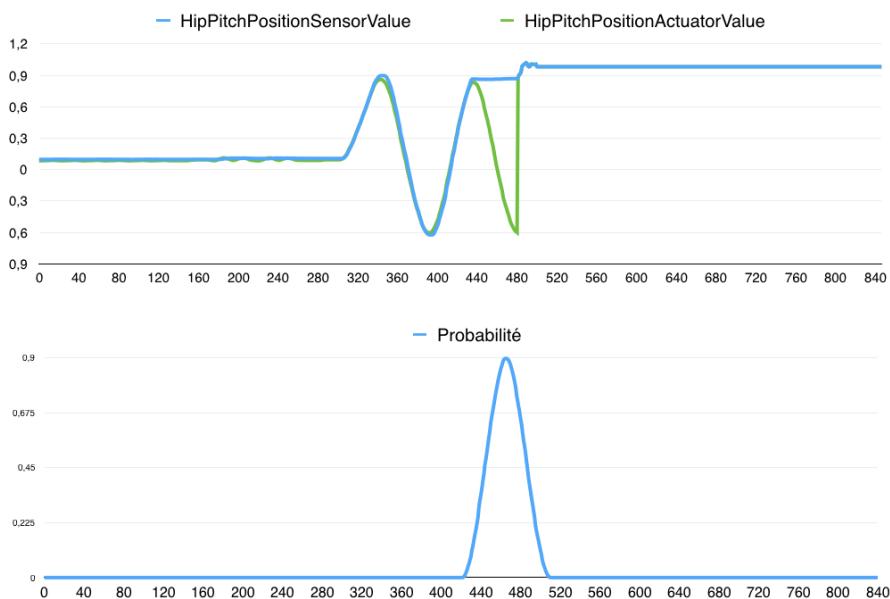


FIGURE 4.13 – Courbe de probabilité de la root cause "frottement des freins de la hanche". On observe que lorsque l'on s'approche du motif caractéristique de la *root cause*, la probabilité augmente fortement. Elle est au contraire faible sur les autres tronçons de la courbe.

		Classe réelle	
		Vrai	Faux
Classe prédictive	Vrai	TP	FP
	Faux	FN	TN

TABLE 4.1 – Matrice de confusion

- TP = True positive (en français vrai positif) correspond au nombre de résultats prédicts positifs, là où ils étaient effectivement positifs.
- TN = True negative (en français vrai négatif) correspond au nombre de résultats prédicts négatifs, là où ils étaient effectivement négatifs.
- FP = False positive (en français faux positif) correspond au nombre de résultats prédicts positifs, là où ils étaient en réalité négatifs.
- FN = False negative (en français faux négatif) correspond au nombre de résultats prédicts négatifs, là où ils étaient en réalité positifs.

A partir de ces résultats, il est possible de déterminer la précision de l'algorithme :

$$\text{accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (4.3)$$

Exemple On soumet ici la matrice de confusion de la couche *root cause* "frottement des freins de la hanche".

		Classe réelle	
		Vrai	Faux
Classe prédictive	Vrai	45	0
	Faux	0	15

TABLE 4.2 – Matrice de confusion de la root cause "frottement des freins de la hanche"

On observe qu'il n'y a aucun faux négatif et faux positif. Cela signifie que pour chaque exemple du *test set*, l'algorithme a parfaitement prédit la sortie, i.e. qu'il a su à chaque fois

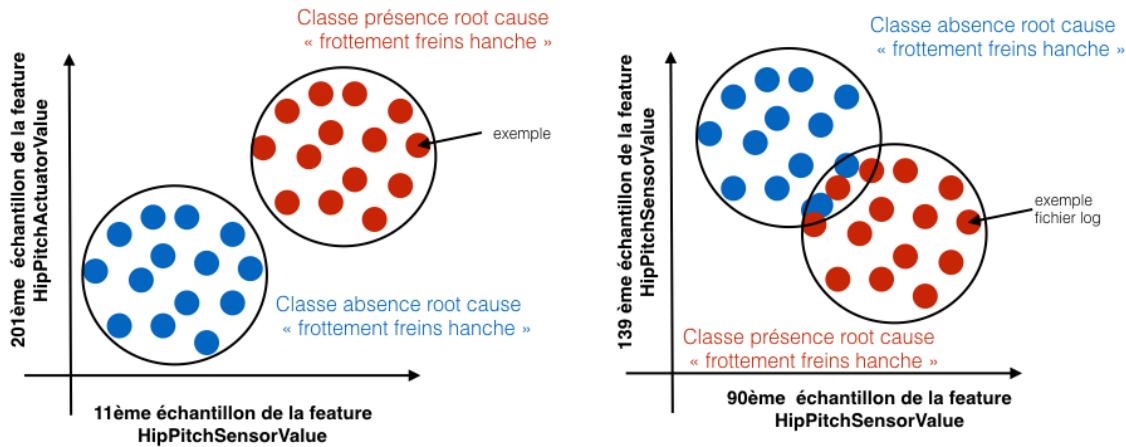


FIGURE 4.14 – Représentation de la répartition des exemples et des classes en fonction des features. On a représenté ici deux graphiques dont chacun exprime la valeur des exemples en fonction de deux features choisies aléatoirement. Chaque feature correspond à un échantillon parmi les 250 qui composent chaque motif caractéristique de la *root cause* "frottement des freins de la hanche".

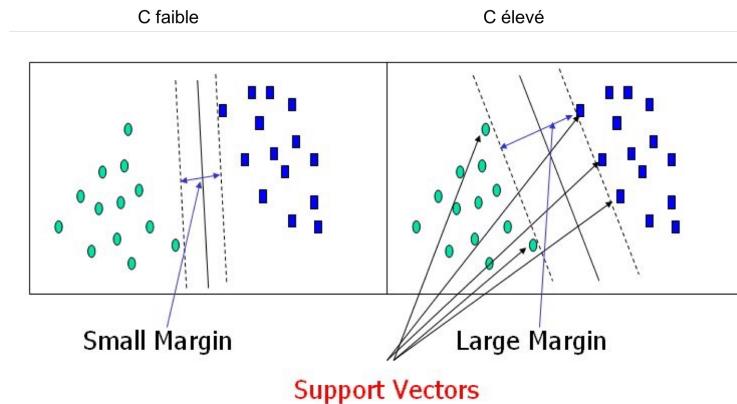


FIGURE 4.15 – Variation du paramètre C.

déTECTer correctement si la *root cause* "frottement des freins de la hanche" était présente ou non dans le fichier log. D'après l'équation 4.3, la précision de l'algorithme SVM de cette couche *root cause* est donc de 100%.

4.3.3 Courbes d'apprentissage

La courbe d'apprentissage représente la précision de l'algorithme d'apprentissage en fonction du nombre d'exemples utilisés dans le *training set* et le *test set*. Grâce à ces tracés, on est en mesure de déterminer la qualité de notre algorithme d'apprentissage et de la base de données d'exemples, de manière visuelle et intuitive.

- Si la distance entre les deux courbes est importante à la fin du graphe, cela signifie que l'on n'a pas utilisé suffisamment d'exemples pour l'entraînement de l'algorithme. On dit que l'algorithme a une *variance* trop élevée.
- Si la valeur de convergence des deux courbes (précision) n'est pas assez élevée, cela signifie que notre algorithme n'est pas suffisamment performant. On dit qu'il a un *bias* trop élevé. Pour résoudre ce problème, on peut par exemple augmenter le nombre de features en entrée. Dans le cas de notre système, cela signifie augmenter la largeur des motifs caractéristiques d'une *root cause*.

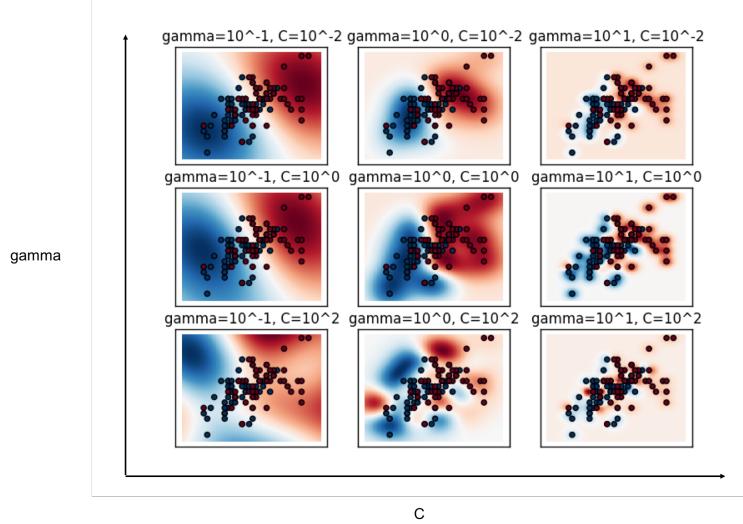
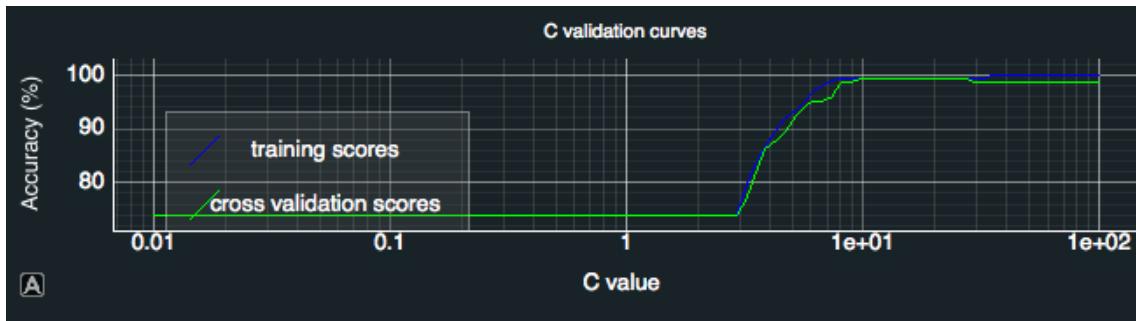


FIGURE 4.16 – Variation des paramètres C et gamma.


 FIGURE 4.17 – Courbes de validation du paramètre C, pour la couche *root cause* "frottement des freins de la hanche".

Exemple On soumet en figure 4.19 les courbes d'apprentissage de la couche *root cause* "frottement des freins de la hanche". On observe que les deux courbes convergent jusqu'à pratiquement se confondre. On en déduit que la *variance* de l'algorithme est très faible et donc que le nombre d'exemples utilisés pour l'apprentissage de l'algorithme est suffisant. De plus, la valeur de convergence est aux alentours de 98%, ce qui signifie que le *bias* de l'algorithme est faible. On peut donc dire que les performances de l'algorithme de la couche *root cause* "frottement des freins de la hanche" sont bonnes.

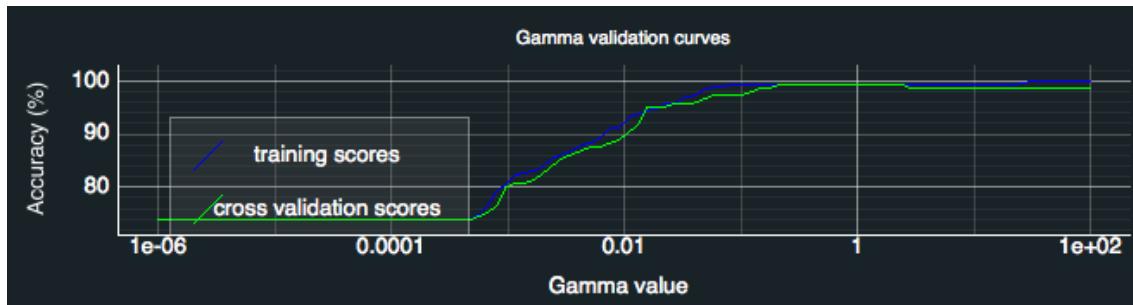


FIGURE 4.18 – Courbes de validation du paramètre gamma, pour la couche *root cause* "frottement des freins de la hanche".

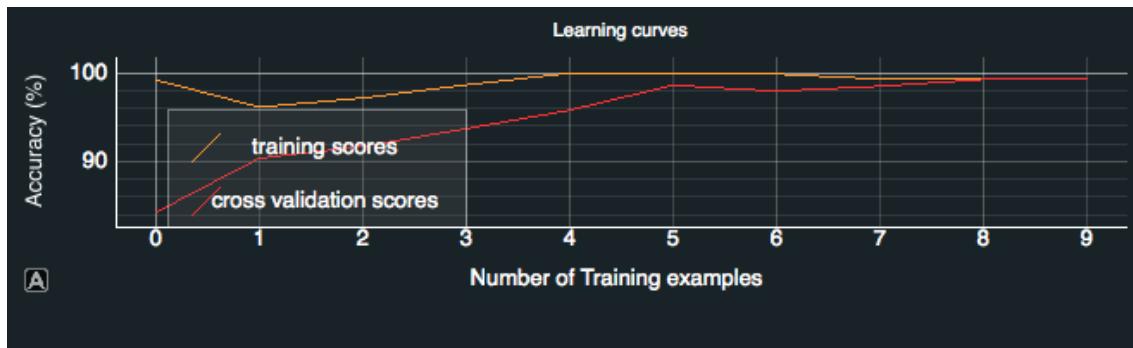


FIGURE 4.19 – Courbes d'apprentissage de la couche *root cause* "frottement des freins de la hanche".

Chapitre 5

Industrialisation du produit

Une fois le processus fonctionnel de notre système défini, on l'industrialise. Cela signifie que l'on crée un ensemble d'outils qui permettent de l'utiliser de la manière la plus simple possible et ce en répondant au mieux à la problématique initiale.

On soumet deux types d'outils : l'API, qui permet d'utiliser le système d'automatisation et les outils graphiques, qui accompagnent l'usage de l'API et offrent à l'utilisateur un moyen d'interagir avec le programme.

5.1 API

L'API que l'on propose est composée de 3 modules :

data base Permet de gérer le stockage et la lecture des données nécessaires à l'exécution des algorithmes d'apprentissage. Deux types de fichiers y sont sauvegardés : les fichiers logs, qui fournissent l'ensemble des exemples permettant d'entraîner le SVM et les fichiers générés par l'algorithme lors de son apprentissage.

data set Permet de prétraiter les exemples utilisés pour l'apprentissage.

machine learning Permet de créer un algorithme d'apprentissage, de l'entraîner et de l'utiliser pour investiguer la *root cause* pour laquelle il a été créé.

La librairie utilise le langage de programmation Python [9].

5.1.1 Prétraitement des données

Le module "Data set" de l'API permet de prétraiter les exemples et de les structurer pour entraîner le SVM. Le prétraitement est composé de 5 étapes.

Lecture Lecture des données contenues dans le fichier log.

Échantillonnage Les données des fichiers logs générés par MEIGUI lors du déroulement du Filtering Test n'ont pas forcément toutes la même période d'échantillonnage. Cela signifie que les exemples que l'on souhaite utiliser pour l'entraînement ne font pas tous la même taille. Or, les spécificités des fonctions de la librairie Scikit-learn utilisées pour l'entraînement nécessite que celles-ci aient le même nombre d'échantillons. Pour cette raison, on échantillonne les données extraites des fichiers logs avec le même nombre d'échantillons. Si le nombre d'échantillons contenus dans le fichier log est inférieur au nombre d'échantillons fixé par l'échantillonnage, on effectue un sur-échantillonnage, quand celui-ci n'altère pas les données.

Selection des motifs Au regard de l'architecture fonctionnelle que l'on a défini en partie 4.1, on doit extraire les motifs caractéristiques d'une root cause dans chaque exemple utilisé. Pour cela, une sélection manuelle du motif est réalisée en amont via une interface graphique (cf. 5.2.1). A partir des informations retournées par l'IHM (Interface Homme Machine), on est en mesure de sélectionner les portions des exemples qui correspondent aux motifs. On rappelle que l'on sauvegarde également des morceaux de la courbe qui ne contiennent pas de motif caractéristique d'une *root cause*. Cette étape permet également de labelliser les exemples, i.e. indiquer si le motif sélectionné correspond à un motif caractéristique de la *root cause* ou non.

Déroulement des données On déroule ensuite les données pour réaliser de la reconnaissance de motifs avec plusieurs features, i.e. que l'on place chacune des colonnes de notre matrice d'exemples les unes en dessous des autres. On obtient en sortie un vecteur.

Tri des données Enfin, pour mesurer les performances de notre algorithme (cf. partie 4.3), on sépare notre base de données d'exemples en deux groupes : le *training set* et le *test set*. Le premier sera utilisé pour entraîner notre algorithme, le deuxième pour le tester.

Sélection des motifs

Comme étudié en partie 4.2.2, la reconnaissance de motifs passe par la sélection des motifs caractéristiques de la root cause que l'on souhaite détecter, dans chaque exemple de notre base de données. Chaque motif sélectionné doit avoir la même taille i.e. le même nombre d'échantillons pour pouvoir réaliser l'entraînement. Cette taille dépend de la largeur globale du motif caractéristique et est déterminée par l'utilisateur lors de l'utilisation de l'interface graphique présentée partie 5.2.1.

Format des données de sortie

On présente dans le tableau 5.1 la structure des données en sortie du prétraitement des données. On a deux vecteurs : l'un contenant les exemples de motifs, l'autre contenant le label associé à chaque motif. Le label 1 signifie que le motif correspond à un motif caractéristique de la *root cause*, 0 signifie que le motif ne correspond pas à un motif caractéristique de la *root cause*.

$$\begin{array}{c} \text{exemples} \quad \text{labels} \\ \left[\begin{array}{c} \text{exemple}_1 \\ \text{exemple}_2 \\ \text{exemple}_3 \\ \text{exemple}_4 \\ \dots \\ \text{exemple}_m \end{array} \right] \left[\begin{array}{c} 1 \\ 0 \\ 0 \\ 1 \\ \dots \\ 0 \end{array} \right] \end{array} \quad (5.1)$$

On retrouve cette structure pour chaque *set* (i.e. *training set* et *test set*).

Chaque exemple correspond à une liste qui contient l'ensemble des échantillons contenus dans un motif.

5.1.2 Module Machine Learning

Le module Machine Learning s'appuie sur l'utilisation de scikit-learn [10]. Il s'agit d'une bibliothèque Open Source développée par l'INRIA (Institut National de Recherche en Informatique et en Automatique [11]). Elle propose de nombreux outils qui permettent de

réaliser de la classification (régression logistique, SVM), de la régression (SVR, régression linéaire) et du clustering (i.e. apprentissage non supervisé). On l'utilise dans le cadre de notre projet pour réaliser de classification (i.e. apprentissage supervisé) en utilisant l'algorithme d'apprentissage automatique SVM. Elle est également utilisée pour construire le *training set* et le *test set* et déterminer les performances de l'algorithme.

5.2 Outils graphiques

On présente ici les différents outils graphiques qui permettent de réaliser la construction d'une nouvelle couche root cause (i.e. un nouvel algorithme pour détecter une *root cause*), d'investiguer une *error name* et d'obtenir des informations sur les performances de l'algorithme.

5.2.1 Pattern selector

Cet outil graphique permet de sélectionner les motifs contenus dans chaque exemple du *training set*, lors la phase de prétraitement et de labellisation des exemples.

Il est formé de trois parties :

- La première partie (encadré vert de la figure 5.1) fournit des informations sur l'état actuel du prétraitement des données : la taille du motif sélectionné, le nom de l'exemple étudié et le nombre d'exemples restant à traiter.
- La seconde partie (encadré rouge de la figure 5.1) affiche les features de l'exemple actuellement étudié. Dans le cas de la figure 5.1, on réalise par exemple l'entraînement de l'algorithme pour que celui-ci puisse reconnaître le motif caractéristique de la root cause "frottement des freins de la hanche". La région de sélection en rouge permet de sélectionner le motif qui nous intéresse.
- La dernière partie (encadré bleu de la figure 5.1) est une succession de boutons qui permettent à l'utilisateur d'interagir avec les différents exemples. De gauche à droite :
 - Le bouton "Previous" permet de revenir à l'exemple précédent.
 - Le bouton "Found" permet d'indiquer au système que le motif est présent sur l'exemple étudié, et qu'il a bien été sélectionné grâce à la région de sélection. Cela revient à labelliser l'exemple ($Y = 1$, cf. partie 5.1.1). Le prochain exemple à étudier s'affiche.
 - Le bouton "Not Found" permet d'indiquer au système que le motif n'est pas présent sur l'exemple étudié. Cela revient à labelliser l'exemple ($Y = 0$, cf. partie 5.1.1). Le prochain exemple à étudier s'affiche.
 - Le bouton en forme d'œil ouvert permet d'activer le mode étendu (cf. figure 5.2).

Région de sélection

La région de sélection permet de sélectionner le motif caractéristique d'une *root cause* dans chaque exemple où celui-ci se présente.

Il est possible d'augmenter sa taille si le besoin est présent. Par exemple, imaginons que l'on sélectionne sur le premier exemple un motif, dont la taille est de 60 échantillons. On clique sur le bouton "Found" et un nouvel exemple s'affiche. Celui-ci contient également le motif caractéristique de la *root cause* que l'on apprend. Cependant, ce dernier est plus large de 10 échantillons. Il est alors possible d'étendre la région de sélection pour pouvoir sélectionner l'ensemble de ce nouveau motif. Cependant, l'ensemble des exemples devant avoir la même taille (même nombre d'échantillons) pour l'entraînement de l'algorithme, on

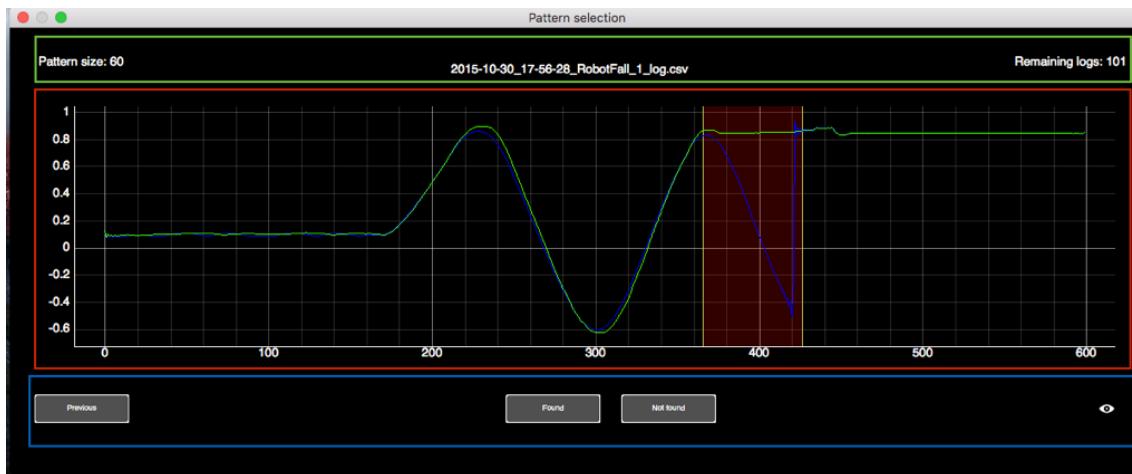


FIGURE 5.1 – Interface graphique du pattern selector.

modifie la taille des motifs précédemment sélectionnés. Dans le cas de notre exemple, on augmente la taille du motif précédent de 5 échantillons de chaque côté. Il n'est pas possible de réduire la taille d'un motif pour ne pas perdre des données sur les exemples précédemment sélectionnés.

Mode étendu

Il existe certains cas où les valeurs de deux features étudiées sont trop éloignées l'une de l'autre pour pouvoir être visualisées de manière correct. Pour cela, on peut basculer l'IHM en mode étendu, ce qui permet d'afficher chaque feature dans un graphique séparé. La région de sélection est commune aux différents graphes, i.e. sa taille et sa position sont contrôlées via le graphique principal et se répercutent sur les graphiques du mode étendu (cf. figure 5.2)

5.2.2 Probability Visualization

Cette interface graphique permet de visualiser l'exemple que l'on investigue et la probabilité que le motif soit présent dans l'image. Elle est composée de deux parties.

- La première partie (encadré vert sur la figure 5.3) affiche les features de l'exemple que l'on investigue. Par exemple, dans le cas présent, on recherche la *root cause* liée à l'*error name* "chute du robot". Le système détecte que la *root cause* est "le frottement des freins de la hanche". Il nous affiche donc les courbes du senseur et de l'actuateur de la hanche, sur lesquelles on observe le motif caractéristique de la *root cause*.
- La deuxième partie (encadré rouge sur la figure 5.3) affiche la courbe de progression de la probabilité, au cours du balayage des features de l'exemple (cf. partie 4.2.2). La ligne horizontale sur le graphique représente le seuil à partir duquel on considère que la *root cause* est bien la cause ayant entraîné l'apparition de l'erreur.

5.2.3 Control panel

Le control panel permet d'obtenir un certain nombre d'informations quant à la qualité de la base de données d'exemple utilisée pour créer une nouvelle couche *root cause*, ainsi que sur les performances de l'algorithme d'apprentissage automatique. La plupart de ces informations sont déterminées grâce aux outils soumis en partie 4.3. L'IHM est composé de trois parties.

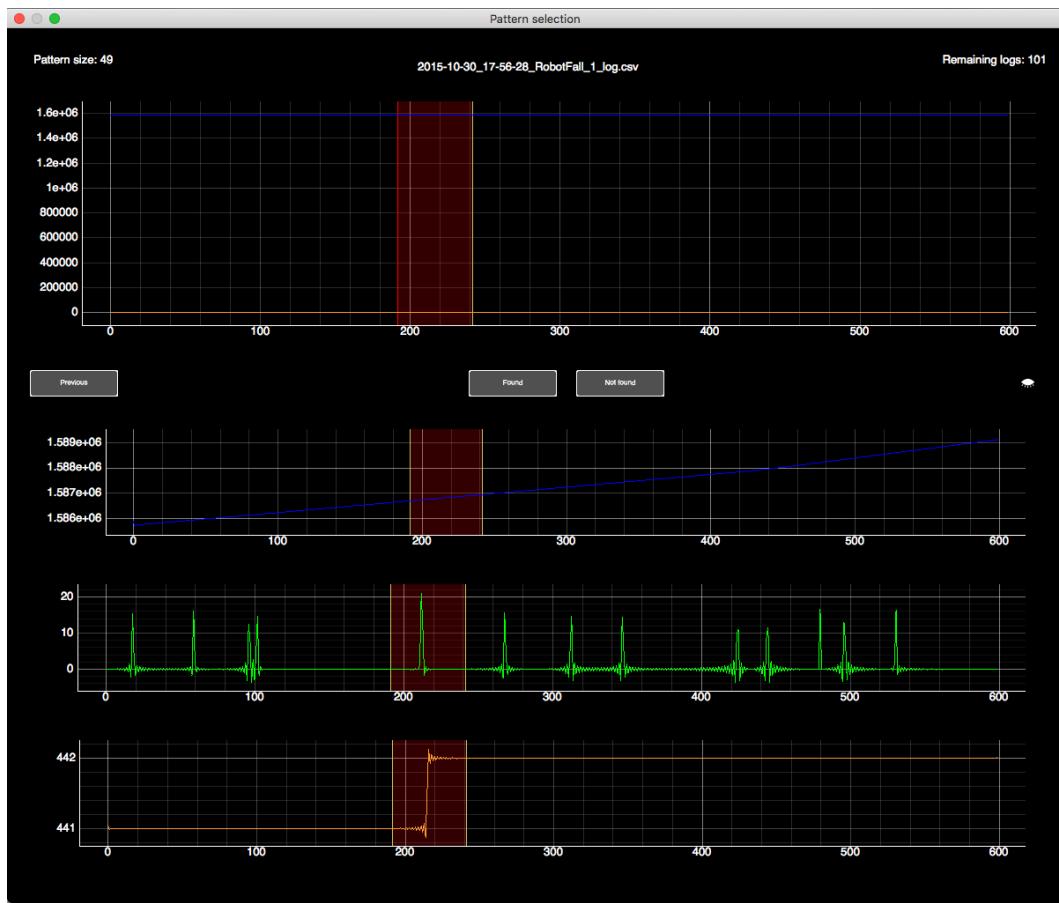


FIGURE 5.2 – Interface graphique du pattern selector en mode étendu. On observe sur ce graphique les trois features BackPlateformAck, BackPlateformNack et BackPlateformError du premier exemple. On remarque que l'affichage sur le graphique principal n'est pas clair. Le mode étendu permet d'afficher chacune des features. La région de sélection est commune aux trois graphiques (même position, même taille).

Data set features (encadré vert sur la figure 5.4) fournit un ensemble d'informations sur la base de données d'exemples utilisée pour l'entraînement de l'algorithme d'apprentissage automatique.

Training panel features (encadré rouge sur la figure 5.4) livre des informations sur l'algorithme d'apprentissage automatique de la couche root cause analysée (e.g. valeur des paramètres, matrice de confusion, précision, etc). Ces données sont pour la plupart relatives aux explications fournies en partie 4.3.

Training panel (encadré bleu sur la figure 5.4) permet d'analyser les courbes d'apprentissage (c.f. partie 4.3.3) et les courbes de validation (c.f. partie 4.3.1)

5.3 Utilisation suggérée des outils

On propose dans cette partie un exemple d'utilisation de l'API et des interfaces graphiques. Cette solution a été mise en place dans le cadre du stage afin de proposer un script qui permet d'ores et déjà de gérer la base de données, de créer de nouvelles couches *root cause* et d'investiguer des fichiers logs. On s'appuie sur l'utilisation de la librairie python *npyscreen* [12] qui permet de réaliser des interfaces utilisateurs simples, directement dans le terminal.

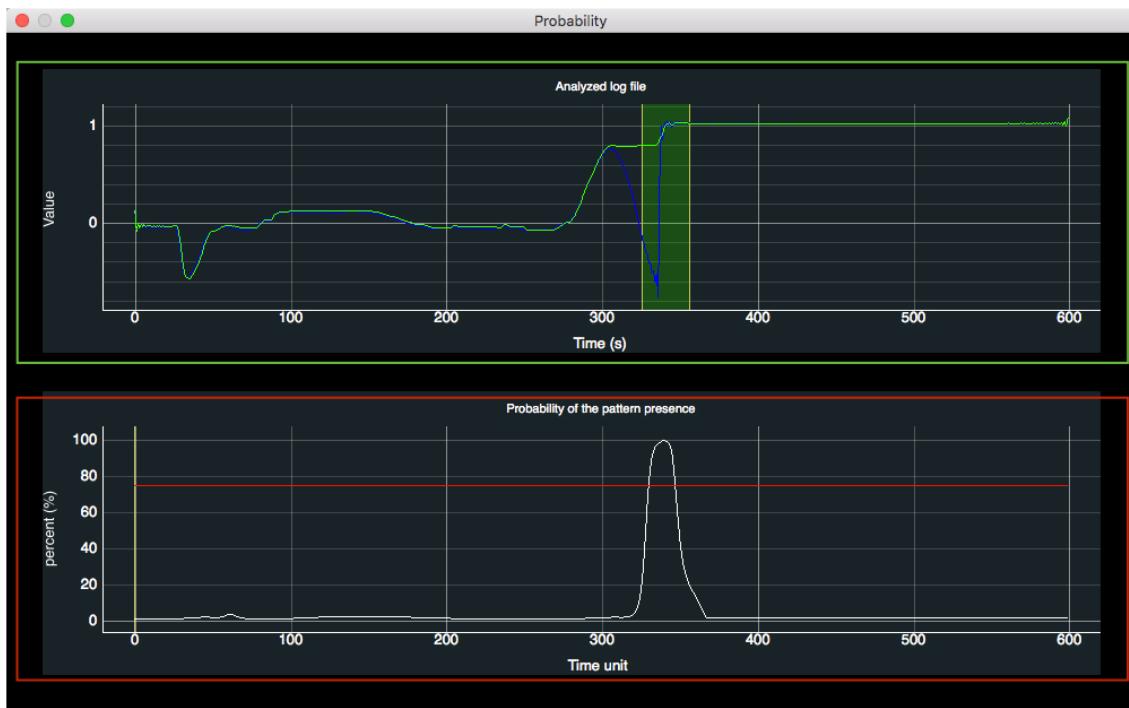


FIGURE 5.3 – Interface graphique du probability visualizer.

On s'intéressera ici au problème de frottement des freins de la hanche, qui entraîne la chute du robot durant le Filtering Test. Sa résolution passe par trois étapes :

1. Créer une nouvelle couche *error name* : la couche "chute du robot".
2. Créer un nouvelle couche *root cause* liée à la couche *error name* "chute du robot" : la couche "frottement des freins de la hanche". Cela signifie que l'on va entraîner un nouvel algorithme à détecter le motif caractéristique de cette *root cause*.
3. vérifier les performances de la nouvelle couche *root cause* créée via le Control Panel.
4. Investiguer un fichier log.

5.3.1 Menu principal

Le menu principal (cf. figure 5.5) permet d'ouvrir 5 sous-menus qui permettent respectivement de :

- Créer une nouvelle couche *error name* et l'ajouter à la base de données.
- Créer une nouvelle couche *root cause*, la lier à une couche *error name* et l'ajouter à la base de données.
- Investiguer un fichier log.
- Mettre à jour une *root cause*.
- Ouvrir le control panel.

5.3.2 Nouvelle error name

Le menu "Add an error name to the knowledge base" (cf. figure 5.5) permet d'ajouter une couche *error name* dans la base de données.

Il suffit pour cela d'indiquer le nom de la couche *error name* que l'on souhaite créer : dans notre cas, on l'appellera **fall down**. Celle-ci ne contient alors aucune *root cause*.

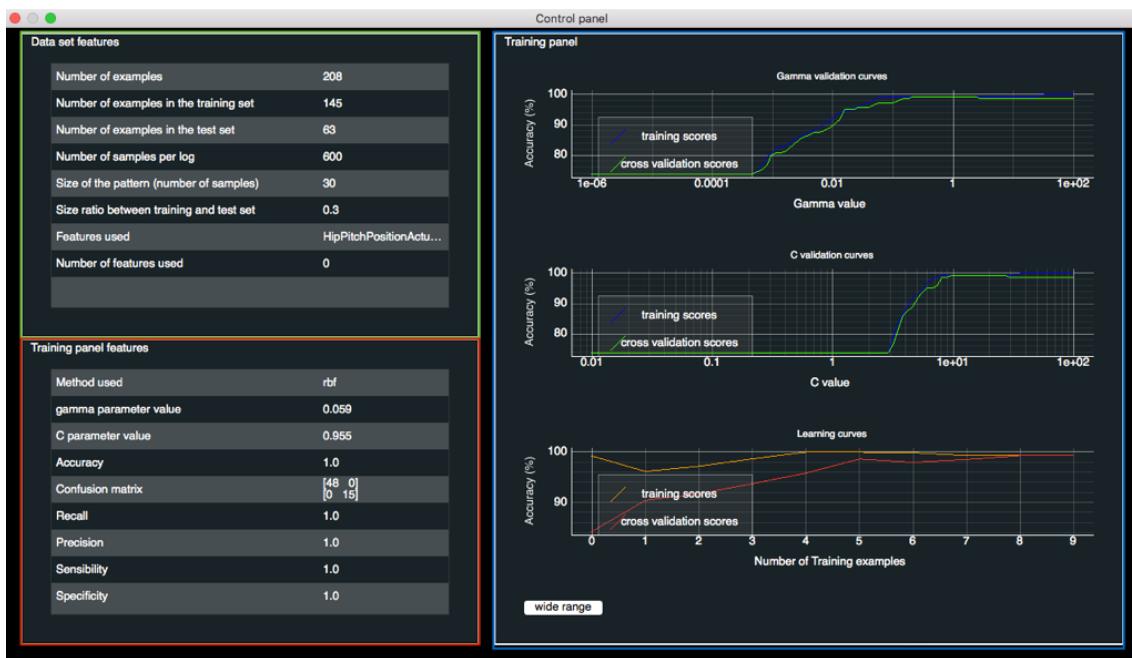


FIGURE 5.4 – Interface graphique du control pattern.

5.3.3 Nouvelle root cause

Le menu "Add a root cause to the knowledge base" (cf. figure 5.5) permet de créer une nouvelle *root cause* (i.e. entraîner un nouvel algorithme d'apprentissage à reconnaître une *root cause*), à la lier à une couche *error name*, et à l'ajouter à la base de données.

Pour cela, on suit le processus suivant (cf. figure 5.6) :

1. On sélectionne l'*error name* à laquelle on souhaite lier cette nouvelle *root cause*. On indique ensuite son nom. Dans le cas de la *root cause* "frottement des freins de la hanche", on la lie à l'*error name* "fall down" et on l'appelle "frottement des freins de la hanche".
2. On sélectionne la/les feature(s) liée(s) à la *root cause*. Dans le cas de la *root cause* du "frottement des freins de la hanche", on sélectionne les clés HipPitchPosition-SensorValue, HipPitchPositionActuatorValue, respectivement les valeurs du senseur et de l'actuateur de la hanche.
3. On utilise le Pattern Selector (cf. partie 5.2.1) pour sélectionner les motifs caractéristiques de la *root cause* que l'on étudie. Dans notre cas, il s'agit du moment où le senseur ne suit plus l'actuateur. On répète cette manipulation pour chaque exemple de la base de données.

5.3.4 Investiguer un fichier log

Le menu "Investigate a log file" (cf. figure 5.5) permet de réaliser une investigation sur un fichier log, i.e. trouver la *root cause* qui a entraîné l'apparition de l'*error name* durant le Filtering Test. Pour cela, on suit le processus suivant (cf. figure 5.7) :

1. On commence par indiquer au script le chemin vers le fichier log. On sélectionne ensuite l'*error name* que l'on souhaite investiguer dans la liste des *errors name* connues (i.e. présentes dans la base de données).
2. Le programme nous affiche le Probability Visualizator (cf. partie 5.2.2)
3. Une fois le Probability Visualizator fermé, le script nous indique la *root cause* trouvée dans le fichier log.

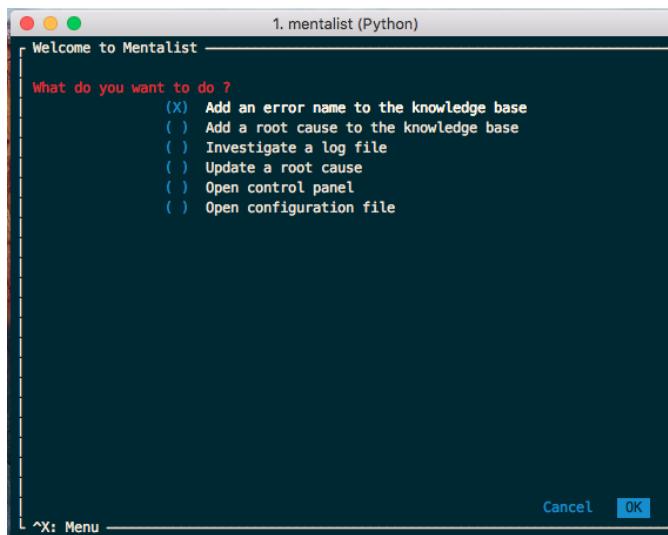


FIGURE 5.5 – Menu principal.

5.3.5 Analyse des performances d'une root cause

Le menu "Open control panel" (cf. figure 5.5) permet de sélectionner une root cause liée à une error name et d'en afficher le control panel pour obtenir des informations sur la qualité des exemples utilisés pour l'apprentissage automatique et sur les performances. Pour cela, on suit le processus suivant (c.f. figure 5.8) :

1. On sélectionne dans l'arborescence des *errors name* et des *root causes*, la *root cause* que l'on souhaite étudier.
2. Le Control Panel s'affiche (cf. partie 5.2.3)

5.3.6 Mise à jour d'une root cause

Le menu "Update a root cause" (cf. figure 5.5) permet d'ajouter des exemples à la base de données d'exemples et d'entrainer de nouveau l'algorithme d'apprentissage afin d'en améliorer les performances. Pour cela, on suit le processus suivant (cf. figure 5.8) :

1. On sélectionne dans l'arborescence des *errors name* et des *root cause*, la *root cause* que l'on souhaite mettre à jour.
2. On sélectionne les motifs caractéristiques de la *root cause* dans les exemples ajoutés via le Pattern Selector.

5.4 Dimensionnement de la solution

Contrairement à l'étude réalisée en partie 4.3, on ne désire pas mesurer les performances intrinsèques de l'algorithme, mais plutôt l'influence du facteur humain sur celle-ci. On s'intéresse notamment à l'impact qu'a l'évolution de la taille de la région de sélection du Pattern Selector (cf. partie 5.2.1). En effet, cette variable dépend de la forme du motif, mais également de l'appréciation de l'utilisateur (quand commence le motif, quand se termine-t-il ?).

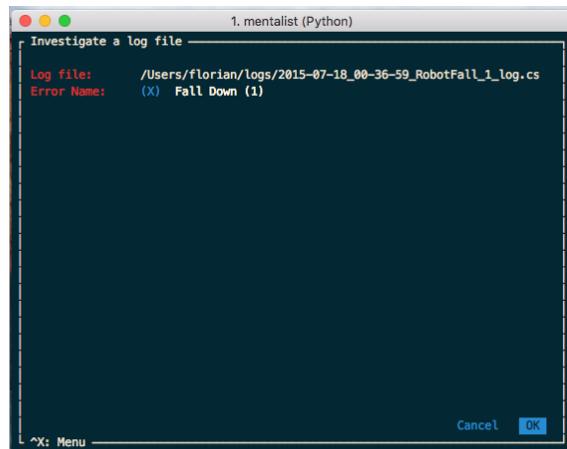
Afin de quantifier cette influence, on effectue plusieurs fois la création de la couche *root cause* "frottement des freins de la hanche" en augmentant à chaque fois la taille de la région de sélection. On observe la variation de la précision à chaque itération sur le graphique de la figure 5.10

Au regard des valeurs obtenues, on en déduit que l'algorithme est plus performant lorsque la région de sélection est petite. Or, le but est également de sélectionner le plus précisément possible le motif caractéristique d'une *root cause*. Il faut donc analyser chaque situation au cas par cas, en gardant en tête ces deux contraintes. Par exemple, si on souhaite apprendre à notre algorithme à reconnaître une région ayant une taille de 50 échantillons, il sera peut-être plus judicieux d'apprendre l'algorithme à reconnaître seulement une partie du motif (de 30 échantillons environ).

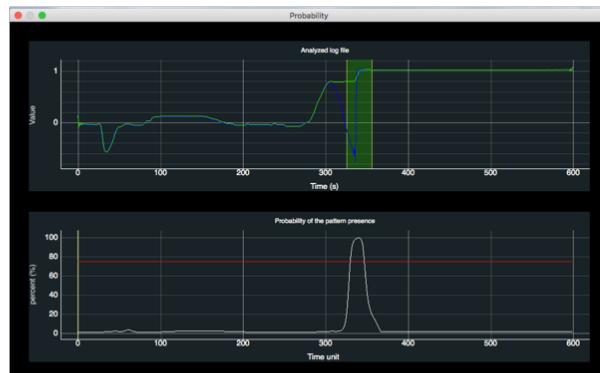


FIGURE 5.6 – Nouvelle root cause.

E.1



E.2



E.3

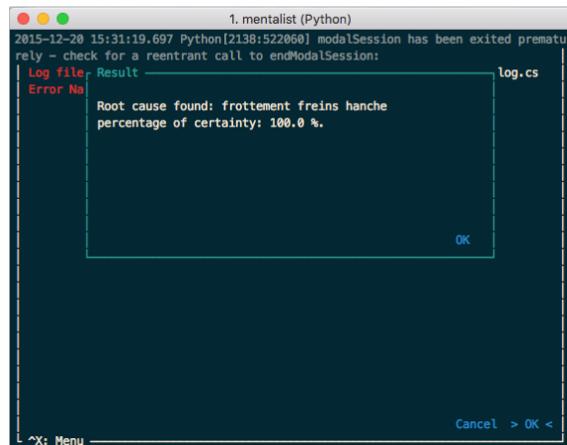
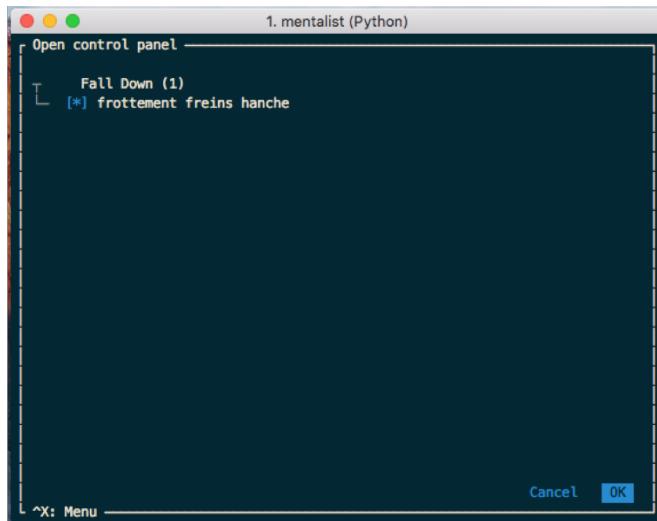


FIGURE 5.7 – Investigation d'un fichier log.

E.1



E.2

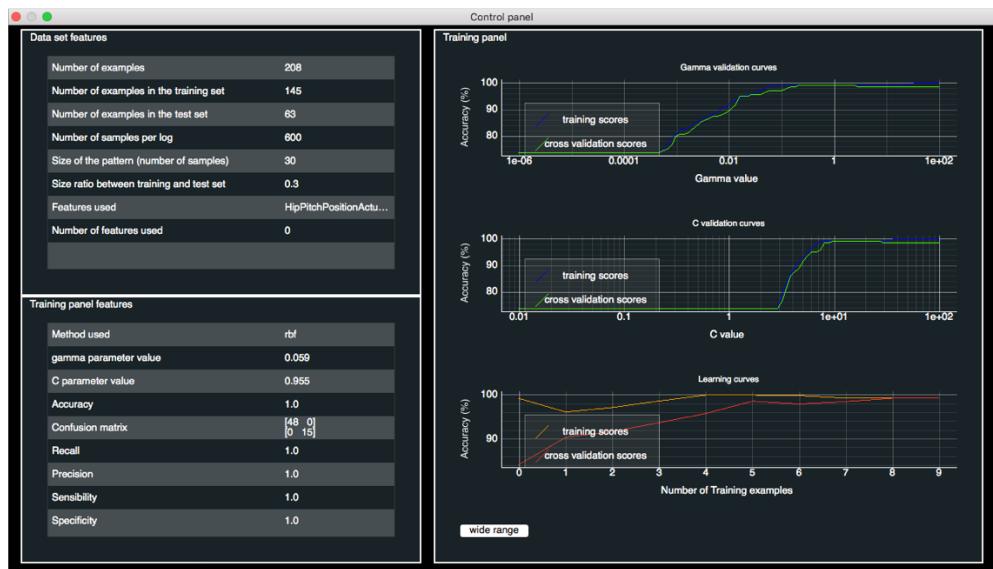
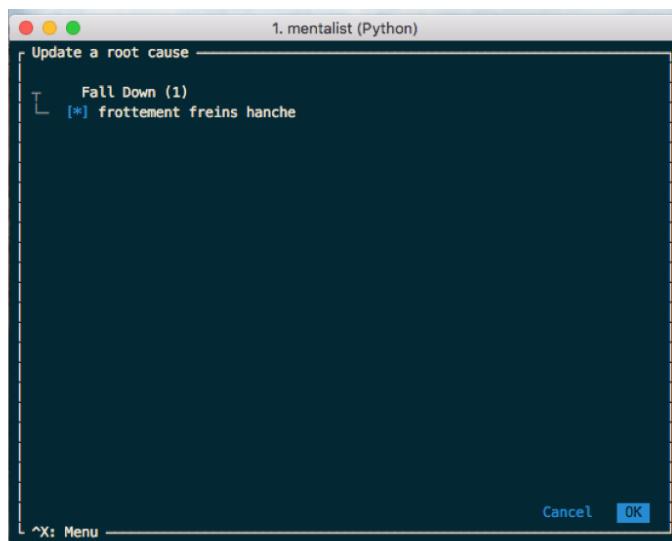


FIGURE 5.8 – Analyse des performances d'une couche root cause.

E.1



E.2

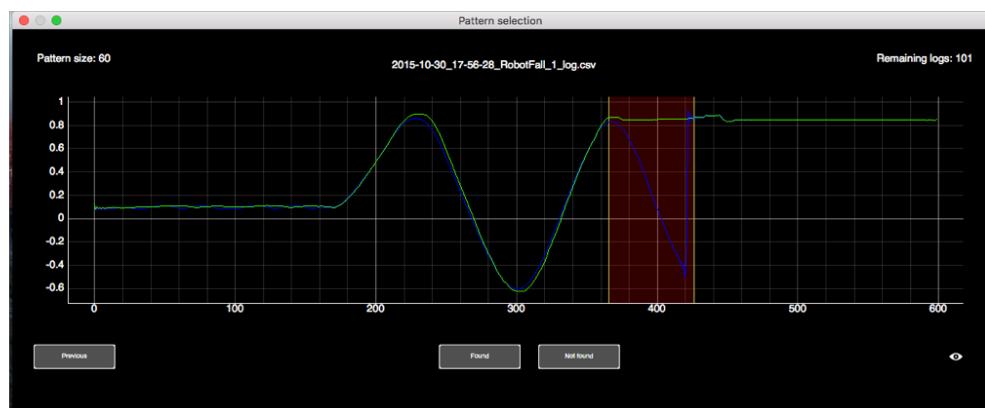


FIGURE 5.9 – Mise à jour d'une root cause.

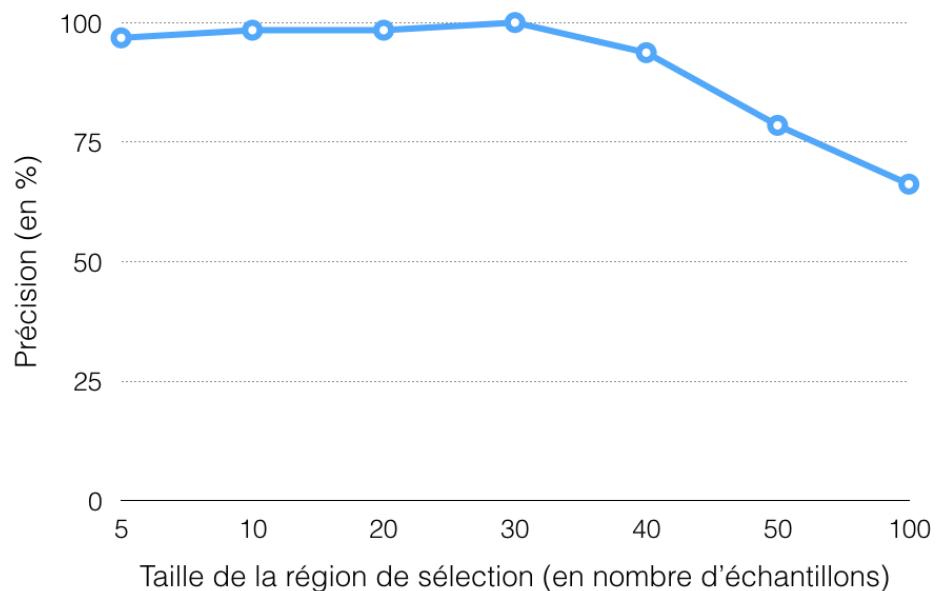


FIGURE 5.10 – Évolution de la précision de l'algorithme en fonction de la taille de la région de sélection. On observe qu'entre une taille de 10 et 30 échantillons, la précision de l'algorithme augmente légèrement. A partir de 30 échantillons, la précision de l'algorithme diminue.

Chapitre 6

Conclusion

J'ai eu la chance de pouvoir réaliser mon stage de fin d'études au sein d'Aldebaran sous la tutelle de M. Emmanuel Nalepa, chef de l'équipe Qualification Hardware Pepper. Cette opportunité m'a permis de bénéficier d'une première expérience dans le monde du Machine Learning, de la qualification et d'acquérir un ensemble de techniques indispensables à leurs mise en place. Il s'agissait ici d'automatiser le processus d'investigation permettant de déterminer l'origine d'une erreur durant le Filtering Test. Ce test vise à stresser l'ensemble des parties mécaniques du robot Pepper en fin de chaîne de production, afin de révéler un maximum de problèmes avant d'envoyer le produit chez le client.

Dans un premier temps, je me suis familiarisé avec les théories mathématiques qui fondent le Machine Learning. J'ai mis en pratique plusieurs des différentes méthodes algorithmiques existantes afin d'en étudier leurs fonctionnement, leurs champs d'applications et les possibilités que celles-ci offraient au regard de notre problématique. J'ai ensuite comparé ces différentes possibilités et émis un choix sur l'une d'entre elles : on effectue de l'apprentissage automatique supervisé en s'appuyant sur l'algorithme *Support Vector Machine* (SVM). Dans un second temps, j'ai mis en place l'architecture fonctionnelle du système d'automatisation des investigations, en prenant en compte les contraintes imposées par les outils déjà mis en place, comme par exemple la structure des données générées lors de l'apparition d'une erreur durant le Filtering Test.

Enfin, j'ai conçu des outils informatiques permettant d'utiliser le plus simplement possible les algorithmes du Machine Learning, dans le but de répondre au mieux à la problématique.

Sur le plan technique, ce stage a été pour moi plus que bénéfique. Grâce à la nature pluridisciplinaire du sujet, j'ai pu mettre en application mes connaissances dans plusieurs domaines et assimiler de nouvelles aptitudes dans des disciplines là aussi variées. Sur le plan humain, j'ai eu la chance d'être conseillé par un tuteur faisant preuve de beaucoup de pédagogie et de travailler dans un cadre agréable grâce à la bonne humeur de mon équipe.

Bibliographie

- [1] Aldebaran. Aldebaran nao documentation website, 2012.
- [2] Aldebaran. Aldebaran pepper documentation website, 2012.
- [3] Aldebaran. Aldebaran romeo documentation website, 2012.
- [4] Aldebaran. Aldebaran naoqi documentation website, 2012.
- [5] Aldebaran. Aldebaran choregraph documentation website, 2012.
- [6] Aldebaran. Aldebaran sdk documentation website, 2012.
- [7] Google. Google deep dream, neural network for pattern recognition in pictures, 2014.
- [8] Google. Tensorflow, the opensource machine learning library of google, 2015.
- [9] Python Software Foundation. Python programming language, 2014.
- [10] INRIA. scikit learn, machine learning in python, 2014.
- [11] INRIA. Inria, institut national de recherche en informatique et en automatique, 2014.
- [12] npyscreen. npyscreen, 2014.