

AUTOMATISATION DE L'ANALYSE D'INCIDENTS PAR L'UTILISATION DU MACHINE LEARNING



Florian LEPONT

M. Emmanuel NALEPA

Hiver 2015

Remerciements

Je tiens tout d'abord à remercier l'entreprise ALDEBARAN de m'avoir accueilli dans le cadre de mon stage de fin d'études, au sein de l'équipe «Qualification Hardware Pepper». Je remercie tout particulièrement M. Emmanuel Nalepa de m'avoir permis de participer à ce projet captivant et formateur, m'offrant ainsi la possibilité d'étoffer mes connaissances et mes aptitudes dans de nombreux domaines. Sa disponibilité, sa pédagogie et son expérience ont été des atouts essentiels à mon enrichissement technique. J'adresse également mes remerciements aux personnes m'ayant proposées leur aide, ainsi qu'à tous les membres de mon équipe pour leur bonne humeur et sympathie.

Résumé

Mon stage ingénieur, réalisé dans le cadre de ma cinquième année de formation à l'École Nationale d'Ingénieurs de Brest (ENIB), s'est déroulé au sein du département "Qualification Hardware Pepper (QWP) de l'entreprise Aldebaran. La société Parisienne s'est fait connaître dans le monde des nouvelles technologies et de la robotique humanoïde grâce au développement de son premier produit, "Nao". A l'origine, le robot se prédestine à l'univers de la recherche et aux universités. La société cherche aujourd'hui à conquérir de nouveaux marchés en offrant des produits et des services au monde de l'entreprise et aux particuliers. Cela se traduit notamment par le développement d'un tout nouveau produit : "Pepper".

Cette extension du marché s'accompagne d'une montée en puissance de la fabrication de robots "Pepper". Cela induit le développement d'une nouvelle génération d'outils de production et de post-production. Un des dispositifs mis en place est le "Filtering Test" : à la fin de la chaîne de production, les robots sont soumis à une série de tests qui visent à mettre à l'épreuve leurs différentes parties mécaniques et électroniques. Lorsqu'une erreur est détectée, les différentes données du robot sont enregistrées (e.g. température des fusibles, valeurs de l'accéléromètre, etc.). Afin de déterminer qu'elles sont les causes qui ont entraîné l'apparition de l'anomalie sur le robot, chaque donnée est étudiée minutieusement et des hypothèses sont émises. Cette tâche dite d'investigation avère laborieuse, il y'a donc un désir d'automatiser le processus.

Le but de ma présence au sein d'Aldebaran est donc de répondre à ce besoin. En s'appuyant sur l'utilisation de méthodes d'apprentissage automatique (Machine Learning), j'ai donc mis au point un algorithme capable de déterminer automatiquement (après une phase d'apprentissage) les causes ayant entraîné l'apparition d'anomalies sur Pepper. La mise au point de cet outil a été réalisée en trois temps :

1. auto-formation à l'apprentissage automatique et maîtrise des outils de développement.
2. conception et développement de l'algorithme.
3. industrialisation du produit, c'est à dire en simplifier l'utilisation et le robustifier.

Ce rapport de stage présente les différentes recherches effectuées, ainsi que les travaux de développement réalisés pour répondre au mieux à la problématique.

Sommaire

1	Entreprise	7
1.1	Histoire	7
1.1.1	Le premier robot, Nao	7
1.1.2	La famille s'agrandit	7
1.2	Les produits	7
1.2.1	Nao	8
1.2.2	Pepper	9
1.2.3	Roméo	9
1.2.4	Le système d'exploitation NAOqi	9
1.2.5	Plateforme de développement	10
2	Introduction	12
2.1	Présentation du produit	12
2.1.1	Les actionneurs	12
2.1.2	Les senseurs	13
2.2	Expression du besoin	13
2.2.1	Hierarchisation des erreurs	13
2.2.2	Exemple d'analyse d'une anomalie	14
2.3	Solution proposée	15
3	Le Machine Learning	17
3.1	Généralités sur le Machine Learning	17
3.1.1	Définition et principe général du Machine Learning	17
3.1.2	Les exemples	19
3.1.3	La décision	20
3.1.4	Le modèle	20
3.2	Les différents algorithmes d'apprentissage supervisé	22
3.2.1	La régression linéaire uni-variable	22
3.2.2	La régression linéaire multi-variable	24

3.2.3	La régression logistique	27
3.2.4	SVM -Support Vector Machine-	31
3.2.5	Périmètres d'utilisation de la régression logistique et du SVM	32
3.2.6	Autres algorithmes pour l'apprentissage supervisé	32
4	Automatisation du processus d'investigation	37
4.1	Architecture High Level du système proposé	37
4.1.1	Les exemples	39
4.1.2	Parallèle avec l'exemple de la prévision saisonnière et mise en évidence du problème de l'évolution temporelle	41
4.1.3	Le modèle d'apprentissage	41
4.1.4	La décision	41
4.2	Reconnaissance de motifs	42
4.2.1	Différentes approches étudiées	42
4.2.2	Concept	44
4.3	Étendre le problème à plusieurs dimensions	44
4.4	Difficultés notoires rencontrées	44
4.5	Performances de la solution	44
4.5.1	Optimisation des paramètres du SVM	44
4.5.2	Matrices de confusion	45
4.5.3	Courbes d'apprentissage	45
5	Industrialisation du produit	46
5.1	API	46
5.1.1	Pré-traitement et traitement des données	46
5.1.2	Sélection des motifs lors du pré-traitement des données	47
5.1.3	Format des données en sortie du pré-traitement des données	47
5.1.4	Module Marchine Learning et librairie scikit-learn	48
5.2	Outils graphiques	48
5.2.1	Pattern selector	48
5.2.2	Probability Visualization	49
5.2.3	Control panel	50
5.3	Utilisation suggérée des outils pour répondre au problème d'investigation du frottement des freins de la hanche	50
5.3.1	Menu principal	51
5.3.2	Nouvelle error name	52
5.3.3	Nouvelle root cause	52
5.3.4	Investiguer un fichier log	53
5.3.5	Analyse des performances d'une root cause	53
5.3.6	Mise à jour d'une root cause	54

5.4	Dimensionnement de la solution	54
6	Conclusion	56

Table des figures

1.1	Le robot humanoïde Nao.	8
1.2	Le robot humanoïde Pepper.	9
1.3	Le robot humanoïde Roméo.	11
2.1	Répartition des actionneurs de Pepper	13
2.2	Analyse d'une anomalie : accéléromètre	16
2.3	Analyse d'une anomalie : les genoux	16
2.4	Analyse d'une anomalie : la hanche	16
3.1	Schéma fonctionnel haut niveau du Machine Learning	18
3.2	Schéma fonctionnel haut niveau du Machine Learning, l'exemple de la pré- vision saisonnière	19
3.3	Comparaison d'un apprentissage supervisé et non supervisé dans le cadre de l'exemple "apprendre aux humains"	21
3.4	Comparaison d'un apprentissage supervisé et non supervisé dans le cadre de l'exemple "prévisions saisonnières"	22
3.5	Comparaison par l'exemple de la régression et de la classification	23
3.6	évolution du prix de l'immobilier en fonction de la surface	24
3.7	Régression linéaire, optimisation de la fonction coût	25
3.8	Régression linéaire, calcul des paramètres de l'hypothèse	26
3.9	Classification via régression linéaire	28
3.10	Fonction sigmoïde	28
3.11	Exemple d'une régression logistique	29
3.12	fonctions $-\log(h_\theta(x))$ et $-\log_\theta(1 - h(x))$	31
3.13	SVM : cas simple d'une régression logistique avec une hypothèse linéaire	32
3.14	SVM : optimisation du calcul de l'hypothèse par l'introduction de marges	33
3.15	Exemple d'un problème de classification linéaire	33
3.16	Exemple d'un problème de classification non linéaire	33
4.1	Création des couches root cause	38
4.2	Utilisation de la couche error name	39

4.3	Synoptique d'une couche root cause	40
4.4	Calcul des caractéristiques simplifiées	43
4.5	Comparaison de deux caractéristiques	44
4.6	Considérer chaque unité de temps comme une feature : exemple	45
5.1	Interface graphique du pattern selector	49
5.2	Interface graphique du pattern selector en mode étendu	50
5.3	Interface graphique du probability visualizator	51
5.4	Interface graphique du control pattern	51
5.5	Menu principal	52
5.6	Nouvelle root cause	53
5.7	Investigation d'un fichier log	53
5.8	Analyse des performances d'une couche root cause	54
5.9	Mise à jour d'une root cause	54
5.10	Evolution de la précision de l'algorithme en fonction de la taille de la région de sélection	55

Liste des tableaux

1.1	Caractéristiques technique de Nao	8
1.2	Caractéristiques technique de Pepper	10
1.3	Caractéristiques technique de Roméo	11
2.1	Les différents capteurs de Pepper	14
2.2	Déroulement d'un Filtering test	15
2.3	Exemple d'un error name et ses root cause	15
3.1	Comparaison des différents modèles d'apprentissage	34
3.2	Comparaison des différentes catégories d'apprentissage supervisé	35
3.3	parc immobilier	35
3.4	parc immobilier multi-variable	35
3.5	Périmètre d'utilisation de la régression logistique et le SVM	36

Chapitre 1

Entreprise

1.1 Histoire

Aldebaran (anciennement Aldebaran Robotics) est une société Française de robotique humanoïde fondée en 2005 par Bruno Maisonnier.

1.1.1 Le premier robot, Nao

Constituée au départ d'une équipe de douze collaborateurs, la toute jeune entreprise se fixe comme objectif de développer des robots humanoïdes et de les commercialiser au grand public en tant que "nouvelle espèce bienveillante à l'égard des humains". Après trois années de recherche et développement, la société dévoile en 2008 son tout premier produit : Nao. La participation du robot humanoïde à divers évènements internationaux, comme par exemple la RoboCup ou encore l'Exposition Universelle de Shanghai en 2010 participe à sa popularisation auprès des laboratoires de recherche, des universités et des développeurs. Une seconde génération de robot Nao apparait en 2011 (Nao Next Gen). L'entreprise dévoile durant la même période le projet Roméo dont l'objectif est de créer un véritable robot d'assistance à la personne, en partenariat avec différents acteurs de la recherche.

1.1.2 La famille s'agrandit

Lors de l'année 2012, Aldebaran Robotics est racheté par SoftBank, société spécialisée dans le commerce électronique au Japon, et prend le nom d'Aldebaran (suppression du terme "Robotics"). Débute alors la conception d'un tout nouveau produit, le robot humanoïde Pepper. Dévoilé au grand public en 2014, il est dans un premier temps vendu au Japon auprès des entreprises. Les premiers clients à en bénéficier seront les magasins de téléphonie mobile du groupe SoftBank. Les ventes s'ouvrent par la suite aux particuliers Japonais. La société compte aujourd'hui plus de 400 collaborateurs et poursuit le développement de ses trois produits afin de les améliorer et de conquérir de nouveaux marchés (Europe , Chine et États-Unis).

1.2 Les produits

Aldebaran commercialise à ce jour deux produits : Nao et Pepper. Le robot Roméo est une plateforme de recherche.

1.2.1 Nao

Nao est un robot humanoïde de 58 cm de hauteur. Les publics ciblés par le produit sont essentiellement les laboratoires de recherche et le monde de l'éducation (des écoles primaires jusqu'aux universités). Il est actuellement le produit le plus connu de l'entreprise auprès du grand public.



FIGURE 1.1 – Le robot humanoïde Nao.

Caractéristiques techniques Caractéristiques techniques de la dernière version de Nao (V5, Évolution) tableau 1.1.

Caractéristiques générales	
Dimensions	574 x 311 x 275 mm
Masse	5,4 kg
Degrés de liberté	25
Processeur	Intel Atom Z530 1.6 GHz RAM : 1GB Mémoire flash : 2GB Micro SDHC : 8 GB
Système d'exploitation	Middleware Aldebaran NAOqi basé sur un noyau Linux
Connectivité	Wi-Fi, Ethernet, USB
Batterie	Autonomie : 90 minutes en usage normal Energie : 48.6 Wh
Vision	Deux caméras frontales 2D, 1220p, 30ips
Audio	Sortie : 2 haut-parleurs stéréo 4 microphones directionnels moteur de reconnaissance vocale Nuance
Capteurs	2 capteurs infra-rouges, résistance sensible à la pression, centrale inertielle, 2 systèmes sonars, 3 surfaces tactiles

TABLE 1.1 – Caractéristiques techniques de la dernière version commerciale de Nao [?]

1.2.2 Pepper

Dernier né d'Aldebaran, le robot Pepper est conçu pour vivre au côté des humains. Imaginé au départ pour accompagner et informer les clients dans les magasins de téléphonie du groupe japonais SoftBank, l'entreprise cherche à présent à placer son produit chez les particuliers. Le robot reprend la structure software et hardware de Nao. Contrairement à son compagnon Nao, Pepper se déplace non pas grâce à une paire de jambes, mais via trois roues omnidirectionnelles, facilitant son déplacement. A noter également que celui-ci est équipé d'une tablette tactile sur son torse afin de faciliter les interactions Homme-Machine.




FIGURE 1.2 – Le robot humanoïde Pepper.

Caractéristiques techniques Caractéristiques techniques de la dernière version commerciale de Pepper (V1.7) tableau 1.2.

1.2.3 Roméo

Roméo est un nouveau type de robot d'accompagnement et d'assistance à la personne. Cette plateforme de recherche est soutenue par Aldebaran ainsi que d'autres partenaires universitaires et laboratoires de recherche (e.g. INRIA, LAAS-CNRS, ISIR, ENSTA, Telemcom, etc.). Il s'agit pour l'instant d'un prototype et sert principalement de plateforme de tests pour les prochaines innovations majeures d'Aldebaran (e.g. yeux mobiles, système vestibulaire, etc.).

Caractéristiques techniques Caractéristiques techniques de la dernière version commerciale de Roméo (V2) tableau 1.3.

1.2.4 Le système d'exploitation NAOqi

NAOqi est le système d'exploitation commun aux 3 robots d'Aldebaran. Il se base sur la distribution de Linux Gentoo et contient plusieurs API's afin de commander et contrôler les robots [?].

NAOqi Core : Gestion de l'ensemble des fonctions de base des robots (e.g. mémoire, "autonomous Life", comportements du robots, etc.).

NAOqi Motion : Gestion des mouvements des robots.

Caractéristiques générales	
Dimensions	1210 x 480 x 425 mm
Masse	28 kg
Degrés de liberté	17
Processeur	Intel Atom E3845 1.91 GHz RAM : 4 GB Mémoire flash : 8 GB MICRO SDHC : 16Go
Système d'exploitation	Middleware Aldebaran NAOqi, basé sur un noyau Linux
Connectivité	Wi-Fi, Ethernet, USB
Batterie	Énergie : 795 Wh
Vision	2 caméras 2D 1 caméra 3D
Audio	3 microphones directionnels moteur de reconnaissance vocale Nuance
Connectivité	Wi-Fi, Ethernet
Capteurs	6 lasers, 2 capteurs infra-rouges, 1 système sonar, résistance sensible à la pression, 2 centrales inertielles, 3 surfaces tactiles

TABLE 1.2 – Caractéristiques techniques de la dernière version commerciale de Pepper [?]

NAOqi Audio : Gestion de la partie audio des robots.

NAOqi Vision : Gestion de la partie vidéo des robots

NAOqi People Perception : Ce module est utilisé pour détecter la présence de personnes autour du robot.

NAOqi Sensors : Gestion de l'ensemble des senseurs équipant les robots.

1.2.5 Plateforme de développement

Les robots sont fournis avec une plateforme de développement.

Choregraphe : Il s'agit d'un outil de programmation graphique basé sur une interface prenant la forme de schémas bloc [?]. Il permet de façon simple d'interagir avec le robot et de concevoir des applications pour le robot. Il comporte également un environnement de simulation 3D permettant aux développeurs de tester leurs applications sans même posséder un robot. Le logiciel permet également de disposer d'un retour visuel sur ce que le robot perçoit (e.g. vidéo issues des caméras, données des moteurs, etc.)

Kit de développement (SDK) : Il permet de développer des applications pour les robots via plusieurs langages de programmation : C++, Python et Java [?].




FIGURE 1.3 – Le robot humanoïde Roméo.

Caractéristiques générales	
Hauteur	1467 mm
masse	37 kg
Processeur	Intel ATOM Z530 1.6 GHz RAM : 1 GB Mémoire flash : 2 GB MICRO SDHC : 8 Go
Système d'exploitation	Middleware Aldebaran NAOqi, basé sur un noyau Linux
Connectivité	Wi-Fi, Ethernet
Batterie	Énergie : 795 Wh
Vision	4 caméras 2D 1 caméra 3D
Audio	3 microphones directionnels moteur de reconnaissance vocale Nuance
Connectivité	Wi-Fi, Ethernet
Capteurs	6 lasers, 2 capteurs infra-rouges, 1 système sonar, résistance sensible à la pression, 2 centrales inertielles, 3 surfaces tac- tiles

TABLE 1.3 – Caractéristiques techniques de la dernière version de Roméo
[?]

Chapitre 2

Introduction

2.1 Présentation du produit

On présente ici de manière succincte l'architecture Hardware du robot Pepper afin de se familiariser avec les différents éléments du système avec lesquels nous serons susceptibles de travailler durant la mise en œuvre de ce projet.

2.1.1 Les actionneurs

Les moteurs

Le robot Pepper est constitué de 20 moteurs dont il est possible de contrôler la position et la rigidité (figure 2.1)

Tête : 2 moteurs pour les mouvements de lacet (HeadYaw) et de tangage (HeadPitch)

Bras : 4 moteurs par bras, répartis de la manière suivante :

Épaule : 2 moteurs pour les mouvements de tangage (ShoulderPitch) et de roulis du bras (ShoulderRoll).

Coude : 2 moteurs pour les mouvements de lacet (ElbowRoll) et de lacet (ElbowYaw) de l'avant-bras.

Main : 1 moteur pour le mouvement de lacet du poignet (WristYaw) et 1 pour le mouvement d'ouverture et de fermeture de la main (Hand).

Hanche : 2 moteurs pour le mouvement de roulis (HipRoll) et de tangage (HipPitch) du buste.

Genoux : 1 moteur pour le mouvement de tangage (KneePitch) du haut du corps.

Roues : 3 moteurs pour les mouvements en rotation de chacune des 3 roues omnidirectionnelles (WheelB, WheelFR et WheelFL).

Les Leds

Les Leds placées sur les épaules de Pepper, autour de ses yeux et de ses oreilles permettent d'obtenir un certain nombre d'informations sur son état. Par exemple, des Leds bleues en rotations autour des yeux indiquent que le robot écoute, des Leds sur les épaules clignotant lentement signifient que le robot démarre.




FIGURE 2.1 – Répartition des actionneurs de Pepper

2.1.2 Les senseurs

Pepper intègre également une multitude de capteurs. Certains d'entre eux sont utilisés afin de s'assurer du bon comportement des parties électroniques et mécaniques du robot, ou pour réaliser du contrôle-commande. D'autres senseurs sont en revanche intégrés sur le robot afin que l'utilisateur interagisse avec (tableau 2.1).

2.2 Expression du besoin

L'extension du marché visée par Aldebaran pour Pepper s'accompagne d'une montée en puissance de la production. Afin de la guider, des outils de vérification des produits en fin de ligne de production sont mis en place. Parmi eux, on retrouve le "Filtering Test" (c.f. tableau 2.2) qui consiste à réaliser une série de tests durant six heures. Il vise notamment à stresser l'ensemble des parties mécaniques du robot afin de faire ressortir d'éventuelles erreurs. Si une anomalie survient lors du déroulement du test, les différentes données relatives à l'état des systèmes mécaniques et électroniques du robot sont enregistrées dans un fichier journal (e.g. température des fusibles, valeur des accéléromètres, etc.). Afin d'identifier les causes de l'apparition de problèmes sur Pepper, un certain nombre d'hypothèses sont émises à partir de l'étude des données en sortie du système.

2.2.1 Hiérarchisation des erreurs

Pour gérer au mieux les anomalies, celles-ci sont hiérarchisées en deux catégories : les "errors name" et les "root causes".

Error name Cela correspond à l'erreur visible, i.e. la conséquence liée à une anomalie hardware ou software. Cela peut correspondre par exemple à la chute du robot.

root cause Il s'agit de l'anomalie en elle même, i.e. la cause ayant entraînée l'apparition d'une "error name". Si l' "error name" est la chute d'un robot, la "root cause" peut par exemple correspondre à la détérioration d'un engrenage de la hanche.

En suivant la logique exprimée par ces définitions, une "error name" peut être constituée d'une ou plusieurs "root cause".

Senseur	position	description
Capteurs liés aux actionneurs	sur les moteurs	Chaque moteur du robot est lié à 3 senseurs, donnant des informations sur la valeur du courant délivrée au moteur (A), la température du moteur (C) et la position du moteur.
Senseurs tactiles	1 sur chaque main, 1 sur la tête	Permet à l'utilisateur d'interagir avec le robot en le touchant.
Les boutons	1 bouton poussoir sur le buste, 3 bumpers sur la base	Les bumpers permettent au robot de détecter s'il rencontre un obstacle à proximité directe. Le bouton du buste permet quant à lui de modifier le mode dans lequel est le robot (autonome, veille).
Centrale inertielle	1 dans le buste, 1 dans la base	Informe sur la position et l'orientation du robot, ainsi que la vitesse et l'accélération.
Sonars	2 sonars à l'avant et l'arrière de la base	Permet de détecter la présence d'un objet situé au delà de 65 cm du robot.
Capteurs batterie	batterie	Renseigne sur le courant et la tension délivrés, le pourcentage de charge et la température.
Capteurs infra-rouges	2 sur la base	Permet de détecter la présence d'un objet situé entre 0 et 50 cm du robot.
Lasers	6 lasers sur la base du robot	Permet de détecter la présence d'un objet

TABLE 2.1 – Les différents capteurs de l'architecture sensorielle de Pepper

2.2.2 Exemple d'analyse d'une anomalie

Observation

- Lors du déroulement du Filtering test, le robot tombe à $t = 16972$ secondes, soit lorsqu'il réalise une séquence de mouvements particulière appelée "Heat Behavior". Les valeurs retournées par l'accéléromètre selon l'axe Z attestent de cette chute.
- On analyse les données liées aux systèmes mécaniques et électroniques du robot pouvant avoir une relation directe ou indirecte avec sa chute. Lorsque l'on étudie la vitesse de rotation du moteur de la hanche, on remarque qu'aux environs de $t = 16970$ secondes (c'est-à-dire 2 secondes avant la chute du robot), l'information fournie par le senseur ne suit plus la commande envoyée au moteur (figure 2.3). On remarque également que le senseur du genou suit correctement la commande du moteur (figure 2.4).
- On observe également une augmentation anormale du courant dans le moteur de l'articulation.

Hypothèse émise

Lors de l'exécution de l'animation "Heat Behavior", le robot est amené à réaliser des mouvements amples au niveau de sa hanche, causant un certain stress sur cette partie mécanique. Lorsque l'engrenage de la hanche arrive près de sa butée mécanique, celui-ci ne parvient pas à atteindre sa position zéro. Ce phénomène occasionne une augmentation du courant délivré dans le moteur de l'articulation, ce qui entraîne le passage en mode protégé du robot et a pour effet de désactiver sa rigidité. Sans cette rigidité, Pepper tombe

5 étapes successives sur 6 heures de test			
Activité	Durée (en minutes)	Temps cumulé (en minutes)	Description
Test 1 : succession de divers actions effectuées 40 fois durant les 10 heures			
Intro, Danse, Outro	6 à 7	6 à 7	Réalisation des mouvements d'introduction et d'outro
Cycles de WakeUp, Rest	3 à 4	10	Passage successif en mode autonome et veille
Faux dialogues	2	12	Réalisation des mouvements effectués lors de dialogues
Rest	3	15	Réalisation des mouvements lors du passage en mode Rest
Test 2 : enchainement de 8 danses répétées 5 fois durant les dix heures			

TABLE 2.2 – Déroulement d'un Filtering test




TABLE 2.3 – Exemple d'un error name et ses root cause

("error name"). Une étude plus poussée nous apprendra que la "root cause" du problème correspondait à une dent cassée au niveau de l'engrenage de la hanche.

2.3 Solution proposée

De part la quantité d'informations à analyser, cette tâche d'analyse peut rapidement devenir rébarbative, d'où le souhait d'automatiser ce processus d'investigation. La variabilité des types de données nous empêche de réduire le nombre d'informations à analyser à de simples caractéristiques communes (e.g. moyenne, écart type, etc.). On s'appuiera donc sur des approches algorithmiques plus poussées, en utilisant notamment des méthodes d'apprentissages automatiques (plus connues sous le terme anglais de Machine Learning). La multiplicité des modèles englobés dans cette discipline nous permettra de répondre au mieux à la problématique.




FIGURE 2.2 – Analyse d'une anomalie : accéléromètre




FIGURE 2.3 – Analyse d'une anomalie : les genoux




FIGURE 2.4 – Analyse d'une anomalie : la hanche

Chapitre 3

Le Machine Learning

3.1 Généralités sur le Machine Learning

Le Machine Learning (traduire par apprentissage automatique) est une ramification de l'intelligence artificielle. Son champ d'étude est vaste et en perpétuelle évolution. Les solutions offertes par cette discipline permettent d'étudier toute sorte de données et d'automatiser une multitude de systèmes. L'apprentissage automatique rencontre un succès croissant qui est corrélé avec l'essor des nouvelles technologies et l'automatisation de l'analyse de volumes conséquents de données utilisateurs (Big Data). Les applications sont multiples, en voici quelques exemples :

- Algorithmes des moteurs de recherches (Google Deep Dream[?], Google TensorFlow [?])
- Analyse boursière
- Analyse de rapports d'erreurs
- Reconnaissance vocale, biométrie, reconnaissance d'écriture
- Robotique (vision, mouvements, prise de décision, etc.)
- Neurosciences

3.1.1 Définition et principe général du Machine Learning

Le champ d'étude et d'application du Machine Learning étant immense, on propose de redéfinir cette notion en l'adaptant à la résolution de notre problématique (i.e. automatiser l'analyse d'incidents révélés lors du filtering test). On offre ici deux définitions de l'apprentissage automatique : une première dite "High Level" qui le caractérise de manière générale et une seconde qui reflète sa dimension algorithmique.

High Level : Le Machine Learning permet à un système d'évoluer grâce à un processus d'apprentissage et ainsi de remplir des tâches qu'il est difficile, voire impossible, de remplir par d'autres moyens algorithmiques plus classiques.

Mathématique Le Machine Learning fournit les outils pour prédire une/des donnée(s) de sortie Y à partir des données d'entrée X via un processus d'apprentissage.

Au regard des deux définitions stipulées ci-dessus, on peut représenter le principe de base de l'apprentissage automatique sous la forme d'un schéma bloc (figure 3.1).

L'apprentissage automatique peut être vu dans sa globalité comme un processus composé de deux étapes successives :

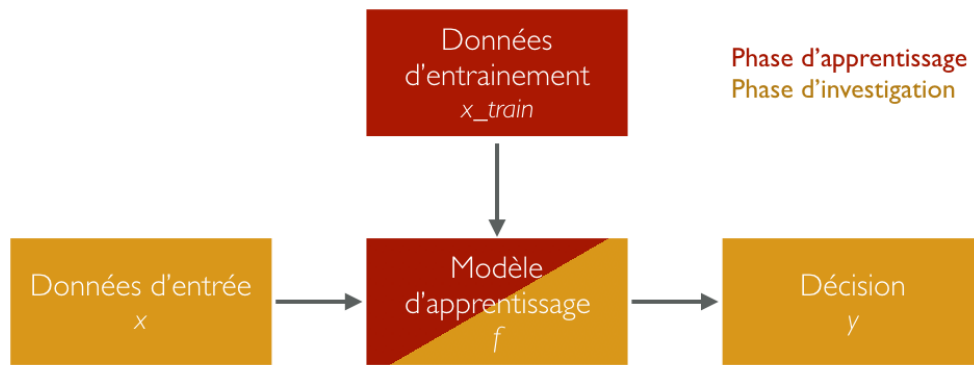


FIGURE 3.1 – Schéma fonctionnel haut niveau du Machine Learning

Apprentissage (a) Un ensemble de données est mis à l'entrée du système lors de la phase d'apprentissage (x_{train}).

(b) A partir de ces informations, le système (f) apprend - s'entraîne- afin d'être par la suite en capacité de prendre une décision vis à vis de la tâche qui lui sera demandée.

Prise de décision (a) On a en entrée du système une ou des donnée(s) brutes (x).

(b) Cette donnée est traitée et analysée par le système.

(c) En sortie, une décision (y) est prise quant à la tâche demandée grâce à l'apprentissage effectué en amont.

Un exemple concret

Afin d'exposer de manière plus concrète le processus fonctionnel haut niveau d'un algorithme d'apprentissage, on soumet l'exemple suivant :

On cherche à déterminer la période de l'année à laquelle on se trouve actuellement (i.e. printemps, été, automne ou hiver) grâce à l'analyse de l'humidité, la température et la pression atmosphérique d'aujourd'hui.

La première étape est d'entraîner notre système afin que celui-ci soit en mesure de prendre une décision vis-à-vis des données qu'on lui présentera en entrée (i.e. l'humidité, la température et la pression atmosphérique d'aujourd'hui).

Une fois le système entraîné, on attend de celui-ci ce type de comportement :

On présente en entrée du système une température de -2 degrés, une pression atmosphérique de 1030hPa et un taux d'humidité de 81%. La décision espérée est : hiver

On peut adapter le schéma fonctionnel haut niveau du Machine Learning à notre exemple figure 3.2.

Lexique

Pour caractériser et désigner plus précisément les différents éléments de notre système, on présente ci-dessous le champs lexical rattaché au Machine Learning :

Features Le type de données présentées en entrée.

La température, la pression atmosphérique et l'humidité.

Echantillons ou exemples Les données permettant d'entraîner le système (x_{train}).

Des échantillons de température, pression atmosphérique et humidité pris à différentes périodes de l'année.

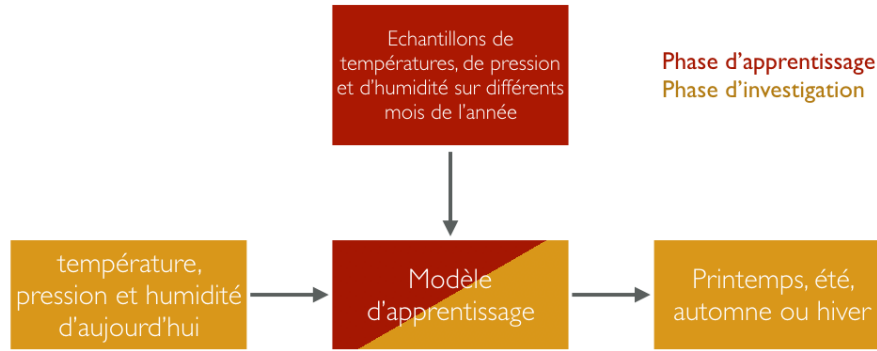


FIGURE 3.2 – Schéma fonctionnel haut niveau du Machine Learning, l'exemple de la prévision saisonnière

Modèle d'apprentissage Le cœur du système décisionnel (f).

Décision La sortie ou réponse du système (y)

Printemps, été, automne ou hiver.

3.1.2 Les exemples

Les exemples sont les données utilisées pour entraîner mon algorithme d'apprentissage. On parle également d'échantillons. Ils sont regroupés en "features" (terme anglais, traduire par caractéristiques). Pour reprendre l'exemple cité précédemment (partie 3.1.1), nos données sont regroupées en 3 features : la température, l'humidité et la pression atmosphérique. Les exemples sont donc structurés de la manière suivante :

$$\begin{array}{c}
 \text{Exemple}_1 \\
 \text{Exemple}_2 \\
 \text{Exemple}_3 \\
 \dots \\
 \text{Exemple}_n
 \end{array}
 \begin{pmatrix}
 \text{temperature}(^{\circ}\text{C}) & \text{humidite}(\%) & \text{pression}(\text{HPa}) \\
 -10 & 85 & 1023 \\
 15 & 80 & 1020 \\
 23 & 65 & 1015 \\
 \dots & \dots & \dots \\
 10 & 81 & 1032
 \end{pmatrix}
 \quad (3.1)$$

$$\begin{array}{c}
 \text{Exemple}_1 \\
 \text{Exemple}_2 \\
 \text{Exemple}_3 \\
 \dots \\
 \text{Exemple}_n
 \end{array}
 \begin{pmatrix}
 \text{temperature}(^{\circ}\text{C}) & \text{humidite}(\%) & \text{pression}(\text{HPa}) \\
 -10 & 85 & 1023 \\
 15 & 80 & 1020 \\
 23 & 65 & 1015 \\
 \dots & \dots & \dots \\
 10 & 81 & 1032
 \end{pmatrix}
 \quad (3.2)$$

Différents types d'exemples

Il existe deux types de données : les échantillons labellisés et non labellisés.

Pour reprendre l'exemple précédent (partie 3.1.1), on a les jeux de données suivants :

Données labellisées Les échantillons labellisés correspondent à des exemples corrélés à une sortie - un label - connue.

$$\begin{array}{c}
 \text{Exemple}_1 \\
 \text{Exemple}_2 \\
 \text{Exemple}_3 \\
 \dots \\
 \text{Exemple}_n
 \end{array}
 \begin{pmatrix}
 \text{temperature}(^{\circ}\text{C}) & \text{humidite}(\%) & \text{pression}(\text{HPa}) \\
 -10 & 85 & 1023 \\
 15 & 80 & 1020 \\
 23 & 65 & 1015 \\
 \dots & \dots & \dots \\
 10 & 81 & 1032
 \end{pmatrix}
 \begin{array}{l}
 \text{hiver} \\
 \text{automne} \\
 \text{ete} \\
 \\
 \text{printemps}
 \end{array}
 \quad (3.3)$$

On connaît la sortie qui correspond aux données d'entrée, i.e. que on sait à quelle période de l'année les échantillons ont été prélevés.

Données non labellisées Les échantillons non labellisés ne sont quant à eux pas corrélés à une sortie.

$$\begin{array}{c}
 \text{Exemple}_1 \\
 \text{Exemple}_2 \\
 \text{Exemple}_3 \\
 \dots \\
 \text{Exemple}_n
 \end{array}
 \begin{pmatrix}
 \text{temperature}(^{\circ}\text{C}) & \text{humidite}(\%) & \text{pression}(\text{HPa}) \\
 -10 & 85 & 1023 \\
 15 & 80 & 1020 \\
 23 & 65 & 1015 \\
 \dots & \dots & \dots \\
 10 & 81 & 1032
 \end{pmatrix}
 \begin{array}{l}
 ?? \\
 ?? \\
 ?? \\
 \\
 ??
 \end{array}
 \quad (3.4)$$

On ne connaît pas la sortie qui correspond aux données d'entrée, i.e. on *ne* sait *pas* à quelle période de l'année les échantillons ont été prélevés.

3.1.3 La décision

La sortie de notre système peut être également nommé décision. L'exemple partie 3.1.1, correspond au choix fait par l'algorithme entre les différentes saisons : printemps, été, automne et hiver.

Différents types de sorties

Il existe différents types de sortie : les sorties continues et discrètes.

Les sorties continues peuvent prendre n'importe quelle valeur.

$$y \in \mathbb{R}$$

Déterminer l'évolution de la température en fonction des échantillons enregistrés les mois précédents correspond à une sortie continue.

Les sorties discrètes ne peuvent prendre que des valeurs prédéterminées.

$$y \in 1, 2, 3, \dots, C$$

L'exemple partie 3.1.1 a une sortie discrète. En effet, la sortie ne peut prendre que des valeurs prédéterminées : printemps, été, automne et hiver.

3.1.4 Le modèle

Il existe différents types d'apprentissages. Le choix d'un modèle en particulier est influencé par le type d'exemples que l'on a en entrée du système et du type de décision que l'on souhaite obtenir en sortie. Nous nous intéresserons à différentes catégories d'apprentissages automatiques :

- Les apprentissages supervisés et non-supervisés. La nature de ces algorithmes dépend du type d'exemples que l'on a en entrée du système.
- Les régression ou les classifications. La nature de ces algorithmes dépend du type de sortie que l'on souhaite obtenir .

Apprentissage supervisé et non supervisé

L'apprentissage supervisé nécessite d'avoir des données labellisées en entrée, i.e. on connaît le type de décision que l'on aura en sortie du système, en fonction des exemples en entrée : il y'a une corrélation entre la sortie et l'entrée. C'est cette notion qui s'exprime au travers du terme *supervisé*. L'apprentissage non supervisé s'appuie quant à lui sur l'utilisation d'une base de donnée non labellisée pour son apprentissage, i.e qu'on ne connaît pas le type de décision associé aux exemples en entrée. Dans le cas d'un apprentissage non supervisé, pour parvenir à prendre une décision, l'algorithme devra diviser les groupes de données hétérogènes en sous-groupes homogènes d'informations aux caractéristiques similaires. On appelle ces subdivisions des *clusters*. Afin de matérialiser les différences entre les deux méthodes et les applications possibles pour chacune d'elles, on propose deux exemples tableau 3.1.




FIGURE 3.3 – Comparaison d'un apprentissage supervisé et non supervisé dans le cadre de l'exemple "apprendre aux humains". On observe sur la figure a) les différents exemples d'entraînement exprimés dans un repère composé des deux features "taille" et "longueur de pelage". On remarque qu'il y a la formation de deux groupes de données homogènes : les animaux de taille globalement élevée avec un pelage court et les animaux de taille moindre avec un poil globalement plus long. Les données étant labellisées, on sait que le premier groupe correspond à des chiens et le deuxième à des chats. Dans le cas de la figure b), les exemples n'étant pas labellisés, l'algorithme ne peut pas regrouper les données en fonction de leurs valeurs de sortie. Il réunit donc les ensembles homogènes de données en clusters.

Il existe deux types d'apprentissage supervisé : la régression et la classification.

Apprentissage supervisé : régression et classification

La régression est un type d'apprentissage avec lequel on souhaite obtenir une sortie continue. Dit de manière différente, la régression implique le fait que l'on souhaite *estimer* ou *prédire* une réponse. La classification est quant à elle un type d'apprentissage avec lequel on souhaite obtenir une sortie discrète, elle peut être vue comme un cas particulier

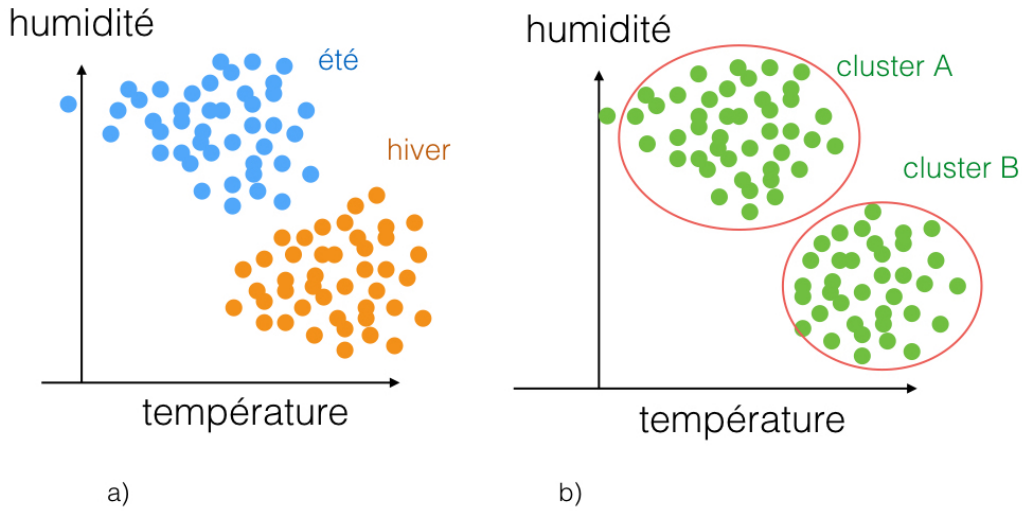


FIGURE 3.4 – Comparaison d'un apprentissage supervisé et non supervisé dans le cadre de l'exemple "prévisions saisonnières". On observe sur la figure a) les différents exemples d'entraînement exprimés dans un repère composé des deux dimensions (features) "humidité" et "température". On remarque qu'il y a la formation de deux groupes de données homogènes : un où les échantillons sont prélevés lors de saisons globalement chaudes et sèches, l'autre où les échantillons sont enregistrés lors de périodes globalement froides et humides. Les données étant labellisées, on sait que le premier groupe correspond à l'été et l'autre groupe à l'hiver. Dans le cas de la figure b), les exemples n'étant pas labellisés, l'algorithme ne peut pas regrouper les données en fonction de leurs valeurs de sortie. Il réunit donc les ensembles homogènes de données en clusters.

de la régression où les valeurs à prédire sont discrètes. Formulé autrement, la classification implique le fait que l'on souhaite *classer* un exemple parmi différentes catégories. Afin de mettre en avant les nuances existantes entre les deux méthodes et les applications possibles pour chacune d'elle, on propose l'exemple tableau 3.2).

3.2 Les différents algorithmes d'apprentissage supervisé

Il existe différents algorithmes d'apprentissage supervisé utilisés pour résoudre des problèmes de régression et de classification.

3.2.1 La régression linéaire uni-variable

La régression linéaire cherche à expliquer une variable de sortie y par une fonction affine de x . Cette fonction linéaire affine est appelée *hypothèse* (notée $h(x)$). Dit autrement : on a un jeu de données x auquel correspond un jeu de données y , on cherche les valeurs θ_1 et θ_2 permettant de "mapper" les données, tel que :

$$h_{\theta}(x) = \theta_0 + \theta_1 x \quad (3.5)$$

Exemple de régression linéaire uni-variable

On souhaite déterminer le prix d'un logement en fonction de sa surface au sol en se basant sur les exemples de prix du parc immobilier. La surface au sol est donc l'entrée x de notre système et le prix la sortie y . A partir des exemples du tableau 3.3 les exemples x ,




FIGURE 3.5 – Comparaison par l'exemple de la régression et la classification. Sur la figure a), on observe deux jeux de données homogènes (été et hiver) s'exprimant dans un repère en deux dimensions (features humidité et température). Le but est ici de classer l'exemple en entrée du système parmi ces deux ensembles, il s'agit donc d'un problème de classification. Dans la figure b), on observe une succession d'exemples exprimés dans un repère en deux dimensions (features température et humidité). On remarque une évolution globalement linéaire de ces exemples, nous permettant ainsi de prédire la température et l'humidité sur les prochains mois : il s'agit d'un problème de régression.

on obtient la représentation graphique en figure 3.6. Grâce à l'expression de l'hypothèse, on est capable de déterminer le prix d'un loyer en fonction de la surface au sol.

Cet exemple est dit uni-variable car un seul jeu de données x (superficie) correspond à un jeu de données y (prix).

La fonction coût

La fonction coût (en anglais cost function) compare la moyenne des différences entre les résultats de l'hypothèse $h(x)$ et les sorties actuelles y . Cela signifie qu'elle cherche à minimiser les valeurs calculées via l'hypothèse et les valeurs réelles (figure 3.7). Soit :

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2 \quad (3.6)$$

avec :

- $J(\theta_0, \theta_1)$ la fonction coût
- θ_0 et θ_1 les paramètres de l'hypothèse $h(x)$
- m le nombre d'exemples disponibles pour l'entraînement
- $h_{\theta}(x)$ l'hypothèse $h_{\theta}(x) = \theta_0 + \theta_1 x$
- x^i exemple i
- y^i sortie i

Algorithme du gradient

On cherche à minimiser la valeur de la fonction coût $J(\theta_0, \theta_1)$ en jouant sur les paramètres θ_0 et θ_1 de l'hypothèse. Pour cela, on calcule la fonction coût pour différentes valeurs




FIGURE 3.6 – évolution du prix de l'immobilier en fonction de la surface. L'ensemble des données semblent globalement évoluer de manière linéaire. Cette linéarité est représentée par l'hypothèse $h(x)$. Grâce à celle-ci, on peut déterminer le prix d'un logement en fonction de sa superficie, et inversement. Par exemple, un appartement d'une surface de 1750 m^2 coutera aux alentours de 390k€.

de θ_0 et θ_1 et on cherche la valeur minimale de $J(\theta_0, \theta_1)$. Dans l'idée, cela revient à choisir une valeur de θ et de "faire un pas" vers la direction la plus basse, il s'agit d'un calcul itératif. La forme de la courbe J en fonction de θ_0 et θ_1 étant convexe (figure 3.8), cela revient à trouver le minimum global de la courbe en appliquant l'algorithme du gradient (en anglais, gradient descent) :

$$\begin{aligned} & \text{repeat : } \{ \\ & \theta_0 = \theta_0 - \alpha \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_0} \\ & \theta_1 = \theta_1 - \alpha \frac{\partial J(\theta_0, \theta_1)}{\partial \theta_1} \\ & \} \end{aligned} \quad (3.7)$$

avec α la taille du "pas" que l'on fait vers la direction la plus basse. Si la valeur de α est trop petite, le nombre d'itération sera plus important, augmentant ainsi le temps de calcul. Si la valeur de α est trop grande, on risque de ne pas pouvoir atteindre le minimum et de diverger.

3.2.2 La régression linéaire multi-variable

On peut réaliser de la régression linéaire avec plusieurs types de variables en entrée.

Exemple de régression linéaire multi-variable

Afin de présenter ce qu'est la régression linéaire multi-variable, on ajuste l'exemple partie 3.2.1 pour le faire correspondre à un problème multi-variable.

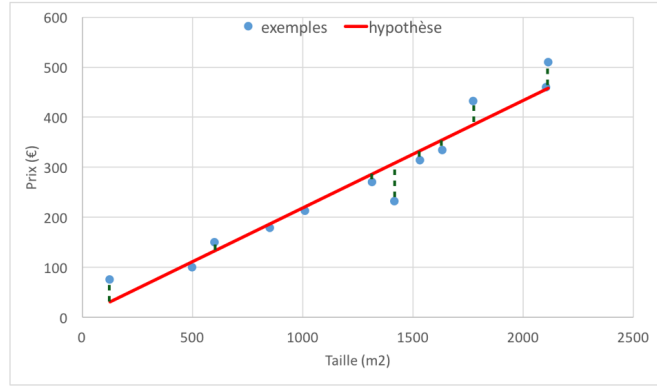


FIGURE 3.7 – Régression linéaire, optimisation de la fonction coût. Le calcul de la fonction coût revient à minimiser la distance entre un exemple et l'hypothèse, et ce pour chaque exemple.

On souhaite cette fois-ci déterminer le prix d'un logement en fonction de sa surface au sol, du nombre de pièces et du nombre d'étages, en se basant sur les exemples de prix du parc immobilier. On a donc plusieurs entrées (surface, nombre de pièces, nombre d'étages). Soit le tableau 3.4, les exemples x utilisés pour l'entraînement.

La fonction coût s'exprime sous cette forme :

$$h_{\theta}(x) = \theta_0 + \theta_1 X_1 + \theta_2 X_2 + \theta_3 X_3 \quad (3.8)$$

Où X_1 , X_2 et X_3 correspondent respectivement aux features surface, nombre d'étages et nombre de pièces.

On peut la généraliser :

$$h_{\theta}(x) = \theta_0 + \theta_1 X_1 + \theta_2 X_2 + \theta_3 X_3 + \dots + \theta_n X_n \quad (3.9)$$

Généralisation de la fonction coût

On peut généraliser la fonction coût utilisée lors de la régression linéaire uni-variable pour l'appliquer à un problème de régression linéaire multi-variable, tel que :

$$J(\theta_1, \theta_2, \theta_3, \dots, \theta_n) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i)^2 \quad (3.10)$$




FIGURE 3.8 – Régression linéaire, calcul des paramètres de l'hypothèse. Ce graphique représente la variation des paramètres θ_0 et θ_1 de l'hypothèse en fonction de la valeur de la fonction coût. On cherche les valeurs θ_0 et θ_1 minimisant $J(\theta_0, \theta_1)$. La courbe ayant la forme d'une "cuvette", les valeurs optimales de θ_0 et θ_1 correspondent à celles au fond de la "cuvette".

Généralisation de l'algorithme du gradient

On peut généraliser l'algorithme du gradient utilisé lors de la régression linéaire uni-variable pour l'appliquer à un problème de régression linéaire multi-variable :

$$\begin{aligned} & \text{Repeat } \{ \\ & \theta_j = \theta_j - \alpha \frac{\partial J(\theta_0, \theta_1, \theta_2, \theta_3, \dots, \theta_n)}{\partial \theta_j} \\ & \} \end{aligned} \quad (3.11)$$

On met à jour simultanément l'ensemble des valeurs de θ lors de chaque itération.

$$\begin{aligned} & \text{Repeat } \{ \\ & \theta_j = \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^i) - y^i) x_j^i \\ & \} \end{aligned} \quad (3.12)$$

avec x_j^i l'entrée j de l'entraînement i .

Vectorisation des calculs

On peut exprimer les exemples en entrée du système sous forme vectorielle :

$$\begin{bmatrix} X_0 \\ X_1 \\ X_2 \\ \dots \\ X_n \end{bmatrix} = X \quad (3.13)$$

De même, on réécrit les paramètres θ de l'hypothèse sous forme vectorielle :

$$\begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \dots \\ \theta_n \end{bmatrix} = \theta \quad (3.14)$$

On peut alors réécrire l'hypothèse (équation (3.9)) :

$$h_\theta(x) = \theta^T X \quad (3.15)$$

L'algorithme du gradient (équation (3.12)) s'exprime donc sous sa nouvelle forme vectorielle :

$$\theta = \theta - \frac{\alpha}{m} \sum_{i=1}^m (h_\theta(x^i) - y^i) X^i \quad (3.16)$$

3.2.3 La régression logistique

La régression logistique permet de résoudre des problèmes de classification. Elle découle de la régression linéaire et s'appuie sur les mêmes concepts. On cherche à séparer des groupes de données homogènes dans un ensemble hétérogène.

Régression linéaire et classification

On reprend l'exemple de la prévision saisonnière en partie 3.1.1 et on utilise de la régression linéaire afin de classer automatiquement l'échantillon qu'on lui présente en entrée dans la classe printemps ou hiver, en fonction de la température (figure 3.9). Pour cela, on met en place un seuil de classification :

- Si $h_\theta(x) > 0,5$ alors $y = 1$
- Si $h_\theta(x) < 0,5$ alors $y = 0$

Où $y = 0$ correspond à la période hiver et $y = 1$ l'été.

Cette méthode fonctionne dans le cas présent car les exemples sont régulièrement espacés entres eux. Dans le cas contraire, le seuil serait alors mal positionné et la classification serait erronée. La régression linéaire n'est donc pas adaptée pour la résolution de problèmes de classification.

Régression logistique et fonction sigmoïde

Pour réaliser de la classification en utilisant de la régression, on peut modifier la forme linéaire de l'hypothèse en une sigmoïde (figure 3.10). On appelle également cette courbe fonction logistique ou fonction de répartition. D'un point de vue probabiliste, cela signifie que l'hypothèse représente la probabilité estimée que la sortie y soit égale à 1. Par exemple, si $h_\theta(x) = 0,7$ signifie que l'on a 70% de chance que la variable de sortie soit égale à 1.

avec $g(x) = \frac{1}{1+e^{-x}}$ la fonction sigmoïde, on a l'hypothèse $h_\theta(x)$ suivante :

$$h_\theta(x) = g(\theta^T x) \quad (3.17)$$

soit :

$$h_\theta(x) = \frac{1}{1 + e^{-\theta^T x}} \quad (3.18)$$




FIGURE 3.9 – Classification via régression linéaire. On observe sur la figure a) que lorsque la température est inférieure à 12,5°C, le système considère que la valeur de sortie est 0 (hiver). Lorsque la température est au dessus, la valeur de sortie devient 1 (été). Ce cas particulier fonctionne car les exemples sont répartis de manière uniforme. Or, dans le cas de la figure b), on remarque qu'une répartition non uniforme des données entraîne un dysfonctionnement du classement. En effet, le seuil de différentiation entre les deux classes se situe aux alentours de 15°C, ce qui n'est pas représentatif des exemples.




FIGURE 3.10 – Fonction sigmoïde, également appelée fonction logistique.

Ligne de décision

On a la propriété de la fonction sigmoïde suivante :

$$g(z) \geq 0,5 \text{ lorsque } z \geq 0 \quad (3.19)$$

On a donc pour l'hypothèse la propriété suivante :

$$h(x) = g(\theta^T x) \geq 0,5 \text{ lorsque } \theta^T x \geq 0 \quad (3.20)$$

On peut alors émettre les deux affirmations suivantes :

$$\begin{aligned} y &= 1 \text{ si } h_{\theta}(x) \geq 0,5, \text{ soit } \theta^T x \geq 0 \\ y &= 0 \text{ si } h_{\theta}(x) \leq 0,5, \text{ soit } \theta^T x \leq 0 \end{aligned} \quad (3.21)$$

application : Soit $h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$ avec $\theta = \begin{bmatrix} -3 \\ 1 \\ 1 \end{bmatrix}$, on a la condition suivante :

$$y = 1 \text{ si } -3 + x_1 + x_2 \geq 0, \text{ soit } x_1 + x_2 \geq 3 \quad (3.22)$$

Cette expression correspond à la ligne (ou frontière) de décision de la régression linéaire (figure 3.11).




FIGURE 3.11 – Exemple d'une régression logistique. Les données en jaune sont séparées des données vertes par la frontière de décision (ligne rouge sur le graphe).

Ligne de décision non linéaire

Il est possible d'utiliser des hypothèses plus complexes, permettant d'effectuer de la classification non linéaire.

On a par exemple $h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_1 x_1^2 + \theta_1 x_2^2)$ avec $\theta = \begin{bmatrix} -1 \\ 0 \\ 0 \\ 1 \\ 1 \end{bmatrix}$.

Cela revient à dire :

$$y = 1 \text{ si } -1 + x_1^2 + x_2^2 \geq 0 \quad (3.23)$$

$$\text{soit } x_1^2 + x_2^2 \geq 1$$

Cette frontière de décision correspond à l'équation d'un cercle. Plus le nombre de polynômes de l'hypothèse est important, plus on peut créer des lignes de décisions complexes.

Fonction coût

Dans le cadre d'une régression linéaire, la forme de l'hypothèse est linéaire. Pour la régression logistique, elle ne l'est plus (forme sigmoïde). La fonction coût n'est donc ici pas convexe (graphe convexe de la régression linéaire figure 3.8) et on ne peut pas déterminer le minimum global (et donc la valeur optimale des paramètres de l'hypothèse), celle-ci pouvant posséder plusieurs minimums locaux. Pour palier à ce problème, on s'appuie sur une reformulation de la fonction coût.

Soit la fonction coût utilisée pour la régression linéaire :

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} (h_{\theta}(x^i) - y^i)^2 \quad (3.24)$$

On pose $Cost(h_\theta, y) = \frac{1}{2}(h_\theta(x^i) - y^i)^2$ le coût, on obtient :

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m Cost(h_\theta, y) \quad (3.25)$$

On reformule le coût dans le cadre de la régression logistique :

$$cost(h_\theta(x), y) = \begin{cases} -\log(h_\theta(x)) & \text{si } y = 1 \\ -\log(1 - h_\theta(x)) & \text{si } y = 0 \end{cases} \quad (3.26)$$

On peut réécrire cette formule en un seul bloc :

$$cost(h_\theta(x), y) = -y \log(h_\theta(x)) - (1 - y) \log(1 - h_\theta(x)) \quad (3.27)$$

La fonction coût devient alors :

$$J(\theta) = \frac{1}{m} \left[\sum_{i=1}^m y^i \log(h_\theta(x^i)) + (1 - y^i) \log(1 - h_\theta(x^i)) \right] \quad (3.28)$$

Sous cette forme, la fonction coût est convexe.

Intuitivement :

- lorsque l'on observe la forme de la fonction $-\log(h_\theta(x))$ (figure 3.12), vraie pour $y = 1$, on remarque que lorsque $h_\theta(x)$ tend vers 1, le coût tend vers 0. Lorsque $h_\theta(x)$ tend vers 0, le coût tend vers l'infini. Autrement dit, plus la valeur de l'hypothèse s'approche de la valeur de sortie réelle ($y=1$), plus le coût est faible. Inversement, plus il s'en éloigne, plus il est élevé.
- Lorsque l'on observe la forme de la fonction $-\log(1 - h_\theta(x))$ (figure 3.12), vraie pour $y = 0$, on remarque que lorsque $h_\theta(x)$ tend vers 0, le coût s'approche de 0. Lorsque $h_\theta(x)$ tend vers 1, le coût tend vers l'infini. Autrement dit, plus la valeur de l'hypothèse s'approche de la valeur de sortie réelle ($y=0$), plus le coût est faible et inversement, plus il s'en éloigne, plus il est élevé.

C'est le comportement que l'on attend de la fonction coût, i.e. optimiser l'hypothèse de manière à ce que celle-ci s'approche de la valeur de sortie réelle.


Algorithme du gradient

La formule de l'algorithme du gradient reste identique à celle utilisée pour la régression linéaire, seule la valeur de $h_\theta(x)$ change, selon la démarche soumise en partie 3.2.3.

$$\begin{aligned} & \text{Repeat } \{ \\ & \theta_j = \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_\theta(x^i) - y^i) x_j^i \\ & \} \end{aligned} \quad (3.29)$$

Classification multiclasse

Les exemples de classification proposés jusqu'ici ne comportaient que deux classes. Or il est possible de résoudre des problèmes dont la décision doit être prise parmi plus de

FIGURE 3.12 – fonctions $-\log_{\theta}(h(x))$ et $-\log_{\theta}(1 - h(x))$

deux classes. Soit l'exemple de la prévision saisonnière (partie 3.1.1), on a en sortie une décision à prendre parmi les 4 classes : printemps, été, automne et hiver. Pour résoudre ce problème, on compare une classe par rapport à l'ensemble des autres classes (considérées alors comme un seul et même ensemble homogène). On répète ensuite le même procédé pour les autres classes. L'exemple analysé appartient à la classe ayant eu la probabilité la plus élevée en sortie. Cette méthode s'appelle la "One-vs-All".

3.2.4 SVM -Support Vector Machine-

Le Support Vector Machine (traduire en français par "Machine à vecteurs de support") permet de résoudre des problèmes de classification. Conceptuellement, le SVM reprend les théories appliquées à la régression logistique. On y ajoute deux notions supplémentaires : la marge maximale et les fonctions noyaux.

Marge maximale

Afin d'expliquer ce qu'est la notion de marge maximale, on s'appuie sur un exemple dans lequel les données sont séparables par une ligne de décision linéaire. Dans le cas de la figure 3.13, on a un problème de classification composé de deux classes. Le but est donc de déterminer une valeur de l'hypothèse permettant de séparer ces deux régions (représentée par la frontière de décision). On remarque qu'elle peut prendre une infinité de valeurs (i.e. il existe une infinité de combinaisons de valeurs des paramètres θ de l'hypothèse résolvant la classification). On cherche donc à déterminer l'hypothèse permettant de répondre de manière optimale à ce problème. Pour cela, on introduit la notion de marge. Comme on peut l'observer sur la figure 3.14, la ligne de décision est bordée de deux marges. Celles-ci prennent appui sur les valeurs situées à l'extrémité de chacune des deux régions homogènes de données. Afin de déterminer la meilleure position pour la ligne de décision (et donc le paramétrage optimal de l'hypothèse), on maximise la distance entre ces deux marges.




FIGURE 3.13 – Svm : cas simple d'une régression logistique avec une hypothèse linéaire. On observe sur la figure ci-contre qu'il existe une infinité de positions de la frontière de décision délimitant les deux classes. Cependant la performance de chacune d'elle peut être différente.

Les fonctions noyaux

Les fonctions noyaux (également appelées Kernel) permettent de résoudre des problèmes de classifications non linéaires grâce à des méthodes de classifications linéaires. Pour cela, on transforme l'espace de représentation des données d'entrées en un espace de plus grande dimension dans lequel il est possible de délimiter les classes par une frontière de décision linéaire (figure 3.15 et 3.16) .

Avantages du SVM

L'entraînement d'un algorithme de type SVM peut être effectué avec peu d'exemples. En effet, la marge maximale s'appuie sur les données en périphéries des ensembles homogènes. De plus, il s'agit d'un outil puissant et facilement adaptable.

3.2.5 Périmètres d'utilisation de la régression logistique et du SVM

La régression logistique et le SVM sont tous deux des algorithmes de classification. Le choix d'un modèle dépend du nombre d'exemples que l'on a pour l'entraînement et du nombre de features. On présente dans le tableau 3.5 les différents périmètres d'utilisation.

3.2.6 Autres algorithmes pour l'apprentissage supervisé

Les méthodes proposées jusqu'ici ne représentent qu'un échantillon du parc algorithmique constituant l'apprentissage automatique supervisé. On peut notamment évoquer les réseaux neuronaux qui sont des algorithmes puissants et sont beaucoup utilisés dans le traitement et l'analyse d'images (mais requièrent un nombre d'exemples élevé). On peut également mentionner les arbres de décision (e.g. Markov).




FIGURE 3.14 – Svm : optimisation du calcul de l'hypothèse par l'introduction de la notion de marges. Afin de déterminer la position optimale pour la frontière de décision, on introduit deux marges entre les échantillons à l'extrémité des classes et la ligne de décision. On cherche à maximiser la distance entre ces deux marges afin d'obtenir la frontière de décision optimisant la classification.




FIGURE 3.15 – Exemple d'un problème de classification linéaire. On observe qu'ici les deux classes (+ et -) sont séparables par une frontière de décision linéaire.




FIGURE 3.16 – Exemple d'un problème de classification non linéaire. On observe que les deux classes (+ et -) ne sont pas linéairement séparables. Pour résoudre ce problème, on utilise des kernels afin de modifier l'espace de représentation et trouver un espace où il est possible de résoudre le problème par une frontière linéaire.

	apprentissage supervisé	apprentissage non supervisé
exemple n°1 : apprendre aux humains	Une institutrice enseigne à ses élèves à différencier un chat d'un chien : c'est la décision qu'on attend d'eux. Pour cela, l'éducatrice leur montre différentes photographies de chiens et de chats : ce sont les exemples utilisés pour l'apprentissage. Ces exemples peuvent être segmentés en différentes caractéristiques, comme la taille de l'animal, sa couleur, la longueur du poil, etc : il s'agit des features. Lorsque l'institutrice leur présente les différentes images, elle stipule clairement si il s'agit d'un chien ou d'un chat : il y'a donc une corrélation entre l'entrée et la sortie de l'apprentissage, il s'agit d'un apprentissage supervisé (figure 3.3,a).	Une institutrice donne à ses élèves le même exercice que dans le cadre de l'apprentissage supervisé, à la différence que lorsqu'elle présente les différentes images, elle <i>ne stipule pas</i> la race de l'animal : il n'y a donc aucune corrélation entre l'entrée et la sortie de l'apprentissage, il s'agit donc d'un apprentissage non supervisé. Pour réussir cet exercice, les enfants devront donc regrouper les animaux en s'appuyant sur leurs similitudes physiques, i.e. leurs features (e.g. taille de l'animal, sa couleur, longueur du poil, etc.). Les élèves ne connaîtront certes pas le nom des deux animaux, mais ils auront su les différencier. C'est la même approche qui est mis en œuvre en apprentissage automatique non supervisé (figure 3.3, b).
exemple n°2 : prévisions saisonnières 3.1.1	On reprend l'exemple dans lequel on souhaite prendre une décision quant à la période de l'année à laquelle on se trouve actuellement, en fonction des features humidité, température et pression atmosphérique. On prélève des échantillons à différentes périodes de l'année en notant à quelle saison ces données ont été prélevées : ce sont des exemples labellisés, i.e. il y'a une corrélation entre les données et la sortie du système. Il s'agit donc d'un apprentissage supervisé (figure 3.4, a).	Cette fois-ci on ne note pas la saison à laquelle les échantillons ont été prélevés. Pour résoudre le problème, l'algorithme doit donc associer les données les plus similaires entre elles et ainsi créer des groupes homogènes d'informations qui correspondront aux 4 décisions possibles (figure 3.4, b).

TABLE 3.1 – Comparaison de l'apprentissage supervisé et non supervisé par des exemples

régression	classification
On souhaite connaître le temps (température et humidité) qu'il fera pendant les jours suivants. Pour cela, on s'appuie sur les différents échantillons de température et d'humidité enregistrés lors des mois et des années précédentes (exemples labellisés). Le fait de déterminer la température des jours suivants relève de la prédiction (figure 3.2, a).	L'exemple de la prédiction saisonnière 3.1.1 est un problème de classification : on cherche à classer notre donnée d'entrée parmi plusieurs groupes de données homogènes : printemps, été automne ou hiver (figure 3.2, b).

TABLE 3.2 – Comparaison entre l'apprentissage supervisé de type régression et supervisé de type classification

taille (m^2)	prix (k€)
2104	460
1416	232
1534	314
852	178
500	100
1012	212
126	75
1775	432
600	150
2114	510
1316	270
1634	334

TABLE 3.3 – exemples de prix des logements en fonction de leur taille

taille (m^2)	prix (k€)
2104	460
1416	232
1534	314
852	178
500	100
1012	212
126	75
1775	432
600	150
2114	510
1316	270
1634	334

TABLE 3.4 – exemples du prix des logements en fonction de leur surface, du nombre d'étages et du nombre de pièces

Périmètres d'utilisation	Modèle d'apprentissage à favoriser
le nombre de features est plus important que le nombre d'exemples (environ 1000 features pour 10 à 100 exemples)	Régression logistique ou SVM sans kernel
le nombre de features est faible (1 à 1000 features pour 10 à 10 000 exemples)	SVM avec un kernel
si le nombre de features est faible et le nombre d'exemples élevé (1 à 10 000 features pour 50 000 à 1 million d'exemples)	Régression logistique ou svm sans kernel avec création de features.

TABLE 3.5 – Périmètre d'utilisation de la régression logistique et le SVM

Chapitre 4

Automatisation du processus d'investigation

Lorsqu'une error name est révélée (partie 2.2.1) durant le Filtering test, de nombreuses données sont enregistrées dans un fichier journal (que l'on retrouve plus souvent sous le terme anglais de fichier "log".) Une analyse poussée de ces informations permet de déterminer la root cause liée à l'error name (partie 2.2.1). Afin d'automatiser ce processus d'analyse, on s'appuie sur l'utilisation d'algorithmes d'apprentissage automatique.

4.1 Architecture High Level du système proposé

L'architecture haut niveau de la solution que l'on propose est composée de deux couches : une couche "root cause" et une couche "error name".

Couche root cause La couche root cause permet de détecter la présence d'une root cause dans l'exemple que l'on analyse. Il s'agit d'un algorithme d'apprentissage automatique entraîné à effectuer cette tâche.

Couche error name La couche error name est constituée d'un ensemble de couches root cause de telle manière que lorsqu'un fichier historique est mis en entrée du système, l'ensemble des couches root cause sont activées. Ainsi, le système recherche la présence de chaque root cause connue dans l'exemple étudié. On obtient en sortie de la couche error name le nom de la root cause ayant la plus forte probabilité d'avoir été reconnue.

Exemple de mise en place d'une couche error name et de ses couches root cause

Afin d'exposer de manière concrète le fonctionnement de l'architecture haut niveau de la solution proposée, on soumet un exemple de mise en place d'une architecture de détection et son utilisation.

Mise en place du système de détection d'une root cause / Apprentissage On souhaite dans un premier temps mettre en place l'architecture permettant de détecter la cause (root cause) ayant entraîné la chute du robot lors du Filtering test (error name). Cette étape consiste à créer les couches root cause, i.e. entraîner différents algorithmes d'apprentissage automatique à reconnaître la root cause pour laquelle ils ont été créés (figure 4.1). Afin d'entraîner ces couches, on utilise les données utiles à chaque root cause,

contenues dans le fichier log généré lors de la chute d'un robot durant le Filtering Test. Par exemple, dans le cas de la root cause "frottement des freins de la hanche", on utilisera les données "valeurs du senseur de la hanche" et "valeurs de l'actuateur de la hanche". Ces deux éléments correspondent aux features de notre apprentissage (c.f. partie 3.1.1). L'ensemble de ces couches root cause sont placées dans la couche error name associée. Ici, il s'agit de la couche permettant de déterminer la cause de la chute d'un robot.




FIGURE 4.1 – Synoptique haut niveau de la création des couches root cause. Les couches root cause correspondent à des algorithmes d'apprentissage automatique que l'on entraîne à détecter la root cause à laquelle ils sont associés. Par exemple, créer la couche root cause "frottement du frein de la hanche" revient à entraîner un algorithme d'apprentissage de type SVM à partir des valeurs senseurs et actuateurs de la hanche contenues dans les différents exemples de fichiers logs générés lors de chutes de robot durant le filtering test. On réalise ce processus pour chaque couche root cause que l'on veut créer.

Utilisation du système de détection d'une root cause Une fois nos différentes couches root cause créées, on souhaite utiliser notre système afin de détecter la cause de la chute d'un robot (c.f. figure 4.2). Pour cela, on place à l'entrée de notre couche error name le fichier log que l'on souhaite analyser. Chaque couche root cause extrait du fichier log les features qui lui sont liées (e.g. la root cause "frottement des freins de la hanche" est liée aux features senseurs et actuateurs de la hanche). L'algorithme SVM de chaque couche root cause va alors émettre une décision quant à la présence ou non de la root cause dans le fichier log ; Cette décision correspond à la probabilité que la root cause ait été détectée (en %). La couche root cause ayant la probabilité la plus élevée en sortie est considérée comme la root cause (cause) ayant entraîné l'error name (i.e. la conséquence, ici la chute du robot)

Chaque couche root cause peut être considérée comme un système à part entière. Le schéma fonctionnel d'une root cause (c.f. figure 4.3) reprend la même structure que celui du Machine Learning (c.f. 3.1) car, comme dit précédemment, chaque root cause est constitué d'une instance de l'algorithme SVM. Dans la suite de notre étude de l'architecture haut niveau de la solution proposée, on s'intéressera plus particulièrement au fonctionnement de la couche root cause car elle contient l'ensemble du traitement et de l'analyse des données.




FIGURE 4.2 – Synoptique haut niveau de l'utilisation de la couche error name. La couche error name contient plusieurs couches root cause. On met en entrée du système le fichier log que l'on souhaite analyser, puis chaque couche root cause va détecter la présence de la root cause à laquelle elle est rattachée. On obtient en sortie de la couche error name la root cause ayant la plus forte probabilité d'avoir été reconnue.

4.1.1 Les exemples

Les exemples sont les éléments permettant d'entraîner l'algorithme d'apprentissage automatique (c.f. partie 3.1.2). Dans le cadre de la résolution de notre problématique, ces exemples correspondent aux données générées et enregistrées dans le fichier log lorsqu'une erreur (error name) est détectée durant le Filtering Test.

Structure du fichier log

Le fichier log renferme un ensemble de données enregistrées lors de la détection d'une erreur durant le Filtering Test. Ces données correspondent aux "rythmes vitaux" du robot. Il contient par exemple l'évolution temporelle des différents actuateurs et senseurs de Pepper, la température de différentes pièces mécaniques, etc. Dans le cadre de l'entraînement de l'algorithme du Machine Learning (SVM), chacune de ces constantes correspond à une

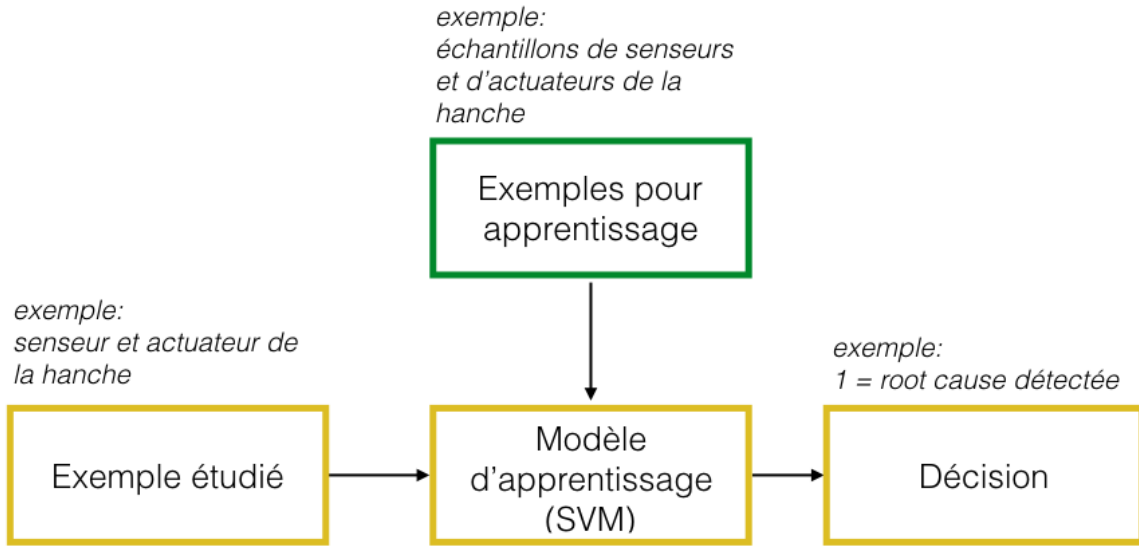


FIGURE 4.3 – Synoptique d'une couche root cause. La couche error name contient plusieurs couches root cause. On met en entrée du système le fichier log que l'on souhaite analyser, puis chaque couche root cause va détecter la présence de la root cause à laquelle elle est rattachée. On obtient en sortie de la couche error name la root cause ayant la plus forte probabilité d'avoir été reconnue.

feature (c.f. partie 3.1.1). Soit le tableau 4.1, un extrait du contenu d'un fichier log :

<i>features</i>	<i>HeadPitchPositionActuatorValue</i>	<i>HeadPitchElectricCurrentSensorValue</i>	<i>HipPitchPo</i>
t_0	-0,404	0,64	
t_1	-0,404	0,64	
t_3	-0,404	0,576	
t_4	-0,402	0,544	
t_5	-0,401	0,448	
t_6	-0,401	0,448	
t_7	-0,408	0,096	
t_8	-0,444	0,096	
t_9	-0,486	0,096	
t_{10}	-0,523	0,128	
t_n	

(4.1)

Le fichier log représenté par ce tableau correspond uniquement à un seul exemple de la base de données nous servant à entrainer chacun de nos algorithmes. A chaque colonne du tableau correspond une feature. Chacune des lignes représente la valeur de la feature à un instant t (une ligne ne correspond pas à un exemple!).

Structure de la base de données d'exemples

La base de donnée est composée de plusieurs exemples qui correspondent à des fichiers logs, générés lors du Filtering Test en cas de présence d'une erreur. Par exemple, dans le cadre de la construction de couche error name correspondant à la chute d'un robot, la base de donnée sera constituée de fichiers logs générés par plusieurs cas de chutes sur des robots différents. On peut représenter la structure des données de la base de données par

le tableau 4.2

<i>features</i>	<i>HeadPitchPositionActuatorValue</i>	<i>HeadPitchElectricCurrentSensorValue</i>
<i>exemple₀</i>	<i>log₀[HeadPitchPositionActuatorValue]</i>	<i>log₀[HeadPitchElectricCurrentSensorValue]</i>
<i>exemple₁</i>	<i>log₁[HeadPitchPositionActuatorValue]</i>	<i>log₁[HeadPitchElectricCurrentSensorValue]</i>
<i>exemple₂</i>	<i>log₂[HeadPitchPositionActuatorValue]</i>	<i>log₂[HeadPitchElectricCurrentSensorValue]</i>
<i>exemple₃</i>	<i>log₃[HeadPitchPositionActuatorValue]</i>	<i>log₃[HeadPitchElectricCurrentSensorValue]</i>
<i>exemple₄</i>	<i>log₄[HeadPitchPositionActuatorValue]</i>	<i>log₄[HeadPitchElectricCurrentSensorValue]</i>
<i>exemple₄</i>	<i>log₄[HeadPitchPositionActuatorValue]</i>	<i>log_n[HeadPitchElectricCurrentSensorValue]</i>

(4.2)

Tout comme la structure d'un fichier log (4.1.1), chaque colonne correspond à une feature. Chaque ligne de ce tableau représente un exemple et correspond à un fichier log en particulier. Cela signifie que chaque ligne du tableau représente le contenu d'un fichier log, comme présenté dans le tableau 4.1.

Construction d'une couche root cause à partir de la base de données d'exemples

Lorsque l'on veut construire une nouvelle couche root cause, i.e. entraîner un nouvel algorithme d'apprentissage pour détecter la présence d'une root cause particulière dans le fichier log, on va sélectionner uniquement les features de la base de données d'exemples liées à la root cause. Par exemple, si on veut créer une nouvelle couche root cause "frottement des freins de la hanche" (lié à l'error name chute du robot), on n'utilisera que les features "HipPitchPositionSensorValue" et "HipPitchPositionActuatorValue" de notre base de données.

4.1.2 Parallèle avec l'exemple de la prévision saisonnière et mise en évidence du problème de l'évolution temporelle

Si on fait le parallèle avec les exemples de l'exemple "prévisions saisonnières (c.f. tableau 3.1) et ceux de notre solution (c.f. tableau 4.2), on observe que dans les deux cas les données sont structurées en exemples et features. Cependant, dans la solution que l'on propose, les données de chaque exemple évoluent temporellement (e.g. la "HipPitchPositionSensorValue" de l'exemple 1 correspond à la colonne "HipPitchPositionSensorValue" du fichier *log₁* qui a une évolution temporelle), alors que celles de la prévision saisonnière sont discrètes (e.g la température de l'exemple 1 est de -10°C, elle est discrète). Le problème est qu'on ne peut réaliser de l'apprentissage supervisé qu'avec des données discrètes. Sous leurs formes actuelles, les données de nos exemples ne peuvent donc pas servir à entraîner les algorithmes SVM de nos couches root cause. Une solution sera soumise ultérieurement en partie ??

4.1.3 Le modèle d'apprentissage

Le modèle d'apprentissage utilisé est le Support Vector Machine (SVM) avec l'utilisation de Kernels (c.f. présentation de l'algorithme partie 3.2.4).

4.1.4 La décision

Chaque couche root cause délivre en sortie la probabilité que la root cause à laquelle elle est rattachée soit présente dans le fichier log analysé (via le SVM).

4.2 Reconnaissance de motifs

On souhaite réaliser de la reconnaissance de motifs grâce à l'utilisation du Machine Learning, afin de mettre en place l'automatisation du processus d'investigation. L'utilisation de cette méthode répond notamment au problème causé par l'évolution temporelle des exemples utilisés pour l'entraînement de notre système (c.f. partie 4.1.2). On présente dans cette partie les différentes solutions envisagées et les raisons ayant amené à utiliser la reconnaissance de motifs.

Afin de simplifier le développement du système de reconnaissance de motifs, on admet dans un premier temps que chaque couche root cause est un système d'apprentissage automatique capable d'apprendre uniquement à détecter une root cause en analysant une seule feature (e.g. BaseAccZ, HipPitchSensorValue, etc.)

4.2.1 Différentes approches étudiées

L'évolution temporelle des exemples utilisés pour l'entraînement de l'algorithme implique de prétraiter les données (c.f. partie 4.1.2). Pour cela, différentes approches sont envisagées.

Création de nouvelles features

On propose de créer de nouvelles features, constantes, caractéristiques des features actuelles. Dans le cadre de cette étude, on les identifiera sous l'appellation de *caractéristiques simplifiées*. On peut par exemple calculer la moyenne d'une feature, sa valeur crête-à-crête, sa valeur maximum, etc. On se sert ensuite de ces nouvelles caractéristiques simplifiées pour réaliser l'entraînement de notre algorithme d'apprentissage automatique (c.f. exemple figure 4.4).

Le problème de cette approche est qu'elle réduit le nombre d'informations que contient une donnée à seulement quelques caractéristiques (e.g. moyenne et valeur crête-à-crête). Comme le démontre la figure 4.5, cette diminution des informations peut entraîner des risques de confusion entre différentes features, i.e. deux features différentes peuvent avoir les mêmes caractéristiques. Or, si on souhaite utiliser cette approche dans l'architecture que l'on propose partie 4.1, le risque est que deux couches root cause soient liées à des features dont les caractéristiques sont similaires. Dans ce cas, le système est incapable de déterminer quelle root cause est responsable de l'apparition d'un error name.

Considérer chaque unité de temps comme une feature

On propose de considérer chaque unité de temps comme une feature caractéristique de nos différents exemples. Le nombre d'entrées du système d'apprentissage automatique est donc égal au nombre d'échantillons contenus dans une donnée temporelle (c.f. figure 4.6). De manière intuitive :

Chaque feature peut être associée à deux formes distinctives :

- Une forme "normale" de la courbe, i.e. une feature qui n'est pas liée à une root cause.
- Une forme caractéristique de la courbe, attestant de la présence d'une root cause.

Entraîner le modèle revient à créer un patron représentatif de la feature liée à la présence d'une root cause. Pour cela, on entraîne l'algorithme d'apprentissage automatique à partir des deux formes distinctes. Cela revient à apprendre la forme globale et caractéristique d'une feature en cas de présence ou non d'une root cause. Une fois cette forme apprise,




FIGURE 4.4 – Calcul des caractéristiques simplifiées. Les figures a) et b) représentent respectivement l'évolution de la valeur du capteur et de l'actuateur de la hanche au cours du temps, lors de la chute d'un robot. La ligne rouge représente la valeur moyenne de chacune des features. la ligne noire correspond à la valeur crête-à-crête de chacune des features. On a ainsi réduit nos features à deux valeurs constantes. On peut donc entraîner l'algorithme d'apprentissage automatique à partir de ces caractéristiques simplifiées.

on la compare avec la feature que l'on souhaite analyser afin de savoir si la root cause est présente ou non dans la feature.

Par exemple, on souhaite créer une nouvelle couche root cause (i.e. entraîner un algorithme d'apprentissage) à reconnaître le frottement des freins de la hanche, entraînant la chute du robot durant le Filtering Test. Pour cela on va s'intéresser plus particulièrement à la courbe de

Passage des données dans le domaine fréquentiel

Afin de supprimer l'aspect temporel des exemples, on propose de les passer dans le domaine fréquentiel. A la manière de la solution testée en partie 4.2.1 Chaque valeur fréquentielle devient alors une entrée de notre système, i.e. une feature.

Par exemple, on calcule la fft des valeurs de l'accélération en Z lors de la chute d'un robot.




FIGURE 4.5 – Calcul de nouvelles features. On retrouve sur la figure a) les valeurs du capteur et de l'actuateur de la hanche, ainsi que leurs caractéristiques simplifiées. Sur la figure b), on observe deux autres features et leurs caractéristiques simplifiées. On remarque que, bien qu'il s'agisse de features différentes entre les figures a) et b), ces dernières possèdent les mêmes caractéristiques simplifiées.

Calcul de la convolution

4.2.2 Concept

4.3 Étendre le problème à plusieurs dimensions

4.4 Difficultés notoires rencontrées

4.5 Performances de la solution

Une fois l'architecture du système définie, on souhaite mesurer les performances de l'algorithme. Il existe pour cela plusieurs outils relatifs au Machine Learning.

4.5.1 Optimisation des paramètres du SVM

La prise de décision de la part de l'algorithme du SVM peut être contrôlée via deux paramètres : C et γ .

γ

C

Afin de déterminer la meilleure combinaison de valeurs des deux paramètres, on calcule les *courbes de validation*. Cela consiste à faire varier chacun des deux paramètres sur une plage de données et à calculer la précision de l'algorithme pour chaque valeur. On conserve la valeur optimale.




FIGURE 4.6 – Considérer chaque unité de temps comme une feature : exemple. On souhaite dans cet exemple entraîner l'algorithme à reconnaître le .

4.5.2 Matrices de confusion

4.5.3 Courbes d'apprentissage

Chapitre 5

Industrialisation du produit

Une fois le processus fonctionnel de notre système défini, on l'industrialise. Cela signifie que l'on crée un ensemble d'outils permettant de l'utiliser de la manière la plus simple possible et en répondant au mieux à la problématique initiale.

On soumet deux types d'outils : l'API, qui permet d'utiliser le système d'automatisation de l'investigation, et les outils graphiques, qui accompagnent l'usage de l'API et permettent à l'utilisateur d'interagir avec le programme.

5.1 API

L'API que l'on propose est composée de 3 modules principaux :

data base Permet de gérer le stockage et la lecture des données nécessaires à l'exécution des algorithmes d'apprentissage. Deux types de fichiers sont sauvegardés dans la base de donnée : les fichiers logs, qui fournissent l'ensemble des exemples permettant d'entraîner l'algorithme et les fichiers générés par l'algorithme lors de son apprentissage.

data set Gère le pré-traitement et le traitement des exemples afin de les structurer pour réaliser l'apprentissage par la suite.

machine learning Permet de créer un algorithme d'apprentissage, de l'entraîner et de l'utiliser pour investiguer sur la root cause pour laquelle il a été créé.

La librairie utilise le langage de programmation Python [?].

5.1.1 Pré-traitement et traitement des données

Le module "Data set" contenu dans l'API permet de pré-traiter les exemples et de les structurer afin de pouvoir réaliser l'apprentissage. Le pré-traitement est composé de 5 étapes.

Lecture La première étape du pré-traitement consiste à lire les données contenues dans le fichier log.

Échantillonnage Les fichiers logs générés par MEIGUI lors du déroulement du Filtering Test n'ont pas forcément tous la même période d'échantillonnage. Cela signifie que les exemples que l'on souhaite utiliser pour l'entraînement ne font pas tous la même taille. Or, les spécificités des fonctions de la librairie Scikit-learn utilisées pour l'entraînement nécessite que celles-ci aient le même nombre d'échantillons.

Pour cette raison, échantillonne les données extraites des fichiers logs avec le même nombre d'échantillons. Si le nombre d'échantillons contenu dans le fichier log est inférieur au nombre d'échantillons fixé pour l'échantillonnage, on effectue un sur-échantillonnage lorsque celui-ci n'altère les données.

Sélection des motifs Au regard de l'architecture fonctionnelle que l'on a définie en partie 4.1, on doit extraire les motifs caractéristiques d'une root cause dans chaque exemple utilisé. Pour cela, une sélection manuelle du motif est réalisée en amont via une interface graphique (c.f. ??). A partir des informations retournées par l'IHM, on est en mesure de sélectionner les données correspondant aux motifs, dans chacun de nos exemples. On rappelle que l'on enregistre également des morceaux de la courbe ne correspondant pas au motif d'une root cause, afin d'avoir les deux types de label lors de l'entraînement de l'algorithme.

Déroulement des données On déroule ensuite les données afin de pouvoir réaliser de la reconnaissance de motifs sur plusieurs features (c.f. partie) 4.3), i.e. que l'on place chacune des colonnes de notre matrice d'exemples l'une en dessous de l'autre pour obtenir en sortie un vecteur.

Tri des données Enfin, afin de pouvoir mesurer les performances de notre algorithme (c.f. partie 4.5), on sépare notre base de données d'exemples en deux groupes : le training set et le test set. Le premier sera utilisé pour entraîner notre algorithme, le deuxième pour le tester.

5.1.2 Sélection des motifs lors du pré-traitement des données

Comme étudié en partie 4.2, la reconnaissance de motifs passe par la sélection des motifs caractéristiques de la root cause que l'on souhaite détecter pour chaque exemple de notre base de donnée. Elle s'accompagne également de la sélection de sections de la courbe ne présentant pas ce motif afin de pouvoir réaliser l'apprentissage de l'algorithme correctement(c.f. partie 4.4). Chaque motif sélectionné doit avoir la même taille i.e. le même nombre d'échantillons pour pouvoir réaliser l'entraînement. Cette taille dépend de la largeur globale du motif caractéristique de la root cause étudiée et est déterminée lors de l'utilisation de l'interface graphique présentée partie

5.1.3 Format des données en sortie du pré-traitement des données

On présente dans le tableau 5.1 la structure des données en sortie du pré traitement des données. On a deux vecteur : un contenant les exemples de motifs et un deuxième contenant le label associé à chaque motif. Le label 1 signifie que le motif lié correspond à un motif caractéristique de la root cause que l'on cherche à détecter ; 0 signifie que le motif lié ne correspond pas à un motif caractéristique de la root cause que l'on cherche à détecter.

$$\begin{array}{cc} \text{exemples} & \text{label} \\ \left[\begin{array}{c} \text{exemple}_1 \\ \text{exemple}_2 \\ \text{exemple}_3 \\ \text{exemple}_4 \\ \dots \\ \text{exemple}_m \end{array} \right] & \left[\begin{array}{c} 1 \\ 0 \\ 0 \\ 1 \\ \dots \\ 0 \end{array} \right] \end{array} \quad (5.1)$$

On retrouve cette structure pour chaque *set* (i.e. *training set* et *test set*) Chaque exemple correspond à une liste qui contient l'ensemble des échantillons contenus dans un motif (c.f. partie 5.1.2).

5.1.4 Module Machine Learning et librairie scikit-learn

Le module Machine Learning s'appuie sur l'utilisation de scikit-learn [?]. Il s'agit d'une bibliothèque Open Source développée par l'INRIA (Institut National de Recherche en Informatique et en Automatique [?]). Elle propose de nombreux outils afin de réaliser de la classification (régression logistique, SVM), de la régression (SVR, régression linéaire) et du clustering (i.e. apprentissage non supervisé). Elle est principalement utilisée dans notre cas pour réaliser de classification (i.e. apprentissage supervisé) en utilisant l'algorithme d'apprentissage automatique SVM. Elle est également utilisée afin de construire le *training set* et le *test set*.

5.2 Outils graphiques

On présente ici les différents outils graphiques permettant de réaliser la construction d'une nouvelle couche root cause (i.e. l'entraînement d'un nouvel algorithme à détecter une root cause particulière), d'investiguer un error name et d'obtenir des informations quant aux performances de l'algorithme.

5.2.1 Pattern selector

Cet outil graphique permet de sélectionner les motifs contenus dans chaque exemple du *training set* durant la phase de pré-traitement des données. Il permet également de labelliser les exemples.

Il est formé de trois parties :

- La première partie (encadré vert de la figure 5.1) nous donne divers indications sur l'état actuel du pré-traitement des données : la taille du motif actuellement sélectionné, le nom de l'exemple étudié et le nombre d'exemples restant à traiter.
- La seconde partie (encadré rouge de la figure 5.1) est la partie graphique de l'interface graphique. Elle affiche les features de l'exemple actuellement étudiée. Dans le cas de la figure 5.1, on réalise par exemple l'entraînement de l'algorithme pour que celui-ci puisse reconnaître le motif caractéristique de la root cause "frottement des freins de la hanche". La région en rouge permet de sélectionner le motif qui nous intéresse. D'après la première partie de l'IHM, on a ici sélectionné un motif dont la taille est de 60 échantillons.
- La dernière partie (encadré bleu de la figure 5.1) est une succession de boutons permettant d'interagir avec les différents exemples. De gauche à droite :
 - Le bouton "Previous" permet de revenir à l'exemple précédent.
 - Le bouton "Found" permet d'indiquer au système que le motif est présent sur l'exemple étudié, et qu'il a bien été sélectionné grâce à la région en rouge. Cela revient à labelliser l'exemple ($Y = 1$, c.f. partie 5.1.3)
 - Le bouton "Not Found" permet d'indiquer au système que le motif n'est pas présent sur l'exemple étudié. Cela revient à labelliser l'exemple ($Y = 0$, c.f. partie 5.1.3). Le prochain exemple à étudier s'affiche.
 - Le bouton en forme d'œil ouvert permet d'activer le mode étendu (c.f. figure 5.2). Le prochain exemple à étudier s'affiche.

Région de sélection

La région de sélection permet de sélectionner le motif caractéristique d'une root cause dans chaque exemple où celui-ci est présent. Il est possible d'augmenter la taille de celui-ci si le besoin est présent. Par exemple, imaginons que l'on sélectionne sur le premier




FIGURE 5.1 – Interface graphique du pattern selector.

exemple un motif, la taille indiquée en haut à gauche de l'IHM du pattern selector est alors de 60 échantillons. On clique sur le bouton "Found" et un nouvel exemple s'affiche. Celui-ci contient également le motif caractéristique de la root cause que l'on apprend, mais ce dernier est plus large de 10 échantillons. Il est alors possible d'étendre la région de sélection pour pouvoir sélectionner l'ensemble de ce nouveau motif. Cependant, l'ensemble des exemples devant avoir la même taille (même nombre d'échantillons), on modifie la taille des motifs précédemment sélectionnés. Dans le cas de notre exemple, on augmente la taille du motif précédent de 5 échantillons de chaque côté.

Il n'est cependant pas possible de réduire la taille d'un motif, afin de ne pas perdre des données sur les exemples précédemment sélectionnés.

Mode étendu

Il existe certains cas où les valeurs de deux features étudiées sont trop éloignées pour pouvoir être visualisé de manière correct. Pour cela, on peut basculer l'IHM en mode étendu, ce qui permet d'afficher chacune des features dans un graphique séparé. La région de sélection est commune aux différents graphes, i.e. sa taille et sa position est contrôlée via le graphique principal et se répercute sur les graphiques du mode étendu (c.f. figure 5.2)

5.2.2 Probability Visualization

Cette interface graphique permet de visualiser l'exemple que l'on investigate et la courbe de probabilité représentant la probabilité que le motif soit présent dans l'image. Celle-ci est composée de deux parties.

- La première partie (encadré vert sur la figure 5.3) affiche les features de l'exemple que l'on investigate. Par exemple, dans le cas présenté, on recherche la root cause liée à l'error name "chute du robot". Le système détecte que la root cause liée sur ce cas précis est "le frottement des freins de la hanche". Il nous affiche donc les courbes du capteur et de l'actuateur de la hanche, sur lesquelles on observe le motif caractéristique de la root cause.
- La deuxième partie (encadré rouge sur la figure 5.3) affiche la courbe de progression de la probabilité au cours du balayage des features de l'exemple (c.f. partie 4.2.2). La ligne horizontale sur le graphique représente le seuil à partir duquel on considère que la root cause est bien la cause ayant entraîné l'apparition de l'erreur.

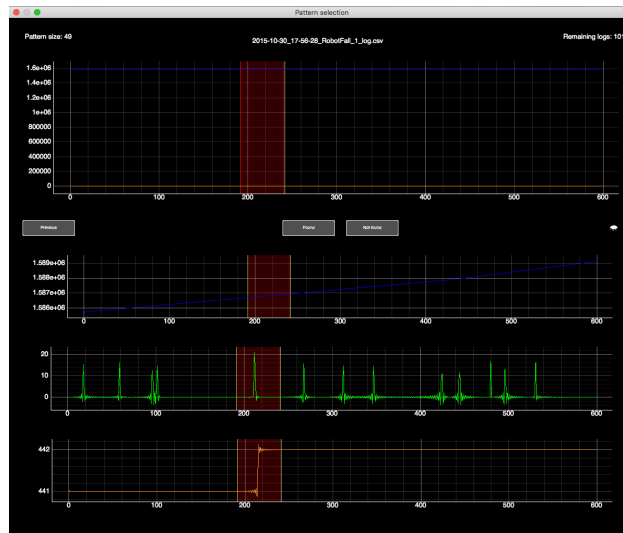


FIGURE 5.2 – Interface graphique du pattern selector en mode étendu. On observe sur ce graphiques trois features `BackPlatformAck`, `BackPlatformNack` et `BackPlatformError` du premier exemple. On remarque que l’affichage sur le graphique principal n’est pas clair. Le mode étendu permet d’afficher plus clairement chacune des features. La région de sélection est commune aux trois graphiques (même position, même taille).

5.2.3 Control panel

Le control panel permet d’obtenir un certain nombre d’informations quant à la qualité de la base de données d’exemple utilisée pour créer une nouvelle couche root cause ainsi que sur les performances de l’algorithme d’apprentissage automatique utilisé. La plupart de ces informations sont déterminées grâce aux outils soumis en partie 4.5. Il est composé de trois parties.

- La partie *Data set features* (encadré vert sur la figure 5.4) fournit un ensemble d’informations sur la base de données d’exemples utilisée pour l’entraînement de l’algorithme d’apprentissage automatique.
- La partie *Training panel features* (encadré rouge sur la figure 5.4) nous livre des informations sur l’algorithme d’apprentissage automatique de la couche root cause analysée (e.g. valeur des paramètres, matrice de confusion, précision, etc). Ces données sont pour la plupart relatives aux explications fournies en partie 4.5.
- La partie *Training panel* (encadré bleu sur la figure 5.4) permet d’analyser les courbes d’apprentissage (c.f. partie 4.5.3) et les courbes de validation (c.f. partie 4.5.1)

5.3 Utilisation suggérée des outils pour répondre au problème d’investigation du frottement des freins de la hanche

On propose dans cette partie un exemple d’utilisation de l’API et des interfaces graphiques. Cette solution a été mise en place dans le cadre du stage afin de proposer un outil permettant d’ores et déjà de gérer la base de données, de créer de nouvelles couches root cause et d’investiguer des fichiers logs. On s’appuie notamment sur l’utilisation de la librairie python *npyscreen* [?] qui permet de réaliser des interfaces utilisateurs simplifiées, directement dans le terminal.

On s’intéressera ici plus particulièrement au problème de frottement des freins de la hanche, entraînant la chute du robot durant le Filtering Test. Sa résolution passe donc par trois étapes :




FIGURE 5.3 – Interface graphique du probability visualizer.



FIGURE 5.4 – Interface graphique du control pattern.

1. Créer une nouvelles couche error name : la couche "chute du robot".
2. Créer un nouvelle couche root cause liée à la couche error name "chute du robot" : la couche "frottement des freins de la hanche". Cela signifie que l'on va entraîner un nouvel algorithme à détecter le motif caractéristique de cette root cause.
3. vérifier les performances de la nouvelle couche root cause créée via le control panel.
4. Investiguer un fichier log.

5.3.1 Menu principal

Le menu principal (c.f. figure) permet d'ouvrir 5 sous-menus qui permettent respectivement :

- Créer une nouvelle couche error name et l'ajouter à la base de donnée.
- Créer une nouvelle couche root cause, la lier à une couche error name et l'ajouter à la base de données.
- Investiguer un fichier log
- Mettre à jour une root cause

— Ouvrir le control panel

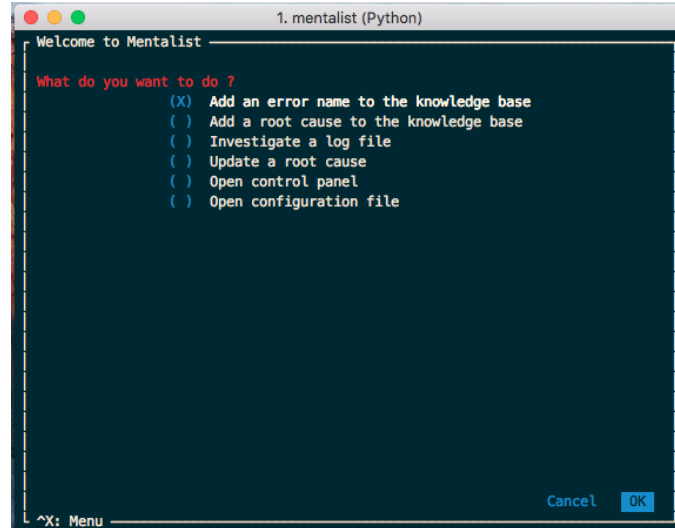


FIGURE 5.5 – Menu principal.

5.3.2 Nouvelle error name

Le menu "Add an error name to the knowledge base" (c.f. figure 5.5) permet d'ajouter une couche error name à la base de données.

Il suffit pour cela d'indiquer le nom de la couche error name que l'on souhaite créer : dans notre cas, on l'appellera **fall down**. Celle-ci ne contient à sa création aucune root cause.

5.3.3 Nouvelle root cause

Le menu "Add a root cause to the knowledge base" (c.f. figure 5.5) permet de créer une nouvelle root cause (i.e. entraîner un nouvel algorithme d'apprentissage à reconnaître une root cause), à la lier à une couche error name, et à l'ajouter à la base données.

Pour cela, on suit le processus suivant (c.f. figure 5.6) :

1. On sélectionne l'error name à laquelle on souhaite lier cette nouvelle root cause. On indique ensuite le nom de cette nouvelle root cause. Dans le cas de la root cause frottement des freins de la hanche, on la lie à l'error name "fall down" et on l'appelle "frottement des freins de la hanche".
2. On sélectionne la/les feature(s) liée(s) à la root cause. Dans le cas de la root cause du frottement des freins de la hanche, on sélectionne les clés HipPitchPositionSensorValue, HipPitchPositionActuatorValue, respectivement les valeurs du capteur et de l'actuateur de la hanche.
3. On utilise le Pattern Selector (c.f. partie 5.2.1) pour sélectionner les motifs caractéristiques de la root cause que l'on étudie. Dans notre cas, il s'agit du moment où le capteur ne suit plus l'actuateur. On répète cette manipulation pour chaque exemple de la base de données.

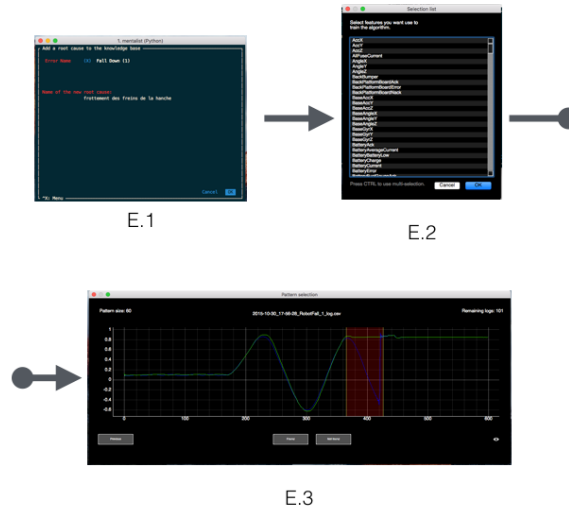


FIGURE 5.6 – Nouvelle root cause.

5.3.4 Investiguer un fichier log

Le menu "Investigate a log file" (c.f. figure 5.5) permet de réaliser une investigation sur un fichier log, i.e. trouver la root cause ayant entraîné l'apparition de l'error name durant le Filtering Test. Pour cela, on suit le processus suivant (c.f. figure 5.7) :

1. On commence par indiquer au script le chemin vers le fichier log. On sélectionne ensuite l'error name que l'on souhaite investiguer, parmi la liste des errors name connues (i.e. présentes dans la base de données).
2. Le programme nous affiche Probability Visualizer (c.f. partie 5.2.2)
3. Une fois le Probability Visualizer fermé, le script nous indique la root cause trouvée dans le fichier log.

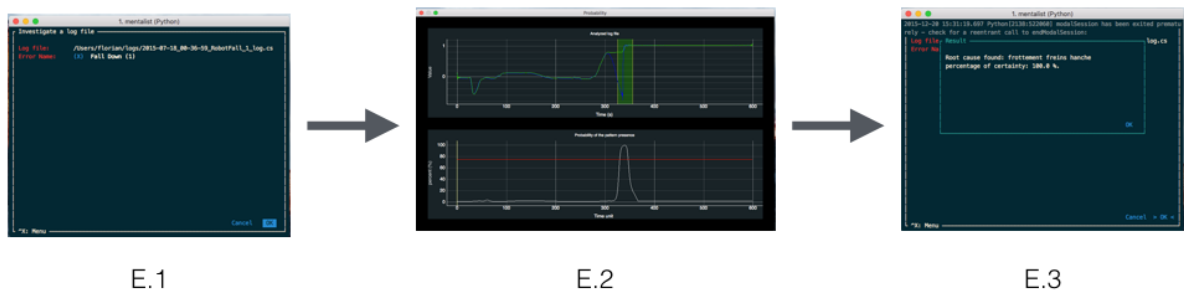


FIGURE 5.7 – Investigation d'un fichier log.

5.3.5 Analyse des performances d'une root cause

Le menu "Open control panel" (c.f. figure 5.5) permet de sélectionner une root cause liée à une error name et d'en afficher le control panel afin d'obtenir des informations sur la qualité des exemples utilisés pour entraîner l'algorithme d'apprentissage automatique ainsi que ses performances. Pour cela, on suit le processus suivant (c.f. figure 5.8) :

1. On sélectionne dans l'arborescence des errors name et des root cause qui leurs sont liées la root cause que l'on souhaite étudier.
2. Le control panel s'affiche (c.f. partie 5.2.3)




FIGURE 5.8 – Analyse des performances d'une couche root cause.

5.3.6 Mise à jour d'une root cause

Le menu "Update a root cause" (c.f. figure 5.5) permet d'ajouter des exemples à la base de données d'exemples d'une root cause déjà connue (i.e. enregistrée dans la base de données) et d'entraîner de nouveau l'algorithme d'apprentissage afin d'en améliorer les performances. Pour cela, on suit le processus suivant (c.f. figure 5.8) :

1. On sélectionne dans l'arborescence des errors name et des root cause qui leurs sont liées la root cause que l'on souhaite mettre à jour.
2. On sélectionne les motifs caractéristiques de la root cause dans les exemples ajoutés.

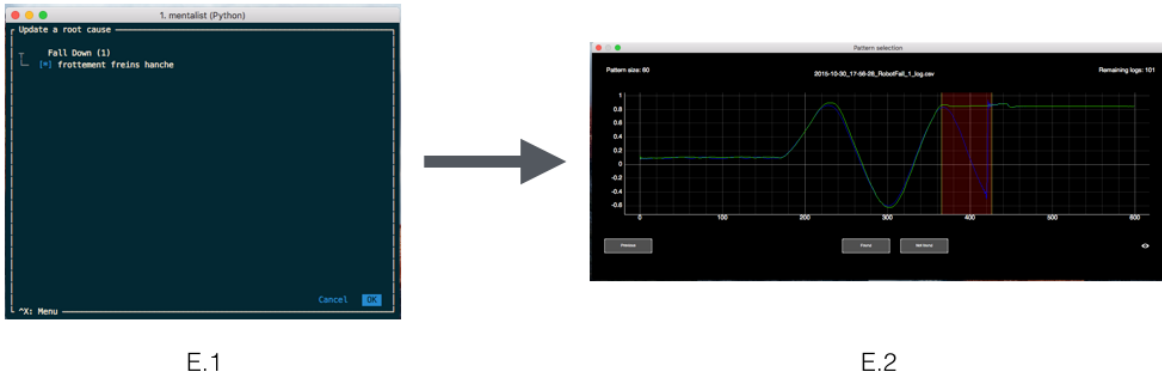


FIGURE 5.9 – Mise à jour d'une root cause.

5.4 Dimensionnement de la solution

Contrairement à l'étude réalisée en partie 4.5, on désire mesurer ici non pas uniquement la performance de l'algorithme, mais également l'influence du facteur humain sur celle-ci. On s'intéresse notamment à l'impact qu'à l'évolution de la taille de la région mobile du Pattern selector (c.f. partie 5.2.1), qui permet de sélectionner les échantillons du motif caractéristique d'une root cause. En effet, cette variable dépend de la forme du motif, mais également de l'appréciation de l'utilisateur (quand commence le motif, quand se termine-t-il ?).

Afin de quantifier cette dimension, on réalise plusieurs fois la création de la couche root cause du "frottement des freins de la hanche" en augmentant à chaque fois la taille de la région de sélection. On prélève la précision à chaque itération. On affiche la courbe

d'évolution de la précision de l'algorithme d'apprentissage automatique, en fonction de la taille de la région de sélection en figure 5.10




FIGURE 5.10 – Évolution de la précision de l'algorithme en fonction de la taille de la région de sélection. On observe que entre une taille de 10 et 30 échantillons, la précision de l'algorithme augmente légèrement. A partir de 30 échantillons, la précision de l'algorithme diminue.

Au regard des valeurs obtenues, on en déduit que l'algorithme est plus performant lorsque la région de sélection est petite. Or, le but est également de sélectionner le plus précisément possible le motif caractéristique d'une root cause. Il faut donc jauger chaque situation au cas par cas, en gardant en tête ces deux contraintes. Par exemple, si on souhaite apprendre notre algorithme à reconnaître une région ayant une taille de 50 échantillons, il sera peut-être plus opportun d'apprendre l'algorithme à reconnaître seulement une partie du motif (de 30 échantillons environ).

Chapitre 6

Conclusion

J'ai eu la chance de pouvoir réaliser mon stage de fin d'études au sein d'Aldebaran sous la tutelle de Emmanuel Nalepa, chef de l'équipe Qualification Hardware Pepper. Cette opportunité m'a permis de bénéficier d'une première expérience dans le monde Machine Learning, de la qualification et d'acquérir un ensemble de techniques indispensables à leurs pratique. Il s'agissait ici d'automatiser le processus d'investigation permettant de déterminer la cause ayant provoqué l'apparition d'une erreur durant le Filtering Test. Ce test vise à stresser l'ensemble des parties mécaniques en fin de chaîne de production, afin de révéler un maximum d'erreurs avant d'envoyer le produit chez le client.

Dans un premier temps, je me suis familiarisé avec les théories mathématiques qui fondent le Machine Learning. J'ai mis en pratique plusieurs des différentes méthodes algorithmiques afin d'en étudier leurs fonctionnement, leurs champs d'applications et les possibilités que celles-ci offraient au regard de notre problématique. J'ai ensuite comparé les différentes possibilités et émis un choix sur l'une d'entre elles : on effectuera de l'apprentissage automatique supervisé en s'appuyant sur l'algorithme *Support Vector Machine* (SVM).

Dans un second temps, j'ai mis en place l'architecture fonctionnelle du système d'automatisation des investigations, en prenant en compte les contraintes imposées par les outils déjà mis en place, comme par exemple la structure des données générées lors de l'apparition d'une erreur durant le Filtering Test.

Enfin, j'ai conçu des outils informatiques permettant d'utiliser le plus simplement possible les algorithmes de Machine Learning, dans le but de répondre à la problématique.

Sur le plan technique, ce stage a été pour moi plus que bénéfique. Grâce à la nature pluridisciplinaire du sujet et plus généralement de la qualification, j'ai pu mettre en application mes connaissances dans plusieurs domaines et d'assimiler de nouvelles aptitudes dans des disciplines là aussi variées. Sur le plan humain, j'ai eu la chance d'être conseillé par un tuteur faisant preuve de beaucoup de pédagogie et de travailler dans un cadre agréable grâce à la bonne humeur émanant de mon équipe.